

人工智能 原理与实践

• 刘鸿福 副研究员

• 国防科技大学 智能科学学院






内容回顾



规划的定义

- ◆ 行动规划是采用AI理论与技术实现规划自动化的技术
- ◆ 行动规划是关于动作的推理，一个规划解就是一个行动过程的描述
 - 与基于遗传算法等智能方法的线性、非线性规划问题（programming）不同，规划实现目标的动作序列是行动规划的主要任务



规划解是一系列动作，当应用这些动作时，会在一个或多个步骤中将初始世界状态转换为目标状态



内容回顾



规划思维

01

预有规划

02

穷尽可能

03

优化效能

04

成就目标

05

基于预案

06

观察判断

07

学习调整

08

灵活机动

主要内容

第三章 知识表示与推理 >>>

- 3.1 逻辑Agent
- 3.2 谓词逻辑
- 3.3 规划问题与算法
- 3.4 不确定知识与推理

主要内容


3.4 不确定知识与推理

- ✓ 3.4.1 不确定性概述
- ✓ 3.4.2 不确定领域的知识表示
- ✓ 3.4.3 贝叶斯网络
- ✓ 3.4.4 基于贝叶斯网络的推理



1 不确定性的表现

由于客观世界的复杂、多变性和人类自身认识的局限、主观性，致使我们所获取的、所处理的信息和知识中，往往含有不肯定、不准确、不完全甚至不一致的成分，这就是所谓的**不确定性**。





3.4.1 不确定性概述

3.4 不确定知识与推理

1 不确定性的表现

环境部分可观察与不确定

由于观测手段局限或不可观测性等原因，对环境信息获取不准确、不完备。

例：

智能导弹协同突防过程中，对防御方的不完全态势感知等。






1 不确定性的表现

行动效果的不确定：随机动作引起行动效果不确定，或者在多智能体环境中，由于对方策略未知，导致行动效果具有不可预知性。

例：智能导弹突防时，不知道防御方的防御策略，使得（突防）行动效果具有不可预知性。





你认为下面哪些性质属于不确定性？

A

随机性

B

模糊性

C

信息不完全、
状态部分可观

D

多源信息不一致性

提交



1 不确定性的表现





1 不确定性的表现

一个命题（亦即所表示的事件）的真实性不能完全肯定，而只能对其为真的可能性给出某种估计。

随机性

狭义不确定性



如果乌云密布并且电闪雷鸣
则很可能要下暴雨



如果头痛发烧
则大概是患了感冒



1 不确定性的表现

一个命题中所出现的某些言辞，从概念上说，无明确的内涵和外延，即是模糊不清的



姚明是个高个子



张三和李四是好朋友

模糊性



1 不确定性的表现

对某事物来说，关于它的信息或知识还不全面、不完整、不充分

不完全性



战场上，交战双方对对手的信息掌握往往是不完全的。


警方破案过程中，所掌握的关于罪犯的有关信息，往往就是不完全的。



1 不确定性的表现

- 在推理过程中发生了前后不相容的结论，或者随着时间的推移或范围的扩大，原来一些成立的命题变得不成立、不适合。
- 多源信息不一致性，多智能体的协作，如何达成一致理解。

不一致性



牛顿运动定律对于宏观世界是正确的，但对于微观世界和宇观世界却是不适合的。



2 不确定性下的动作

➤ 案例1：Agent决策提前多久出发赶高铁

用 A_t 表示提前 t 分钟出发前往高铁站， A_t 能使我按时到达吗？

可能存在如下问题：


1. 部分可观（路况、其他司机驾驶行为等）
2. 含有噪声的传感信息（不准确的路况报告）
3. 不确定的行为结果（爆胎、没油/没电等）
4. 建模与预测交通状况面临巨大的复杂性

理性决策（rational decision），既依赖各种目标的相对重要性，也依赖它们实现的可能性和程度



2 不确定性下的动作

➤ 案例2: Agent侦察未知环境



◆ 同时在 (1,2)和 (2,1)中感受到震动异常

→ 没有安全的行为

◆ 假定陷阱是均匀分布的；无路可走的情况下，
选择一个相对安全的行动？

(2,2)有陷阱的概率大于 (1,3) 和 (3,1)



3 引入概率处理不确定性（随机性）

引入概率处理不确定性的原因：

惰性 (laziness)

无法列出没有任何意外的规则的所有前提和结论

理论无知 (Ignorance)

缺乏相关领域的完整理论和规则

实践无知 (Ignorance)


即使知道所有规则，对于特定的情况也无法确定，因为不是所有必要的测试都完成了

引入概率论，用概率定量描述语句成立的信念度



3 引入概率处理不确定性（随机性）

逻辑智能体的本体论约定相信每个命题或对或错，要么0、要么1；而概率智能体的认识论约定有着0和1之间的数值信念度。



➤ 概率论提供了一种概括因惰性与无知而产生的不确定性的方式，从而解决了逻辑的资格问题，即关于不同知识状态的单独断言



3 引入概率处理不确定性（随机性）

逻辑智能体的本体论约定相信每个命题或对或错，要么0、要么1；而**概率智能体**的认识论约定有着0和1之间的数值信念度。

- 概率论提供了一种概括因惰性与无知而产生的不确定性的方式，从而解决了逻辑的资格问题，即关于不同知识状态的单独断言
- 决策依赖于决策者的偏好(preferences)：
误车 vs. 车站等待，等等。

效用理论(Utility theory)：对偏好进行描述和推理

决策
理论

效用理论+ 概率论

期望效用最大化原则：一个**理性 Agent**当且仅当选择能产生最高期望效用的行动，这里的期望效用是行动的所有可能结果的平均



3 引入概率处理不确定性（随机性）

采样空间
(样本空间)

Ω ，所有可能世界组成的集合，比如六个面的色（骰）子，样本空间为6；

采样点

$\omega \in \Omega$ ，采样空间中的一个样本，即一个特定的可能世界

概率模型

对于任意的采样点 $\omega \in \Omega$ ，在整个采样空间 Ω 出现的概率

$$0 \leq P(\omega) \leq 1$$

比如： $P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$ 。 $\sum_{\omega} P(\omega) = 1$



3 引入概率处理不确定性（随机性）

概率断言和查询通常不是关于某个特定的可能世界的，而是关于**可能世界的集合**。比如，掷色子，两个色子相加等于11，两个点数相同。

随机事件： Φ 是采样空间 Ω 的子集

$$P(\Phi) = \sum_{\{\omega \in \Phi\}} P(\omega)$$

$$\begin{aligned} &P(\text{Total}=11) \\ &= P((5,6)) + P((6,5)) \\ &= 1/36 + 1/36 \\ &= 1/18. \end{aligned}$$



3 引入概率处理不确定性（随机性）

随机变量

(Random variables)

随机变量 (Random variables) 是一个采样点到一个值域的映射函数，用**大写字母**表示。每个随机变量有一个定义域 (domain) — 这个变量能取的所有可能值对应采样点组成的集合。



3 引入概率处理不确定性（随机性）

布尔随机变量

- 定义域为 $\langle \text{true}, \text{false} \rangle$ ，比如 $Lowbat$ 的定义域为 $\langle \text{true}, \text{false} \rangle$ ，通常可以将 $Lowbat = \text{true}$ 这样的命题简写成 **小写字母** 的名称 $lowbat$ ，类似的 $Lowbat = \text{false}$ 简写成 $\neg lowbat$

➤ 例1

采样空间为色子的点数构成的空间，随机变量 Odd 的值域为 $\{\text{true}, \text{false}\}$ ，因此可将采样点映射为 true 或 false ，如：

$$Odd(1) = \text{true}$$

对于任意的随机变量 X ，其概率分布为：

$$P(X = x_i) = \sum_{\{\omega: X(\omega) = x_i\}} P(\omega)$$

如：

$$P(Odd = \text{true}) = 1/6 + 1/6 + 1/6 = 1/2$$



3 引入概率处理不确定性（随机性）

离散随机变量

- 取值来自于一个可数集，
- 比如 $Weather$ 的定义域为 $\langle sunny, rainy, cloudy, snow \rangle$ ， $Weather=sunny$ 简写成 $sunny$ 。
在不引起歧义的情况下，可以用一个值本身表示“一个特定的变量取这个值”

➤ 比如

$$P(sunny) = P(Weather = sunny)$$

$$P(unmovable) = P(Unmovable = true)$$

$$P(\neg unmovable) = P(Unmovable = false)$$

基本命题，比如 $Unmovable = false$ 和 $Lowbat = true$ ，可以通过所有标准逻辑连接符进行组合形成复合命题。
 $Unmovable = false \wedge Lowbat = true$ ，可以简写为 $\neg unmovable \wedge lowbat$

主要内容

3.4 不确定知识与推理

- ✓ 3.4.1 不确定性概述
- ✓ 3.4.2 不确定领域的知识表示
- ✓ 3.4.3 贝叶斯网络
- ✓ 3.4.4 基于贝叶斯网络的推理



1 先验概率

先验概率（无条件概率）

没有给定事实或者依据，根据以往获得的一些历史的经验赋予的一个概率值，也就是一个信念值 (belief) 。

比如：

$$P(\text{Lowbat} = \text{true}) = 0.1$$

$$P(\text{Weather} = \text{sunny}) = 0.72$$

概率分布

给出了所有可能的概率。

例如：

$$\mathbf{P}(\text{Weather}) = (0.72, 0.1, 0.08, 0.1)$$

（通常，加权和等于1）

$\text{Weather} = \{\text{sunny}, \text{rain}, \text{cloudy}, \text{snow}\}$




1 先验概率

概率公理

$$P(\neg a) = 1 - P(a)$$

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$





1 先验概率

联合概率分布

针对一系列变量，给定每个事件发生的概率。

例如：

$P(\text{Weather}, \text{Lowbat})$ 是一个 4×2 的概率表：

Weather = sunny rain cloudy snow

Lowbat = true 0.144 0.02 0.016 0.02

Lowbat = false 0.576 0.08 0.064 0.08

给定联合概率分布之后，关于定义在采样空间上的任何事件概率的问题都可以通过对事件所覆盖的所有采样点的联合概率加和而求得。



2 条件概率（后验概率）

- 比如， $P(\text{lowbat} \mid \text{unmovable}) = 0.8$
- 含义：已知无人车无法移动的条件，且没有其他新的证据时，低电量的概率为80%。

> 条件概率分布

$P(\text{lowbat} \mid \text{unmovable})$ 是一个值，而 $P(\text{Lowbat} \mid \text{Unmovable})$ 是 2×2 的矩阵。

条件概率有可能随着新证据的增加变化，也可能保持不变，需要看新增加的证据是否与考察的随机变量有关，若新加入的证据与随机变量无关，则可以化简，是否相关属于领域内知识。

$$P(\text{lowbat} \mid \text{unmovable}, \text{lowbat}) = 1$$

$$P(\text{lowbat} \mid \text{unmovable}, \text{ChinaWin}) = P(\text{lowbat} \mid \text{unmovable}) = 0.8$$

注意：符号“|”的优先级： $P(\dots \mid \dots) = P((\dots) \mid (\dots))$



2 条件概率（后验概率）

条件概率的定义： $P(a|b) = \frac{P(a \wedge b)}{P(b)}$ if $P(b) \neq 0$

可以变换为： $P(a \wedge b) = P(a/b)P(b) = P(b/a)P(a)$

➤ 比如：

$$P(\text{Weather}, \text{Lowbat}) = P(\text{Weather} / \text{Lowbat})P(\text{Lowbat})$$

（看做 4×2 的方程集合，而非矩阵乘。）

➤ 链式规则：

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1}) P(X_n / X_1, \dots, X_{n-1}) \\ &= P(X_1, \dots, X_{n-2}) P(X_{n-1} / X_1, \dots, X_{n-2}) P(X_n / X_1, \dots, X_{n-1}) \\ &= \dots \\ &= \prod_{i=1}^n P(X_i / X_1, \dots, X_{i-1}) \end{aligned} \quad (\text{注: } P(X_1|X_0)=P(X_1))$$



以下条件概率的计算表达式，哪些是正确的？

A

$$P(e,f)=P(e|f)P(f)$$

B

$$P(i,j,k)=P(i|j,k)P(j,k)$$

C

$$P(i,j,k)=P(i|j,k)P(j|k)P(k)$$

D

$$P(w,x,y,z)=P(x|w,y,z)P(x,y,z)$$

提交



3 基于联合概率分布的推理

从全联合概率分布出发：

	unmovable		$\neg$ unmovable	
	flattire	$\neg$ flattire	flattire	$\neg$ flattire
lowbat	0.108	0.012	0.072	0.008
$\neg$ lowbat	0.016	0.064	0.144	0.576

对于任意事件 ϕ , 其概率为使该事件为真的所有原子事件的概率和：

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$

$$P(\text{unmovable}) = ?$$



3 基于联合概率分布的推理

从全联合概率分布出发：

	unmovable		$\neg$ unmovable	
	flattire	$\neg$ flattire	flattire	$\neg$ flattire
lowbat	0.108	0.012	0.072	0.008
$\neg$ lowbat	0.016	0.064	0.144	0.576

对于任意事件 ϕ , 其概率为使该事件为真的所有原子事件的概率和：

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$

$$P(\text{unmovable}) = ?$$

$$P(\text{unmovable}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$



3 基于联合概率分布的推理

从全联合概率分布出发：

	unmovable		$\neg$ unmovable	
	flattire	$\neg$ flattire	flattire	$\neg$ flattire
lowbat	0.108	0.012	0.072	0.008
$\neg$ lowbat	0.016	0.064	0.144	0.576

对于任意事件 ϕ , 其概率为使该事件为真的所有原子事件的概率和：

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega) \quad P(\text{unmovable} \vee \text{lowbat}) = ?$$

$$\begin{aligned} P(\text{unmovable} \vee \text{lowbat}) &= P(\text{unmovable}) + P(\text{lowbat}) - P(\text{unmovable} \wedge \text{lowbat}) \\ &= 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28 \end{aligned}$$



3 基于联合概率分布的推理

从全联合概率分布出发：

	unmovable		¬unmovable	
	flattire	¬flattire	flattire	¬flattire
lowbat	0.108	0.012	0.072	0.008
¬lowbat	0.016	0.064	0.144	0.576

➤ (练习) 计算条件概率如下：

$$P(\neg lowbat | unmovable) = ?$$

$$\begin{aligned} & P(\neg lowbat | unmovable) \\ &= \frac{P(\neg lowbat \wedge unmovable)}{P(unmovable)} \end{aligned}$$

$$= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

$$P(lowbat | unmovable) = ?$$

$$= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064}$$

$$= 0.6$$



4 贝叶斯规则

条件概率的定义: $P(X|Y) = \frac{P(X,Y)}{P(Y)}$ if $P(Y) \neq 0$

➤ 据此进一步推导贝叶斯规则:

$$P(X, Y) = P(X)P(Y|X) = P(X|Y)P(Y)$$

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

以某个背景证据 e 为条件的情况

$$P(Y|X, e) = \frac{P(X|Y, e)P(Y|e)}{P(X|e)}$$



4 贝叶斯规则

◆ 贝叶斯规则: $P(X, Y) = P(X)P(Y|X) = P(X|Y)P(Y)$

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$



◆ 将未知因素cause造成的结果effect看作是证据，从而确定未知因素cause，贝叶斯规则可描述为：

$$P(\text{cause}|\text{effect}) = \frac{P(\text{effect}|\text{cause})P(\text{cause})}{P(\text{effect})}$$

其中，条件概率 $P(\text{effect}|\text{cause})$ 量化了因果方向上的关系，而 $P(\text{cause}|\text{effect})$ 描述诊断方向上的关系。



4 贝叶斯规则

➤ 例题练习：情报分析贝叶斯决策系统

- 实战演练：NX情报验证
- 战场参数：
 - 历史情报准确率：20%
 - 情报分析系统：
 - 真实情报触发警报概率：95%
 - 虚假情报触发警报概率：15%



警报触发时，情报真实的概率是多少？

主要内容


3.4 不确定知识与推理

- ✓ 3.4.1 不确定性概述
- ✓ 3.4.2 不确定领域的知识表示
- ✓ 3.4.3 贝叶斯网络
- ✓ 3.4.4 基于贝叶斯网络的推理



1 贝叶斯网络概念

贝叶斯网络 (Bayesian Networks, BN) 也称作信念网络、因果网络、概率网络等，是用来表示变量间连接概率的图形模式，它提供了一种自然的表示因果信息的方法，用来发现数据间的潜在关系。在BN中，用节点表示变量，有向边表示变量间的依赖关系。





1 贝叶斯网络概念

◆ 贝叶斯方法发展历史

贝叶斯方法奠基性工作是由**托马斯-贝叶斯**（**Thomas Bayes**）的论文“关于几率问题求解的评论”。

20世纪50年代，以**罗宾斯**为代表，提出了经验贝叶斯方法和经典方法相结合，引起统计界的广泛注意，成为很活跃的一个方向。



托马斯·贝叶斯（1702-1761）



1 贝叶斯网络概念

◆ 贝叶斯方法发展历史

朱迪亚·珀尔 (Judea Pearl)

- 1988年，提出贝叶斯网络，2011年获图灵奖，被誉为“贝叶斯网络之父”
- 人工智能的发展，尤其是机器学习、数据挖掘等兴起，为贝叶斯理论的发展和应用提供了更为广阔的空间，贝叶斯理论的内涵不断深化和拓展：因果深度学习(Causal Deep Learning)、神经符号系统 (Neuro-Symbolic AI) 等交叉领域。



Judea.Pearl (1936-)



1 贝叶斯网络概念

◆ 贝叶斯学派

统计学中两个主要学派：**频率学派**和**贝叶斯学派**



托马斯.贝叶斯 (1702-1761)

贝叶斯概率与传统概率之间最大的区别在于他们对**某个事件概率**的定义是不一样的

经典概率定义一个事件的概率是确定的，并且是**客观的**；而贝叶斯概率认为，一个事件的概率是确定这个概率的人的**主观判断**




Judea.Pearl (1936-)

传统概率是客观认识，而贝叶斯概率是主观判断。



1 贝叶斯网络概念

贝叶斯方法的基本思想是用概率去表示所有形式的不确定性，学习或其它形式的推理都用概率规则来实现。





1 贝叶斯网络概念

最优决策

决策网络包含实用信息，概率推理要求

$$P(outcome|action,evidence)$$

信息价值评估

下一步搜索哪个证据？

联合查询

$$\begin{aligned} P(X_i, X_j | E=e) \\ = P(X_i | E=e) P(X_j | X_i, E=e) \end{aligned}$$

贝叶斯网络 能解决的问题

敏感性分析

同一结果，若干个概率值，哪个概率值最关键？

单个查询

计算后验概率

$$P(X_i | E=e)$$

解释问题

同一个状态，为什么采取了某一行动？



2 贝叶斯网络语法语义

语法

节点集合，对于每个随机变量用一个节点表示

一个连接节点对的有向边或箭头集合，如果存在从节点X指向节点Y的有向边则称X是Y的父节点

对每个节点，有一个与每个父节点相关的条件概率分布，量化其父节点对该节点的影响

$$P(X_i | \text{Parents}(X_i))$$

条件概率分布可以表示成条件概率表（Conditional Probability Table, CPT）的形式，它覆盖所有父节点的每个可能的取值组合。



2 贝叶斯网络语法语义

例 1

智能边境围栏系统 边境闯入预警

某边境安装有智能围栏系统，预警探测雷达、光学监视系统等，出现人员越境Enemy或者动物Animal经过时，会发出信号Signal。接收器R1和接收器R2收到后会在哨所鸣响警报，但有时接收器R1会发生虚警误报；有时R2会因信号干扰等，可能虚报漏报


变量

Enemy, Animal, Signal, R1Alarm, R2Alarm



2 贝叶斯网络语法语义

例1 智能边境围栏系统边境闯入预警



首先确定贝叶斯变量，“由因及果”分析梳理变量之间的关系，画出贝叶斯网络的拓扑结构。



2 贝叶斯网络语法语义


条件概率表 (CPT) : 对于一个变量 Z , CPT定义了一个条件分布 $P(Z|\text{parent}(Z))$; 其中, $\text{parent}(Z)$ 表示 Z 的父结点。

- ◆ 如果结点 X 没有父结点, 则表中只包含先验概率 $P(X)$;
- ◆ 如果结点 X 只有一个父结点 Y , 则表中包含条件概率 $P(X | Y)$;
- ◆ 如果结点 X 有多个父结点 $\{Y_1, Y_2, \dots, Y_k\}$, 则表中包含条件概率 $P(X | Y_1, Y_2, \dots, Y_k)$



2 贝叶斯网络语法语义


➤ 例1 边境闯入预警——条件概率表 (CPT)





2 贝叶斯网络语法语义

◆ 全局语义：全联合概率分布与局部条件概率分布之间的关系




$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1}) P(X_n | X_1, \dots, X_{n-1}) \\ &= P(X_1, \dots, X_{n-2}) P(X_{n-1} | X_1, \dots, X_{n-2}) P(X_n | X_1, \dots, X_{n-1}) \\ &= \dots \\ &= \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1}) \end{aligned}$$



2 贝叶斯网络语法语义

◆ **全局语义：** 全联合概率分布与局部条件概率分布之间的关系




$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Parents}(X_i))$$

$$P(r1 \wedge r2 \wedge s \wedge \neg e \wedge \neg a) = ?$$



2 贝叶斯网络语法语义


◆ **全局语义：** 全联合概率分布与局部条件概率分布之间的关系



$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Parents}(X_i))$$

$$P(r1 \wedge r2 \wedge s \wedge \neg e \wedge \neg a) = P(r1 \mid s)P(r2 \mid s)P(s \mid \neg e, \neg a)P(\neg e)P(\neg a)$$

$$P(r1 \wedge r2 \wedge \neg s \wedge e \wedge \neg a) = ?$$



- ☒ A $P(r1 \mid \neg s)P(r2 \mid \neg s)P(\neg s \mid e, \neg a)P(e)P(\neg a)$
- ☐ B $P(r1 \mid \neg s)P(r2 \mid \neg s)P(\neg s \mid e, \neg a)P(\neg e)P(\neg a)$
- ☐ C $P(r1 \mid \neg s)P(r2 \mid \neg s)P(s \mid e, \neg a)P(e)P(\neg a)$
- ☐ D $P(r1 \mid s)P(r2 \mid s)P(s \mid \neg e, \neg a)P(\neg e)P(\neg a)$



提交



2 贝叶斯网络语法语义

◆ **局部语义：**充分利用条件独立性，分析哪些变量之间是独立的

贝叶斯网络中的一个结点，如果它的父结点已知，则该结点条件独立于它的所有非后代结点。





3 贝叶斯网络的构建

◆ 构造贝叶斯网络一般分为三个步骤

第一步

确定变量集和变量域

第二步

确定网络结构

第三步

确定节点条件概率表



3 贝叶斯网络的构建



确定条件概率表：一旦找到了合适的拓扑结构，与各结点关联的概率表就确定了。对这些概率的估计比较容易，与朴素贝叶斯分类器中所用的方法类似


方法一：用先验数据的统计频率和用户的知识确定

方法二：用户通过测试和观察确定

方法三：根据专家的知识确定



3 贝叶斯网络的构建



在**非因果方向**上，确定条件独立是困难的，且网络的压缩效果也不理想，如该结构的贝叶斯网络需要的概率值为：

$1+1+4+2+4=12$ ，前面基于因果关系构造的网络所需概率值为10个，全联合概率分布需要的概率值为 $2^5-1=31$ 个。

主要内容

3.4 不确定知识与推理

- ✓ 3.4.1 不确定性概述
- ✓ 3.4.2 不确定领域的知识表示
- ✓ 3.4.3 贝叶斯网络
- ✓ 3.4.4 基于贝叶斯网络的推理



1 贝叶斯网络的精确推理

◆ 智能边境围栏系统——边境闯入预警

某边境安装有智能围栏系统，预警探测雷达、光学监视系统等，出现人员越境Enemy或者动物Animal经过时，会发出信号Signal。接收器R1和接收器R2收到后会在哨所鸣响警报，但有时接收器R1会发生虚警误报；有时R2会因信号干扰等，可能虚报漏报。


假设某天,接收器R1和接收器R2对应的警报器都响了，问此时边境发生人员越境的概率。

变量

Enemy, Animal, Signal, R1Alarm, R2Alarm



1 贝叶斯网络的精确推理





1 贝叶斯网络的精确推理

已知，一个事件 $e = \{R1Alarm = true, \text{ and } R2Alarm = true\}$ ，试问出现人员闯入的概率是多少？

➤ 解：

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

而 $P(X, e, y)$ 可写成条件概率乘积的形式。

- 因此，在贝叶斯网络中可通过计算条件概率的乘积并求和来回答查询。

$$P(Enemy|R1Alarm = true, R2Alarm = true)$$

简写为：

$$\begin{aligned} P(E|r1, r2) &= \frac{P(E, r1, r2)}{P(r1, r2)} = \alpha P(E, r1, r2) = \alpha \sum_a \sum_s P(E, a, s, r1, r2) \\ &= \alpha \sum_a \sum_s P(E)P(a)P(s|E, a)P(r1|s)P(r2|s) \\ &= \alpha P(E) \sum_a P(a) \sum_s P(s|E, a)P(r1|s)P(r2|s) \end{aligned}$$



1 贝叶斯网络的精确推理

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

使用求和消元

用完全联合分布进行计算。通过独立性可减小概率表的规模。

贝叶斯公式



$$= P(e|X) P(X)$$

使用贝叶斯公式

分解为一个条件概率表和一个无条件概率表。当证据 e 过多时条件概率表规模过大

$$P(Y|x) = \alpha P(x|Y)P(Y)$$



1 贝叶斯网络的精确推理

已知，一个事件 $e = \{R1Alarm = true, \text{ and } R2Alarm = true\}$ ，试问出现人员闯入的概率是多少？


➤ 解：

$$\begin{aligned} P(E|r1,r2) &= \alpha P(E,r1,r2) = \alpha \sum_a \sum_s P(E,a,s,r1,r2) \\ &= \alpha \sum_a \sum_s P(E)P(a)P(s|E,a)P(r1|s)P(r2|s) \\ &= \alpha P(E) \sum_a P(a) \sum_s P(s|E,a)P(r1|s)P(r2|s) \end{aligned}$$

$$P(e|r1,r2) = \alpha P(e) \sum_a P(a) \sum_s P(s|e,a)P(r1|s)P(r2|s)$$

$$P(\neg e|r1,r2) = \alpha P(\neg e) \sum_a P(a) \sum_s P(s|\neg e,a)P(r1|s)P(r2|s)$$

$$P(e|r1,r2) + P(\neg e|r1,r2) = 1$$





1 贝叶斯网络的精确推理

已知，一个事件 $e = \{R1Alarm = true, \text{ and } R2Alarm = true\}$ ，试问出现人员闯入的概率是多少？


➤ 解：

$$\begin{aligned} P(e| r1, r2) &= \alpha P(e) \sum_a P(a) \sum_s P(s|e, a) P(r1|s) P(r2|s) \\ &= \alpha P(e) \left[P(a) \sum_s P(s|e, a) P(r1|s) P(r2|s) + P(\neg a) \sum_s P(s|e, \neg a) P(r1|s) P(r2|s) \right] \\ &= \alpha P(e) \{ P(a) [P(s|e, a) P(r1|s) P(r2|s) + P(\neg s|e, a) P(r1|\neg s) P(r2|\neg s)] \\ &\quad + P(\neg a) [P(s|e, \neg a) P(r1|s) P(r2|s) + P(\neg s|e, \neg a) P(r1|\neg s) P(r2|\neg s)] \} \\ &= \alpha \times 0.001 \times \{ [0.002 \times (0.95 \times 0.9 \times 0.7 + 0.05 \times 0.05 \times 0.01)] + \\ &\quad [0.998 \times (0.94 \times 0.9 \times 0.7 + 0.06 \times 0.05 \times 0.01)] \} \\ &= \alpha \times 0.00059224 \end{aligned}$$



1 贝叶斯网络的精确推理

◆ 查询条件概率表的数值，代入公式计算





1 贝叶斯网络的精确推理

一个事件 $e = \{R1Alarm = true, \text{ and } R2Alarm = true\}$ ，试问出现人员闯入的概率是已知，多少？

$$\begin{aligned} P(\neg e | r1, r2) &= \alpha P(\neg e) \sum_a P(a) \sum_s P(s | \neg e, a) P(r1 | s) P(r2 | s) \\ &= \alpha P(\neg e) \{P(a) [P(s | \neg e, a) P(r1 | s) P(r2 | s) P(\neg s | \neg e, a) P(r1 | \neg s) P(r2 | \neg s)] \\ &\quad + P(\neg a) [P(s | \neg e, \neg a) P(r1 | s) P(r2 | s) + P(\neg s | \neg e, \neg a) P(r1 | \neg s) P(r2 | \neg s)]\} \\ &= \alpha \times 0.999 \times \{[0.002 \times (0.29 \times 0.9 \times 0.7 + 0.71 \times 0.05 \times 0.01)] + [0.998 \times \\ &\quad (0.001 \times 0.9 \times 0.7 + 0.999 \times 0.05 \times 0.01)]\} \\ &= \alpha \times 0.0014919 \end{aligned}$$



1 贝叶斯网络的精确推理

$$P(e| r1, r2) + P(\neg e| r1, r2) = 1$$

$$\alpha \times 0.00059224 + \alpha \times 0.0014919 = 1$$

做归一化处理，可以在不计算出 α 的情况下，计算出**比值**

$$\frac{0.00059224}{0.00059224 + 0.0014919} = 0.284165$$

➤ 因此


$$P(E|r1, r2) = \alpha < 0.00059224, 0.0014919 > \\ \approx < 0.284, 0.716 >$$

即在接收器1和接收器2都报警的条件下，出现人员越境的概率约为**28.4%**。



2 枚举法

$$P(e | r1, r2) = \alpha P(e) \sum_a P(a) \sum_s P(s | e, a) P(r1 | s) P(r2 | s)$$



$P(e | r1, r2)$
的自顶向下的计算过程



2 枚举法

$$P(e|r1,r2) = \alpha P(e) \sum_a P(a) \sum_s P(s|e,a)P(r1|s)P(r2|s)$$

通过枚举进行推理

缺点：重复计算效率较低


算法改进的思路：变量消元法

基本思想： 从右向左的顺序计算条件概率表达式，中间结果保存下来，而对每个变量的求和只需要对依赖于这些变量



练习题

➤ 考虑下图所示的贝叶斯网络，解答下列问题：



1、网络结构能否断言下列语句?若不能，请写出正确的表达式。

$P(B, I, M) = P(B) P(I) P(M)$ 不能，正确的表达式为：
 $P(B, I, M) = P(B) P(I|B, M) P(M)$

$P(J|G) = P(J|G, I)$ 能

$P(M|G, B, I) = P(M|G, B, I, J)$ 能

2、计算 $P(b, i, \neg m, G, \neg j)$



练习题解答

2、计算 $P(b,i,\neg m,G,\neg j)$

$$\begin{aligned} &P(b,i,\neg m,g,\neg j) \\ &= P(b)P(\neg m)P(i|b,\neg m)P(g|b,i,\neg m)P(\neg j|g) \\ &= 0.9 \times (1-0.1) \times 0.5 \times 0.8 \times (1-0.9) \\ &= 0.0324 \end{aligned}$$

$$\begin{aligned} &P(b,i,\neg m,\neg g,\neg j) \\ &= P(b)P(\neg m)P(i|b,\neg m)P(\neg g|b,i,\neg m)P(\neg j|\neg g) \\ &= 0.9 \times (1-0.1) \times 0.5 \times (1-0.8) \times (1-0) \\ &= 0.081 \end{aligned}$$

- 另一种写法

$$\begin{aligned} &P(b,i,\neg m,G,\neg j) \\ &= P(b)P(\neg m)P(i|b,\neg m)P(G|b,i,\neg m)P(\neg j|G) \\ &= 0.9 \times (1-0.1) \times 0.5 \times \langle 0.8, 0.2 \rangle \times \langle (1-0.9), (1-0) \rangle \\ &= \langle 0.0324, 0.081 \rangle \end{aligned}$$



不确定知识与推理

3.4.1 不确定性概述	3.4.2 不确定领域的知识表示	3.4.3 贝叶斯网络	3.4.4 基于贝叶斯网络的推理
随机性（狭义不确定性）	先验概率	贝叶斯网络概念	贝叶斯网络的精确推理
模糊性	条件概率	贝叶斯网络语法语义	枚举法
不完全性	基于联合概率分布的推理	贝叶斯网络的构建	
不一致性	贝叶斯规则		

感谢聆听

- 刘鸿福 副研究员
- 国防科技大学 智能科学学院

