

最优化问题与局部搜索

祝恩
计算机学院
国防科技大学



1. 最优化问题与局部搜索：

最陡爬山法、随机爬山法、首选爬山法、随机重启爬山法；
模拟退火算法；局部束搜索；遗传算法。

2. 连续空间中的局部搜索：

不用离散化就能处理的方法；离散化的方法

$\nabla f = 0$ ；梯度上升/下降；Newton-Raphson方法

约束优化问题

3. 连续空间的约束优化*

寻找优化状态


爬山法（最陡爬山法，随机爬山法，首选爬山法，随机重启爬山法）；
模拟退火法；局部束搜索；遗传算法；连续空间局部搜索

1 最优化问题与局部搜索



n-queens

- Put n queens on an $n \times n$ board with no two queens on the same row, column, or diagonal
- Move a queen to reduce **number of conflicts**



纯粹的最优化问题: 根据目标函数找到最佳状态



(1)爬山法

(最陡)爬山法

- “Like climbing Everest in thick fog with amnesia (健忘症)”
- (steepest) Hill-Climbing:

function HILL-CLIMBING(problem) **returns** a state that is a **local** maximum

current $\leftarrow$ problem.INITIAL-STATE



loop do

neighbor $\leftarrow$ a highest-valued successor state of current

if VALUE(neighbor) $\leq$ VALUE(current) **then return** current

current $\leftarrow$ neighbor

局部最优问题、山脊问题、高原问题



随机爬山法

- stochastic hill climbing
 - chooses a random from among the uphill moves
 - 比最陡爬山法收敛慢，但在某些状态空间里能找到更好的解。

随机行走：在所有后继中随机选择一个。

随机爬山：在所有好的后继中随机选择一个。

首选爬山法

- first-choice hill climbing
 - generating successors randomly until one is generated that is better than the current state
 - 在后继结点很多时是个好策略。

随机重启

- Random-restart hill climbing
 - "If at first you don't succeed, try, try again. “
 - 如果每次爬山法搜索成功的概率为 p , 那么需要重新开始搜索的期望次数为_____。



(2)模拟退火法

模拟退火

- Idea: escape local maxima by **allowing some "bad" moves** but **gradually decrease** their frequency

function SIMULATED-ANNEALING(problem, schedule) returns a solution state

inputs: *problem*, a problem
schedule, a mapping from time to “temperature”

current $\leftarrow$ *problem*.INITIAL

for $t=1$ **to** ∞ **do**

$T \leftarrow \text{schedule}(t)$

if $T=0$ **then return** *current*

next $\leftarrow$ a randomly selected successor of *current*

$\Delta E \leftarrow \text{next}.\text{VALUE} - \text{current}.\text{VALUE}$

if $\Delta E > 0$ **then** *current* $\leftarrow$ *next*

else *current* $\leftarrow$ *next* only with probability $e^{\Delta E/T}$

模拟退火的特性


- One can prove: If T decreases slowly enough, then simulated annealing search will find a global optimum with probability approaching 1
- Widely used in VLSI layout, airline scheduling, etc




(3)局部束搜索

局部束搜索

- Start with k randomly generated states
- At each iteration, all the successors of all k states are generated
- If any one is a goal state, stop; else select the k best successors from the complete list and repeat.



并行的K个随机重启



Start with k
randomly
generated
states


all the
successors
of all k
states are
generated

Until any
one in the
list is a
goal state.



(4)遗传算法

N-queens问题的遗传算法



The genetic algorithm, illustrated for digit strings representing 8-queens states. The initial population in (a) is ranked by the fitness function in (b), resulting in pairs for mating in (c). They produce offspring in (d), which are subject to mutation in (e).

- **Fitness function:** number of non-attacking pairs of queens (min = 0, max = $8 \times 7/2 = 28$)
- $24 / (24 + 23 + 20 + 11) = 31\%$

遗传算法的核心概念

- A state is represented as a **string** over a finite alphabet (often a string of 0s and 1s)
- Evaluation function (**fitness function**). Higher values for better states.
- Start with k randomly generated states (**population**)
- A successor state is generated by combining **two** parent states
- Produce next generation of states by **selection**(选择), **crossover**(杂交), and **mutation**(变异)

function GENETIC-ALGORITHM(population, FITNESS-FN) **returns** an individual

inputs: population, a set of individuals

FITNESS-FN, a function that measures the fitness of an individual

repeat

new population $\leftarrow$ empty set

for i = 1 **to** SIZE(population) **do**

x $\leftarrow$ RANDOM-SELECTION(population, FITNESS-FN)

y $\leftarrow$ RANDOM-SELECTION(population, FITNESS-FN)

child $\leftarrow$ REPRODUCE(x, y)

if (small random probability) **then** child $\leftarrow$ MUTATE(child)

add child to new population

population $\leftarrow$ new population

until some individual is fit enough, or enough time has elapsed

return the best individual in population, according to FITNESS-FN

function REPRODUCE(x, y) **returns** an individual

inputs: x, y, parent individuals

n $\leftarrow$ LENGTH(x); c $\leftarrow$ random number from 1 to n

return APPEND(SUBSTRING(x, 1, c), SUBSTRING(y, c + 1, n))

This is a **more popular version**, each mating of two parents produces **only one offspring, not two**.

最优化问题与局部搜索(2)

祝恩
计算机学院
国防科技大学



在连续空间里寻找优化解。
使用已有方法；设计新方法。

2 连续空间中的局部搜索



能处理连续空间的算法

□ 哪些能处理连续空间？

- 最陡爬山法
- 随机爬山法
- 首选爬山法
- 模拟退火
- 局部束搜索
- 遗传算法

□ 首选爬山法和模拟退火能够处理连续状态和动作空间。连续空间的分支因子是无限的，最陡爬山、随机爬山、局部束搜索要产生无限个后继，不可行。

□ 遗传算法对状态编码，假设 n 个01位，最多表示 2^n 个状态，无法表示连续空间的无限多个状态。

建机场的优化问题


- 假设建一个机场，使地图上所有城市（集合C）到该机场的**距离平方和最小**。
- 问题的状态空间通过机场的坐标 $\mathbf{m}$ 来定义， $\mathbf{m}$ 是二维坐标。
- 设 $\mathbf{x}_i$ 是城市 i 的二维坐标：

$$f(\mathbf{m}) = \sum_{i \in C} (\mathbf{x}_i - \mathbf{m})^2$$

将连续问题离散化

□ 离散化每个状态的邻居

- 沿着x和y的正或负方向移动一小步 δ
- 每个状态有4个邻居（后继）
- 使用前面描述的局部搜索算法求解



□ 不用离散化就能使用（随机生成长度为 δ 的向量）：

- 首选爬山法
- 模拟退火法

使用梯度:求解 $\nabla f = 0$

- 很多方法试图利用梯度来找最小值。

$$\nabla f(\mathbf{m})$$

- $f(\mathbf{m}) = \sum_{i \in C} (\mathbf{x}_i - \mathbf{m})^2$ 最小值点可以通过直接求解 $\nabla f = 0$ 的解获得

$$\frac{\partial f}{\partial \mathbf{m}} = -2 \sum_{i \in C} (\mathbf{x}_i - \mathbf{m}) = 0$$

- 解是所有城市的算术平均: $\mathbf{m} = \frac{1}{|C|} \sum_{i \in C} \mathbf{x}_i$

使用梯度：梯度下降/上升


- 很多情况下无法找到 $\nabla f = 0$ 的闭式解
- 这时，一种方法是使用**梯度下降/上升法**：给定梯度的局部表达式，我们可以通过下述公式更新当前状态来完成最陡上升爬山

$$x \leftarrow x + \alpha \nabla f(x)$$

梯度上升法

$$x \leftarrow x - \alpha \nabla f(x)$$


梯度下降法



使用梯度：Newton-Raphson方法

□ 另一种方法是**牛顿法**

□ 求解方程 $g(x) = 0$ 的牛顿方法：
根据牛顿公式计算根 x 的一个新的估计值



$$x \leftarrow x - (g'(x))^{-1} g(x)$$

□ 考虑 $\nabla f(x) = 0$ 的解。牛顿公式中的 $g(x)$ 就变为 $\nabla f(x)$ ，更新过的等式可以写成矩阵向量形式

$$\mathbf{x} \leftarrow \mathbf{x} - (H_f(\mathbf{x}))^{-1} \nabla f(\mathbf{x})$$


□ $H_f(\mathbf{x})$ 是二阶导数的Hessian矩阵, $H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$

3 连续空间的约束优化



约束优化问题

- 约束优化：问题的解必须满足变量的某些严格约束，称此优化问题是受约束的。例如，在机场选址问题中，可以限定机场的位置在某个区域范围内。




- 约束最优化问题的难点取决于约束和目标函数的性质。

等式约束

□ 等式约束优化问题

$$\begin{aligned} \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t. } h_i(\mathbf{x}) = 0, i = 1, 2, \dots \end{aligned}$$



- 约束条件将解限制在一个可行区域 $D = \{\mathbf{x} | \forall i h_i(\mathbf{x}) = 0\}$ 。
构建拉格朗日函数，其中 α_i 为拉格朗日乘子。

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) + \sum_i \alpha_i h_i(\mathbf{x})$$

等式约束

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) + \sum_i \alpha_i h_i(\mathbf{x})$$

- 若只有单个约束等式 $h(\mathbf{x}) = 0$ ，在优化解 $\mathbf{x}^*$ 处， $h(\mathbf{x}) = 0$ 一定与 $f(\mathbf{x})$ 经过 $\mathbf{x}^*$ 的等值曲线相切，从而： $\nabla_{\mathbf{x}} f(\mathbf{x}^*)$ 与 $\nabla_{\mathbf{x}} h(\mathbf{x}^*)$ 平行，即

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = -\alpha \nabla_{\mathbf{x}} h(\mathbf{x}^*)$$

- $\mathbf{x}^*$ 还需要满足等式约束 $h(\mathbf{x}^*) = 0$


- 在多个约束等式的条件下，上面的关系式变为

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = - \sum_i \alpha_i \nabla_{\mathbf{x}} h_i(\mathbf{x}^*)$$

$$\text{即：} \nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\alpha}) = 0$$

- 同时 $\mathbf{x}^*$ 还满足所有的约束 $\forall i \ h_i(\mathbf{x}) = 0$ 。因此,优化解通过求解以下方程获得

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}) = 0 \\ \forall i \ h_i(\mathbf{x}) = 0, \text{即} \nabla_{\boldsymbol{\alpha}} L(\mathbf{x}, \boldsymbol{\alpha}) = \mathbf{0} \end{cases}$$





不等式约束

□ 不等式约束优化问题

$$\begin{aligned} \min_x & f(x) \\ \text{s.t. } & g_i(x) \leq 0, i = 1, 2, \dots \end{aligned}$$

□ 可行区域 $D = \{x | \forall i, g_i(x) \leq 0\}$ 。构建拉格朗日函数

$$L(x, \alpha) = f(x) + \sum_i \alpha_i g_i(x)$$





不等式约束

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) + \sum_i \alpha_i g_i(\mathbf{x})$$

□ 多个不等式约束情况下的优化问题的优化解满足

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}) = 0 \\ \forall i \ \alpha_i g_i(\mathbf{x}) = 0 \\ \forall i \ \alpha_i \geq 0 \\ \forall i \ g_i(\mathbf{x}) \leq 0 \end{cases}$$



混合约束

- 同时具有不等式和等式约束的优化问题

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s. t. } & \begin{cases} g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots \\ h_j(\mathbf{x}) = 0, j = 1, 2, \dots \end{cases} \end{aligned}$$

- 构建拉格朗日函数

$$L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{x}) + \sum_i \alpha_i g_i(\mathbf{x}) + \sum_j \beta_j h_j(\mathbf{x})$$

- 优化解满足：

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = 0 \\ \forall j \ h_j(\mathbf{x}) = 0 \\ \forall i \ \alpha_i g_i(\mathbf{x}) = 0 \\ \forall i \ \alpha_i \geq 0, \\ \forall i \ g_i(\mathbf{x}) \leq 0 \end{cases}$$

- 称为KKT条件。

混合约束

$$L(\boldsymbol{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\boldsymbol{x}) + \sum_i \alpha_i g_i(\boldsymbol{x}) + \sum_j \beta_j h_j(\boldsymbol{x})$$

- 不难证明,在 $\boldsymbol{x}$ 的值让所有等式约束和不等式约束都得到满足的前提下, 有

$$f(\boldsymbol{x}) = \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} L(\boldsymbol{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 如果 $\boldsymbol{x}$ 的值让任意的某个约束得不到满足, 则

$$\max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} L(\boldsymbol{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \infty$$

- 因此, 原约束优化问题等价于以下问题:

$$\min_{\boldsymbol{x}} \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} L(\boldsymbol{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 对偶问题是

$$\max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} \min_{\boldsymbol{x}} L(\boldsymbol{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

Thanks
LUGUK2