

贝叶斯网络

祝恩
计算机学院
国防科技大学



学习内容

1 贝叶斯网络

何谓贝叶斯网络；从网络计算概率；
如何构建贝叶斯网络；网络中的条件独立性

何谓贝叶斯网络；从网络计算概率；
如何构建贝叶斯网络；网络中的条件独立性

1 贝叶斯网络




贝叶斯网络用于什么？

- 贝叶斯网络用于表示变量之间的依赖关系。可以本质上表示任何完全联合概率分布，在许多情况下这种表示是简明扼要的。

防盗报警器问题

- I'm at work, neighbor John calls to say my alarm is ringing, but neighbor Mary doesn't call. Sometimes it's set off by minor earthquakes. Is there a burglar?
- 变量之间的依赖关系（因果关系）可表示成网络




贝叶斯网络

1. 每个**结点**对应一个随机变量，这个变量可以是离散的或者连续的。
 2. 一组**有向边**或箭头连接结点对。如果有从结点 X 指向结点 Y 的箭头，则称 X 是 Y 的一个父结点。图中没有有向回路（因此被称为有向无环图，或简称为DAG）。
 3. 每个结点 X 有一个**条件概率分布** $P(X_i | Parents(X_i))$ ，量化其父结点对该结点的影响。
- 由此可确定所有变量的完全联合概率分布

防盗报警器问题的贝叶斯网络

字母 B 、 E 、 A 、 J 、 M 分别表示
Burglary、*Earthquake*、*Alarm*
JohnCalls、*MaryCalls*
 每个变量右边是**条件概率表CPT**




从贝叶斯网络计算联合概率分布

$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$$

$$= P(j|m \wedge a \wedge \neg b \wedge \neg e) P(m|a \wedge \neg b \wedge \neg e) P(a|\neg b \wedge \neg e) P(\neg b|\neg e) P(\neg e)$$

$$= P(j | a) P(m | a) P(a | \neg b \wedge \neg e) P(\neg b) P(\neg e)$$

$$= 0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 = 0.00062$$




问题出在哪里？

$$P(a \wedge \neg b \wedge \neg e \wedge j \wedge m)$$

$$= P(a | \neg b \wedge \neg e \wedge j \wedge m) P(\neg b | \neg e \wedge j \wedge m) P(\neg e | j \wedge m) P(j | m) P(m)$$

$$= P(a | \neg b \wedge \neg e) P(\neg b) P(\neg e) P(j) P(m)$$

$$= 0.001 \times 0.999 \times 0.998 \times ? \times ?$$



$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$$

结点的排序

$$\square \quad P(x_1, \dots, x_n) = P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1} | x_{n-2}, \dots, x_1) \cdots P(x_2 | x_1) P(x_1)$$

$\square$ 或写为:

$$\square \quad P(x_n, \dots, x_1) = P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1} | x_{n-2}, \dots, x_1) \cdots P(x_2 | x_1) P(x_1)$$

$\square$ 若 $Parents(X_i) \subseteq \{X_{i-1}, \dots, X_1\}$, 即
 序列 $X_1, \dots, X_n$ 中 X_i 的父节点都排在它的前面,
 序列 $X_n, \dots, X_1$ 中 X_i 的父节点都排在它的后面,
 则 $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | Parents(X_i))$
 【贝叶斯网络的条件独立性】

$\square$ 从而

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | parents(X_i))$$

通用公式

- 联合概率分布中的每个条目都可表示为贝叶斯网络的条件概率表（CPT）中适当元素的乘积

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- 其中 $\text{parents}(X_i)$ 表示 $\text{Parents}(X_i)$ 的变量的出现在 $x_1, \dots, x_n$ 中的取值。

构建贝叶斯网络


1. 结点：首先确定变量集合。对变量进行排序得到 $\{X_1, \dots, X_n\}$ ，原因排列在结果之前。
2. 边： i 从1到 n ，执行：
 - 从 $X_1, \dots, X_{i-1}$ 中选择 X_i 的父结点的最小集合，使得 $Parents(X_i) \subseteq \{X_{i-1}, \dots, X_1\}$ 满足。
 - 在每个父结点与 X_i 之间插入一条边。
3. 条件概率表（CPTs）：写出条件概率表 $P(X_i | Parents(X_i))$ 。

贝叶斯网络的紧致性

- 假设 n 个布尔变量，联合概率分布中将包含 2^n 个数值。若 $n=30$ ，将有超过10亿个值。
- 假设每个随机变量受到至多 k 个其他随机变量的影响，其中 k 是某个常数。整个网络可以用至多 $n2^k$ 个数值描述。若 $n=30$ ， $k=5$ ，则只有960个值。


微弱的依赖关系

- 地震发生的时候，John和Mary即使听到了警报声也不会打电话，因为他们认为警报声是地震引起的而不是盗贼闯入引起的。是否需要增加从 *Earthquake* 到 *JohnCalls* 以及 *MaryCalls* 的边？（优点和缺点）




结点顺序不当会如何？

- 若“结果”作为“原因”的父节点



- 就像因果模型与诊断模型的区别，诊断概率 $P(E|A,B)$ 很脆弱
- 坚持因果模型，只需要更少的概率值，这些值更容易获得

条件独立性



$$P(x_n, \dots, x_1) = P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1} | x_{n-2}, \dots, x_1) \dots P(x_2 | x_1) P(x_1)$$

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$


□ 构造贝叶斯网络的方法，将我们带到结论：

- 给定父结点，一个结点条件独立于它的其他祖先结点。
 $\mathbf{P}(X | U_1, \dots, U_m, \text{Parents}(U_1), \dots, \text{Parents}(U_m)) = \mathbf{P}(X | U_1, \dots, U_m)$
- 给定父结点，一个结点条件独立于它的非后代结点
 $\mathbf{P}(X | U_1, \dots, U_m, \text{Parents}(Y_1), \dots, \text{Parents}(Y_n)) = \mathbf{P}(X | U_1, \dots, U_m)$

条件独立性

□ 进一步可得出：

- 给定一个结点的父结点、子结点、以及子结点的父结点——即给定它的马尔科夫覆盖 (Markov blanket) ——这个结点条件独立于网络中的**所有其他结点**。(ex14.7)



$$\begin{aligned} P(X | \text{Parents}(X), Y_1, \dots, Y_n, \text{Parents}(Y_1), \dots, \text{Parents}(Y_n), \text{Others}) \\ = P(X | \text{Parents}(X), Y_1, \dots, Y_n, \text{Parents}(Y_1), \dots, \text{Parents}(Y_n)) \end{aligned}$$

□ 贝叶斯网络表示变量之间的依赖关系

□ 联合概率可以通过条件概率表计算

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

□ 贝叶斯网络的条件独立性

- 给定父结点，一个结点条件独立于它的其他祖先结点
- 给定父结点，一个结点条件独立于它的非后代结点
- 给定一个结点的父结点、子结点、以及子结点的父结点——即给定它的马尔科夫覆盖（Markov blanket）——这个结点条件独立于网络中的所有其他结点

Thanks

贝叶斯网络的推理

祝恩
计算机学院
国防科技大学



学习内容

1 贝叶斯网络的精确推理

求和消元/枚举；消元次序；重复子表达式；无关变量

2 贝叶斯网络的近似推理

直接采样；拒绝采样；加权；马尔科夫链采样

推理任务是什么？

求和消元/枚举；消元次序；重复子表达式；无关的求和变量

1 贝叶斯网络的精确推理



概率推理任务

□ X 表示查询变量； E 表示证据变量集

$E_1, E_2, \dots, E_m$, e 表示一个观察到的特定事件；

Y 表示非证据非查询变量集 $Y_1, Y_2, \dots, Y_l$ （隐藏变量/未观测变量）。全部变量是 $X = \{X\} \cup E \cup Y$, 典型的查询是询问 $P(X | e)$ 。


通过求和消元进行推理

- 任何条件概率都可以通过将完全联合概率分布中的某些项相加而计算得到


$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

- $P(x, e, y)$ 可以写成网络中的条件概率的乘积形式

- 考虑查询
 $P(B | j, m)$



通过求和消元进行推理



$$\begin{aligned}
 P(B|j, m) &= \alpha P(B, j, m) = \alpha \sum_{e, a} P(B, j, m, e, a) \\
 &= \alpha \sum_e \sum_a P(B) P(e) P(a|B, e) P(j|a) P(m|a) \\
 &= \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) P(j|a) P(m|a)
 \end{aligned}$$

先消元A再消元E

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a) = \alpha \times 0.00059224$$

$$P(\neg b|j, m) = \alpha P(\neg b) \sum_e P(e) \sum_a P(a|\neg b, e) P(j|a) P(m|a) = \alpha \times 0.0014919$$

$$P(B|j, m) = \langle P(b|j, m), P(\neg b|j, m) \rangle = \langle 0.2842, 0.7158 \rangle$$

通过求和消元进行推理

先消元A再消元E

$$\begin{aligned}
 P(B|j, m) &= \alpha P(B, j, m) = \alpha \sum_{e, a} P(B, j, m, e, a) \\
 &= \alpha \sum_e \sum_a P(B) P(e) P(a|B, e) P(j|a) P(m|a) \\
 &= \alpha P(B) \sum_e P(e) \sum_a P(a|B, e) P(j|a) P(m|a)
 \end{aligned}$$

$$\begin{aligned}
 P(b|j, m) &= \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a) = \alpha \times 0.00059224 \\
 P(\neg b|j, m) &= \alpha P(\neg b) \sum_e P(e) \sum_a P(a|\neg b, e) P(j|a) P(m|a) = \alpha \times 0.0014919 \\
 P(B|j, m) &= \langle P(b|j, m), P(\neg b|j, m) \rangle = \langle 0.2842, 0.7158 \rangle
 \end{aligned}$$

先消元E再消元A

$$\begin{aligned}
 P(B|j, m) &= \alpha P(B, j, m) = \alpha \sum_{e, a} P(B, j, m, e, a) \\
 &= \alpha \sum_a \sum_e P(B) P(e) P(a|B, e) P(j|a) P(m|a) \\
 &= \alpha P(B) \sum_a P(j|a) P(m|a) \sum_e P(e) P(a|b, e)
 \end{aligned}$$



不同消元次序影响了什么?

$$\begin{aligned}
 P(b|j, m) &= \alpha P(b) \sum_a P(j|a) P(m|a) \sum_e P(e) P(a|b, e) \\
 P(\neg b|j, m) &= \alpha P(\neg b) \sum_a P(j|a) P(m|a) \sum_e P(e) P(a|\neg b, e)
 \end{aligned}$$




(1)求和消元顺序

乘法次数

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

先消元A再消元E

乘法次数？


计算 $P(b|j, m)$ 共_次乘法计算 $P(B|j, m)$ 共_次乘法

乘法次数

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

先消元A再消元E

乘法次数？

计算 $P(b|j, m)$ 共_次乘法计算 $P(B|j, m)$ 共_次乘法

求和消元

$$P(B|j, m) = \alpha \underbrace{P(B)}_{f_1(B)} \underbrace{\sum_e \frac{P(e)}{f_2(E)} \sum_a \underbrace{\frac{P(a|B, e) P(j|a) P(m|a)}{f_3(A, B, E) f_4(A) f_5(A)}}_{f_6(B, E)}}_{f_7(B)}$$

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

“ $\times$ ” 不是矩阵乘，而是逐点相乘

Review:

$P(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather}) =$
 $P(\text{Toothache}, \text{Catch}, \text{Cavity}) \times P(\text{Weather})$

求和消元

$$P(B|j, m) = \alpha \underbrace{P(B)}_{f_1(B)} \underbrace{\sum_e \underbrace{P(e)}_{f_2(E)} \underbrace{\sum_a \underbrace{P(a|B, e)}_{f_3(A, B, E)} \underbrace{P(j|a)}_{f_4(A)} \underbrace{P(m|a)}_{f_5(A)}}_{f_6(B, E)}}_{f_7(B)}$$

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

$f_6(B, E)$

$$= \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

$f_6(B, E)$ 共4个值，每个值需要4次乘法：共16次

$$= (f_3(a, B, E) \times f_4(a) \times f_5(a)) + (f_3(\neg a, B, E) \times f_4(\neg a) \times f_5(\neg a))$$

$f_7(B)$

$$= \sum_e f_2(E) \times f_6(B, E)$$

$f_7(B)$ 共2个值，每个值需要2次乘法：共4次

$$= (f_2(e) \times f_6(B, e)) + (f_2(\neg e) \times f_6(B, \neg e))$$

$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$

$P(B|j, m)$ 共2个值，每个值需要1次乘法：共2次

合计 16+4+2=22

不同消元顺序

□ 如果先消A再消E:

$$\begin{aligned}
 & P(B|j, m) \\
 &= \alpha \sum_e \sum_a \mathbf{P}(B) P(e) \mathbf{P}(a|B, e) P(j|a) P(m|a) \\
 &= \alpha \underbrace{\underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \underbrace{\sum_e \mathbf{P}(e)}_{\mathbf{f}_2(E)} \underbrace{\sum_a \mathbf{P}(a|B, e) P(j|a) P(m|a)}_{\mathbf{f}_6(B, E)}}_{\mathbf{f}_7(B)} \\
 &= \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \underbrace{\sum_a \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)}_{\mathbf{f}_6(B, E)} \\
 &\quad \underbrace{\hspace{10em}}_{\mathbf{f}_7(B)}
 \end{aligned}$$

$\mathbf{f}_6$ 共4个值，每个值4次乘法；
 $\mathbf{f}_7$ 共2个值，每个值2次乘法；
 $P(B|j, m)$ 共2个值，每个值1次乘法。
 合计： $4 \times 4 + 2 \times 2 + 2 \times 1 = 22$

不同消元顺序


□ 如果先消E再消A:

$$\begin{aligned}
 & P(B|j, m) \\
 &= \alpha \sum_a \sum_e \mathbf{P}(B) P(e) \mathbf{P}(a|B, e) P(j|a) P(m|a) \\
 &= \alpha \underbrace{\underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \underbrace{\sum_a \underbrace{P(j|a)}_{\mathbf{f}_4(A)} \underbrace{P(m|a)}_{\mathbf{f}_5(A)}}_{\mathbf{f}_7(B)} \underbrace{\sum_e \underbrace{P(e)}_{\mathbf{f}_2(E)} \underbrace{P(a|b, e)}_{\mathbf{f}_3(A, B, E)}}_{\mathbf{f}_6(A, B)}}_{\mathbf{f}_7(B)} \\
 &= \alpha \mathbf{f}_1(B) \times \underbrace{\sum_a \mathbf{f}_4(A) \times \mathbf{f}_5(A)}_{\mathbf{f}_7(B)} \times \underbrace{\sum_e \mathbf{f}_2(E) \times \mathbf{f}_3(A, B, E)}_{\mathbf{f}_6(A, B)}
 \end{aligned}$$

不同消元顺序决定了不同的时间和空间要求。

$\mathbf{f}_6$ 共4个值，每个值2次乘法；
 $\mathbf{f}_7$ 共2个值，每个值4次乘法；
 $P(B|j, m)$ 共2个值，每个值1次乘法。
 合计： $4 \times 2 + 2 \times 4 + 2 \times 1 = 18$

不同消元顺序



- 获得**最优消元顺序**是一个**NP难**的问题。
- 获得好的消元顺序的**贪心法**：消去的变量能最小化下一个将被构造出的因子的规模**(从具有最小邻接点的结点开始)**---参见“概率图模型”中的“变量消元方法”。

如果先消A再消E:

$$\begin{aligned}
 &P(B|j, m) \\
 &= \alpha \sum_e \sum_a P(B)P(e)P(a|B, e)P(j|a)P(m|a) \\
 &= \alpha \underbrace{P(B)}_{f_1(B)} \underbrace{\sum_e P(e)}_{f_2(E)} \underbrace{\sum_a P(a|B, e) P(j|a) P(m|a)}_{f_7(B)} \\
 &\quad \underbrace{\quad \quad \quad f_6(B, E)}_{f_7(B)} \\
 &= \alpha f_1(B) \times \sum_e f_2(E) \times \underbrace{\sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)}_{f_7(B)} \\
 &\quad \underbrace{\quad \quad \quad f_6(B, E)}_{f_7(B)}
 \end{aligned}$$

f_6 共4个值，每个值4次乘法；
 f_7 共2个值，每个值2次乘法；
 $P(B|j, m)$ 共2个值，每个值1次乘法。
 合计： $4 \times 4 + 2 \times 2 + 2 \times 1 = 22$

如果先消E再消A:

$$\begin{aligned}
 &P(B|j, m) \\
 &= \alpha \sum_a \sum_e P(B)P(e)P(a|B, e)P(j|a)P(m|a) \\
 &= \alpha \underbrace{P(B)}_{f_1(B)} \underbrace{\sum_a P(j|a) P(m|a)}_{f_7(B)} \underbrace{\sum_e P(e) P(a|B, e)}_{f_6(A, B)} \\
 &\quad \underbrace{\quad \quad \quad f_4(A) \quad f_5(A)}_{f_7(B)} \\
 &= \alpha f_1(B) \times \sum_a \underbrace{f_4(A) \times f_5(A)}_{f_7(B)} \times \underbrace{\sum_e f_2(E) \times f_3(A, B, E)}_{f_6(A, B)} \\
 &\quad \underbrace{\quad \quad \quad f_6(A, B)}_{f_7(B)}
 \end{aligned}$$

f_6 共4个值，每个值2次乘法；
 f_7 共2个值，每个值4次乘法；
 $P(B|j, m)$ 共2个值，每个值1次乘法。
 合计： $4 \times 2 + 2 \times 4 + 2 \times 1 = 18$



$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$



(2)重复子表达式

存在重复子表达式

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$



重复子表达式

存在重复子表达式

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

计算 $P(b|j, m)$ 共11次乘法

计算 $P(\neg b|j, m)$ 共11次乘法


计算 $P(B|j, m)$ 共22次乘法

消除重复后:

计算 $P(b|j, m)$ 共_次乘法

计算 $P(\neg b|j, m)$ 共_次乘法

计算 $P(B|j, m)$ 共_次乘法




重复子表达式

存在重复子表达式

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

计算 $P(b|j, m)$ 共11次乘法
 计算 $P(\neg b|j, m)$ 共11次乘法
 计算 $P(B|j, m)$ 共22次乘法
 消除重复后:

计算 $P(b|j, m)$ 共_次乘法
 计算 $P(\neg b|j, m)$ 共_次乘法
 计算 $P(B|j, m)$ 共_次乘法



存在重复子表达式

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$

计算 $P(b|j, m)$ 共11次乘法

计算 $P(\neg b|j, m)$ 共11次乘法


计算 $P(B|j, m)$ 共22次乘法

消除重复后:

计算 $P(b|j, m)$ 共_次乘法

计算 $P(\neg b|j, m)$ 共_次乘法

计算 $P(B|j, m)$ 共_次乘法



消除重复子表达式

$$P(B|j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times \underbrace{f_4(A) \times f_5(A)}_{f_8(A)}$$

重复子表达式

$$f_8(A) = f_4(A) \times f_5(A)$$

$f_8(A)$ 共2个值，每个值需要1次乘法：共2次

$$f_6(B, E)$$

$$= \sum_a f_3(A, B, E) \times f_8(A)$$

$f_6(B, E)$ 共4个值，每个值需要2次乘法：共8次

$$= (f_3(a, B, E) \times f_8(a)) + (f_3(\neg a, B, E) \times f_8(\neg a))$$

$$f_7(B)$$

$f_7(B)$ 共2个值，每个值需要2次乘法：共4次

$$= \sum_e f_2(E) \times f_6(B, E)$$

$$= (f_2(e) \times f_6(B, e)) + (f_2(\neg e) \times f_6(B, \neg e))$$

$$P(B|j, m) = \alpha f_1(B) \times f_7(B)$$


$P(B|j, m)$ 共2个值，每个值需要1次乘法：共2次

合计16次乘法



(3)无关的求和变量

无关的求和变量



既非查询变量的祖先亦非证据变量的祖先的变量都和查询无关。

- 查询: $P(J|b)$
- $P(J|b) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(J|a) \sum_m P(m|a)$
- $\sum_m P(m|a) = 1$, M和这个查询无关。即使把结点 *MaryCalls* 从网络中删除, 查询 $P(J|b)$ 的结果也不会发生变化。



既非查询变量的祖先亦非证据变量的祖先的变量都和查询无关，无关的求和变量可直接删除，使得推理是在贝叶斯网络的子网络里进行

学习内容

1 贝叶斯网络的精确推理

求和消元/枚举；消元次序；重复子表达式；无关变量

2 贝叶斯网络的近似推理

直接采样；拒绝采样；加权；马尔科夫链采样

随机采样算法（蒙特卡洛算法）：

直接采样，拒绝采样，似然加权，Gibbs采样

2 贝叶斯网络的近似推理



蒙特卡洛算法

- 大规模多连通网络中的精确推理是不实际的。随机采样算法（也称为蒙特卡洛算法），能够给出一个问题的近似解，精度度依赖于所生成的采样点的多少。
- 讨论两个算法家族：
 1. 直接采样
 2. 马尔科夫链采样




如何通过采样计算概率 $P(X)$?



直接采样

直接采样

- 按照拓扑顺序[*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]依次对每个变量进行采样。变量值被采样的概率分布依赖于父结点已得到的赋值。
- 1. 从 $P(\textit{Cloudy}) = \langle 0.5, 0.5 \rangle$ 中采样*Cloudy*, 假设返回*true*。
- 2. 从 $P(\textit{Sprinkler} \mid \textit{Cloudy} = \textit{true}) = \langle 0.1, 0.9 \rangle$ 中采样*Sprinkler*, 假设返回*false*。
- 3. 从 $P(\textit{Rain} \mid \textit{Cloudy} = \textit{true}) = \langle 0.8, 0.2 \rangle$ 中采样*Rain*, 假设返回*true*。
- 4. 从 $P(\textit{WetGrass} \mid \textit{Sprinkler} = \textit{false}, \textit{Rain} = \textit{true}) = \langle 0.9, 0.1 \rangle$ 中采样*WetGrass*, 假设返回*true*。
- 这样, PRIOR-SAMPLE返回事件
[*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]
=[*true*, *false*, *true*, *true*]。



直接采样

- 统计 $X = x$ 的出现的频次而计算出估计概率
 $\alpha\langle X = x \text{的频次}, X = x' \text{的频次}, \dots \rangle$

- 假设总共有 N 个样本，令 $N_{PS}(x_1, \dots, x_n)$ 为特定事件 $x_1, \dots, x_n$ 在样本集中出现的次数。

$$P(x_1, \dots, x_n) \approx \frac{N_{PS}(x_1, \dots, x_n)}{N}$$

- $N_{PS}(x_1, \dots, x_n)$ 和总样本数 N 的比在大样本极限下收敛到期望值

$$\lim_{N \rightarrow \infty} \frac{N_{PS}(x_1, \dots, x_n)}{N} = P(x_1, \dots, x_n)$$

直接采样算法

function PRIOR-SAMPLE(bn) **returns** an event sampled from the prior specified by bn
inputs: bn, a Bayesian network specifying joint distribution $\mathbf{P}(X_1, \dots, X_n)$

$\mathbf{x} \leftarrow$ an event with n elements
foreach variable X_i **in** $X_1, \dots, X_n$ **do**
 $\mathbf{x}[i] \leftarrow$ a random sample from $\mathbf{P}(X_i \mid \text{parents}(X_i))$
return $\mathbf{x}$



如何通过采样计算条件概率 $P(X | e)$?



拒绝采样

拒绝采样

- 计算条件概率 $P(X|e) = \frac{P(X,e)}{P(e)} = \alpha P(X,e)$
- 首先，根据网络指定的先验分布生成采样样本。然后，它拒绝所有与证据不匹配的样本。最后，在剩余样本中通过统计 $X = x$ 的出现的频次而计算出估计概率 $\alpha \langle X = x \text{ 的频次}, X = x' \text{ 的频次}, \dots \rangle$
- 可能是低效的。如何避免这种低效率？

```

function REJECTION-SAMPLING( $X, e, bn, N$ ) returns an estimate of  $P(X|e)$ 
  inputs:  $X$ , the query variable
             $e$ , observed values for variables  $E$ 
             $bn$ , a Bayesian network
             $N$ , the total number of samples to be generated
  local variables:  $N$ , a vector of counts for each value of  $X$ , initially zero

  for  $j = 1$  to  $N$  do
     $x \leftarrow$  PRIOR-SAMPLE( $bn$ ) //直接采样
    if  $x$  is consistent with  $e$  then
       $N[x] \leftarrow N[x] + 1$  where  $x$  is the value of  $X$  in  $x$ 
  return NORMALIZE( $N$ ) //归一化
  
```



似然加权

似然加权

- 似然加权 (likelihood weighting) 只生成与证据 e 一致的事件，从而避免拒绝采样算法的低效率。
- 固定证据变量 E 的值，然后只对非证据变量采样。这保证了生成的每个事件都与证据一致。
- 在对查询变量的分布进行计数之前，每个事件以它与证据吻合的似然（相似性）为权值。

似然加权


- 求解查询 $P(Rain | Cloudy = true, WetGrass = true)$, 假设变量的拓扑顺序是 $Cloudy$ 、 $Sprinkler$ 、 $Rain$ 、 $WetGrass$ 。过程是这样的：首先，将权值 w 设为1.0。然后生成一个事件：

证据变量形成权值，其他变量采样具体的值

1. $Cloudy$ 是一个证据变量，其值为 $true$ 。因此我们设置

$$w \leftarrow w \times P(Cloudy = true) = 0.5$$

2. $Sprinkler$ 不是一个证据变量，因此从 $P(Sprinkler | Cloudy = true) = \langle 0.1, 0.9 \rangle$ 中采样；假设返回 $false$ 。




似然加权

3. 类似地, 从 $\mathbf{P}(\text{Rain} \mid \text{Cloudy} = \text{true}) = \langle 0.8, 0.2 \rangle$ 中采样; 假设返回 *true*。

4. *WetGrass* 是一个证据变量, 其值为 *true*。因此我们设置

$$w \leftarrow w \times P(\text{WetGrass} = \text{true} \mid \text{Sprinkler} = \text{false}, \text{Rain} = \text{true}) = 0.5 \times 0.9 = 0.45。$$



这里WEIGHTED-SAMPLE返回权值为0.45的样本 [*Cloudy* = *true*, *Sprinkler* = *false*, *Rain* = *true*, *WetGrass* = *true*], 权值0.45将被计入 *Rain* = *true* 中去。最后归一化:

$\alpha \langle \text{Rain} = \text{true} \text{ 的权值之和}, \text{Rain} = \text{false} \text{ 的权值之和} \rangle$




马尔科夫链蒙特卡洛算法MCMC

马尔科夫链采样

- 马尔科夫链蒙特卡洛(MCMC)算法：
在特定的当前状态，每个变量的取值都已确定，
然后随机修改当前状态，从而生成下一个状态
- **Gibbs**采样是一种特殊形式的MCMC算法，它特别适合贝叶斯网络。


Gibbs采样算法

- 贝叶斯网络的Gibbs采样算法：
从任意的状态出发，通过(给定马尔科夫覆盖)对一个非证据变量 X_i 随机采样而生成下一个状态。
- 对 X_i 的采样条件依赖于 X_i 的马尔科夫覆盖中的变量的当前值。
 $P(X_i | mb(X_i))$
- 例如，查询 $P(Rain | Sprinkler = true, WetGrass = true)$ 。



Gibbs采样算法


- 例如，查询 $P(Rain \mid Sprinkler = true, WetGrass = true)$ 。
- 首先初始化：证据变量 $Sprinkler$ 和 $WetGrass$ 固定为它们的观察值，非证据变量 $Cloudy$ 和 $Rain$ 随机地初始化——比如 $true$ 和 $false$ 。因此，初始状态为
 $[Cloudy = true, Sprinkler = true, Rain = false, WetGrass = true]$ 。



Gibbs采样算法

□ 然后以任意顺序对非证据变量采样（循环执行）


1. 对 *Cloudy* 采样，给定它的马尔科夫覆盖变量的当前值：从 $P(\text{Cloudy} \mid \text{Sprinkler} = \text{true}, \text{Rain} = \text{false})$ 中采样。（待证明“为什么Gibbs采样可行”）假设采样结果为 *Cloudy* = *false*。那么新的当前状态是 [Cloudy=*false*, Sprinkler=*true*, Rain=*false*, WetGrass=*true*]。



Gibbs采样算法

2. 对 *Rain* 采样，给定它的马尔科夫覆盖变量的当前值：从 $\mathbf{P}(\text{Rain} \mid \text{Cloudy} = \text{false}, \text{Sprinkler} = \text{true}, \text{WetGrass} = \text{true})$ 中采样。假设采样结果为 *Rain* = *true*。新的当前状态是 [*Cloudy* = *false*, *Sprinkler* = *true*, *Rain* = *true*, *WetGrass* = *true*]。

□ 如果该过程访问了20个 *Rain* 为真的状态和60个 *Rain* 为假的状态，则所求查询的解为 $\text{NORMALIZE}(\langle 20, 60 \rangle) = \langle 0.25, 0.75 \rangle$




Gibbs采样算法

□ 证明结论:

$$P(x'_i | mb(X_i)) = \alpha P(x'_i | parents(X_i)) \times \prod_{Y_j \in Children(X_i)} P(y_j | parents(Y_j))$$

$$P(X_i | MB(X_i)) = \alpha P(X_i | Parents(X_i)) \times \prod_{Y_j \in Children(X_i)} P(Y_j | Parents(Y_j))$$

□ $mb(X_i)$ 表示 X_i 的马尔科夫覆盖 $MB(X_i)$ 中各变量的取值




Gibbs采样算法

□ 证明:

Y=Children(X_i)
y=children(X_i)
Parents(Y_i)={X_i,Z_i}
parents(Y_i)={x_i,z_i}

$$\begin{aligned} P(x_i | mb(X_i)) \\ &= \alpha P(x_i | parents(X_i)) \prod_i P(y_i | x_i, \mathbf{z}_i) \\ &= \alpha P(x_i | parents(X_i)) \prod_i P(y_i | parents(Y_i)) \end{aligned}$$

$$\begin{aligned} \mathbf{P}(X_i | mb(X_i)) \\ &= \mathbf{P}(X_i | parents(X_i), \mathbf{y}, \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha \mathbf{P}(X_i, parents(X_i), \mathbf{y}, \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha \mathbf{P}(\mathbf{y} | X_i, parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \mathbf{P}(X_i | parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &\quad \mathbf{P}(parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha' \mathbf{P}(\mathbf{y} | X_i, parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \mathbf{P}(X_i | parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha' \mathbf{P}(X_i | parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \mathbf{P}(\mathbf{y} | X_i, parents(X_i), \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha' \mathbf{P}(X_i | parents(X_i)) \mathbf{P}(\mathbf{y} | X_i, \mathbf{z}_1, \dots, \mathbf{z}_l) \\ &= \alpha' \mathbf{P}(X_i | parents(X_i)) \prod_j \mathbf{P}(y_j | X_i, \mathbf{z}_j) \end{aligned}$$



Thanks