

国防科技大学

《机器学习》试题

一. 感知机算法 (20') 感知机算法的更新规则为

$$\text{IF } \text{sign}(\mathbf{w}_t^\top \mathbf{x}_i) \neq y_i, \quad \text{THEN } \mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + y_i \mathbf{x}_i. \quad (1)$$

① (5'). $\mathbf{w}_{t+1}$ 是否一定能将 $\mathbf{x}_i$ 分对? 如果不可以, 请设计新的更新准则以确保 $\mathbf{x}_i$ 能被 $\mathbf{w}_{t+1}$ 分对.

② (10'). 假设样本集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 线性可分且被中心化, $\mathbf{w}_f$ 为存在但未知的理想线性分类器的法向量. 定义 $R^2 = \max_i \|\mathbf{x}_i\|^2$ 及 $\rho = \min_i \frac{y_i \mathbf{w}_f^\top \mathbf{x}_i}{\|\mathbf{w}_f\|}$. 试推导感知机算法达到收敛条件所需要的迭代次数的上界.

③ (5'). 如何改进线性感知机算法使得它能够处理非线性可分的数据.

二. 支持向量机及泛化误差界 (25') ① (10'). 给出支持向量机的原始优化目标并推导其对偶形式.

② (5'). 设计随机梯度下降算法以高效地求解大规模支持向量机对偶问题.

③ (10'). 对假设空间 $\mathcal{H}: \mathcal{X} \mapsto \{-1, +1\}$, 依据分布 $\mathcal{D}$ 从 $\mathcal{X}$ 中独立同分布采样得到训练集合 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, $\mathbf{x}_i \in \mathcal{X}$, $0 \leq \delta \leq 1$, 对任意 $h \in \mathcal{H}$,

$$\mathbb{E}[h] \leq \hat{\mathbb{E}}[h] + \mathcal{R}_n(\mathcal{H}) + \sqrt{\frac{\ln(1/\delta)}{2n}} \quad (2)$$

成立的概率至少为 $1 - \delta$, 其中 $\mathcal{R}_n(\mathcal{H})$ 为假设空间 $\mathcal{H}$ 关于 D 的经验 Rademacher 复杂度.

三. 随机梯度下降算法的收敛速率 (15') 令 $B, \rho > 0$. 假设 $f(\cdot)$ 为凸函数, 且 $\mathbf{w}^* \in \arg \min_{\mathbf{w}: \|\mathbf{w}\| \leq B} f(\mathbf{w})$. 假设随机梯度下降算法迭代执行 T 次, 其中学习速率 $\eta = \sqrt{\frac{B^2}{T\rho^2}}$. 对于所有的 t , $\|\mathbf{v}_t\| \leq \rho$ 均成立, 其中 $\mathbf{v}_t$ 为第 t 次迭代的随机下降方向. 试证明:

$$\mathbb{E}[f(\hat{\mathbf{w}})] - f(\mathbf{w}^*) \leq \frac{B\rho}{\sqrt{T}}, \quad (3)$$

其中 $\hat{\mathbf{w}} = \frac{1}{T} \sum_{t=1}^T \mathbf{w}_t$.

四. k -means 聚类的梯度下降 (15') 回顾 k -means 聚类的损失函数, 其有着 k 个簇, 样本点 $\mathbf{x}_1, \dots, \mathbf{x}_n$, 以及中心点 $\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k$:

$$L = \frac{1}{2} \sum_{j=1}^k \sum_{\mathbf{x}_i \in \mathcal{S}_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2, \quad (4)$$

其中, S_j 指的是相比较于其他簇的均值, 更接近 μ_j 的样本点的集合。

① (5'). 不采取通过计算均值的方法来更新 μ_j , 我们在保持集合 S_j 固定时用批量梯度下降法来最小化损失函数 L 。试推导出学习率 (步长) 为 ε 时 μ_1 的更新公式

② (5'). 推导出在单一样本点 x_i 使用随机梯度下降时 μ_1 的更新公式, 学习率设置为 ε 。

③ (5'). 在这一部分, 我们将把批量梯度下降更新公式与标准的 k -means 算法联系起来。回顾一下, 在标准 k -means 算法的更新步骤中, 我们将每个簇中心分配为最接近该中心的数据点的平均值 (中心点)。事实证明, 对学习率 ε 的特定选择 (对每个簇可能不同) 使得两种算法 (批量梯度下降和标准 k -means 算法) 具有相同的更新步骤。让我们关注第一个簇的更新, 其中心点为 μ_1 。计算 ε 的值, 使得两种算法对 μ_1 进行相同的更新。

五. 自动驾驶汽车和反向传播 (25') 你想要训练一个神经网络来驾驶一辆汽车。你的训练数据包含 64×64 像素的灰度图。训练标签包含人类驾驶员方向盘角度 (度) 和人类驾驶运动员的速度 (英里/小时)。你的神经网络包含一个 $64 \times 64 = 4,096$ 单元的输入层, 一个 2,048 单元的隐藏层, 以及一个 2 个单元的输出层 (一个是转向角, 一个是速度)。对隐藏单元使用 ReLU 激活函数, 输入或输出没有激活函数。

① (5'). 计算这个网络中的参数 (权重) 的数量。

② (10'). 使用损失函数 $J = \frac{1}{2} \|z - y\|^2$ 训练网络。使用以下符号。

a) x 是一个输入的训练图像向量, 在最后附加了一个分量 “1”, y 是输入的训练标签向量, z 是输出向量。

b) $r(\gamma) = \max\{0, \gamma\}$ 是 ReLU 激活函数, $r'(\gamma)$ 是其导数 ($\gamma > 0$ 时为 1, 否则为 0), $r(v)$ 是 $r(\cdot)$ 按分量应用到一个向量上。

c) g 是应用 ReLU 激活函数之前的隐藏单元值的向量, $h = r(g)$ 是应用后的隐藏单元值的向量 (但是我们在 h 的末尾添加了一个分量 “1”)。

d) V 是将输入层映射到隐藏层的权重矩阵, $g = Vx$ 。

e) W 是将隐藏层映射到输出层的权重矩阵, $z = Wh$ 。

求 $\partial J / \partial W_{ij}$ 。

③ (5'). 求 $\partial J / \partial W$ 。

④ (5'). 求 $\partial J / \partial V_{ij}$ 。