



统计学习理论简介

I. 可学习性

参考教材



前言

机器学习理论研究的是关于机器学习的理论基础，主要内容是分析学习任务的困难本质，为学习算法提供理论保证，并根据分析结果指导算法设计。

对一个任务，通常我们先要考虑它是不是“可学习的(learnable)”

本章就是介绍关于可学习性的基本知识：

PAC(概率近似正确)，可学习性，不可知PAC可学习性，概念类，假设空间。

数据与分布

给定样例集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ 其中 $\mathbf{x}_i \in \mathcal{X}$
若无特别说明, $y_i \in \mathcal{Y} = \{-1, +1\}$, 即本章主要讨论二分类问题.

基本假设:

$\mathcal{X}$ 中的所有样本服从一个隐含未知的分布 $\mathcal{D}$, D 中的所有样本都是独立地从 $\mathcal{D}$ 上采样得到, 记作 $D \sim \mathcal{D}^m$ 即独立同分布(independent and identically distributed 简称 *i.i.d.*)样本.

泛化误差与经验误差

令 h 为从 $\mathcal{X}$ 到 $\mathcal{Y}$ 的一个映射, 其泛化误差为

$$E(h; \mathcal{D}) = P_{\mathbf{x} \sim \mathcal{D}}(h(\mathbf{x}) \neq y) = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}}[\mathbb{I}(h(\mathbf{x}) \neq y)], \quad (2.1)$$

h 在 D 上的经验误差为

$$\hat{E}(h; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(\mathbf{x}_i) \neq y_i). \quad (2.2)$$

两者之间的关系: 由于 D 是 $\mathcal{D}$ 的独立同分布采样, 因此 h 的经验误差的期望等于其泛化误差.

在上下文明确时, $E(h; \mathcal{D})$ 和 $\hat{E}(h; D)$ 分别简记为 $E(h)$ 和 $\hat{E}(h)$.

误差参数 一致性 不合

误差参数 ϵ

ϵ 为 $E(h)$ 的上界, 即 $E(h) \leq \epsilon$, 表示预先设定的学得模型所应满足的误差要求, 亦称误差参数.

一致性:

若 h 在数据集 D 上的经验误差为 0, 则称 h 与 D 一致, 否则称其与 D 不一致.

不合 (disagreement) :

对任意两个映射 $h_1, h_2 \in \mathcal{X} \rightarrow \mathcal{Y}$, 可通过其 “不合” 来度量它们之间的差别:

$$\text{dis}(h_1, h_2) = P_{\mathbf{x} \sim \mathcal{D}}(h_1(\mathbf{x}) \neq h_2(\mathbf{x})) . \quad (2.3)$$

概念

概念:

令 c 表示概念(concept), 这是从样本空间 $\mathcal{X}$ 到标记空间 $\mathcal{Y}$ 的映射, 它决定示例 x 的真实标记 y

目标概念:

若对任何样例 (x, y) , 都有 $c(x) = y$ 成立, 则称 c 为目标概念

概念类:

所有希望学得的目标概念所构成的集合称为概念类(concept class), 用符号 C 表示.

概念的举例

例：三角形概念

目标概念“三角形”把所有三角形映射为1, 把其它图形映射为-1。

例：概念类

一个概念类则是想要学习的概念构成的一个集合. 假设我们在学习任务中考虑“三角形”“四边形”“五边形”这三种概念, 则它们组成的集合{三角形, 四边形, 五边形}就构成了一个概念类。

假设与假设空间

假设空间(hypothesis space):

给定学习算法 $\mathcal{L}$, 它所考虑的所有可能的概念构成的集合称为假设空间, 用符号 $\mathcal{H}$ 表示.

学习算法 $\mathcal{L}$ 事先并不知道概念类的真实存在, 故 $\mathcal{H}$ 和 $\mathcal{C}$ 通常是不同的, 学习算法会把自认为可能的目标概念集中起来构成 $\mathcal{H}$

假设(hypothesis):

对 $h \in \mathcal{H}$, 由于并不能确定它是否真是目标概念, 因此称为假设, 显然假设 h 也是从示例空间 $\mathcal{X}$ 到标记空间 $\mathcal{Y}$ 的映射.

可分性

可分(separable):

若目标概念 $c \in \mathcal{H}$, 则 $\mathcal{H}$ 中存在假设能将样本正确地完全分开, 我们称以 c 为目标的这个学习问题对假设空间 $\mathcal{H}$ 是可分的.

不可分(non-separable):

若 $c \notin \mathcal{H}$, 则 $\mathcal{H}$ 中不存在任何假设能将所有样本正确地完全分开, 则称该学习问题对假设空间 $\mathcal{H}$ 是不可分的.

PAC的基本思想

概率近似正确 (Probably Approximately Correct ,PAC) , [Valiant, 1984].

希望以比较大的把握学得比较好的模型, 即以较大的概率学得误差满足预设上限的模型.

对于给定训练集 D , 希望基于学习算法 $\mathcal{L}$ 学得模型对应的假设 h 尽可能地接近目标概念 c .

为什么不是希望精确地学得目标概念 c 呢?

机器学习过程受很多因素的制约:

获取的训练集 D 往往仅包含有限数量的样本, 因此通常会存在一些在 D 上等价的假设, 学习算法有时无法区分它们

从分布 $\mathcal{D}$ 采样得到数据集 D 有一定偶然性, 即使对同样大小的不同训练集 D , 学得结果也可能有所不同.

PAC辨识

形式化地说, 令 δ 表示置信参数, 可定义:

PAC辨识 (PAC Identify):

对 $0 < \epsilon, \delta < 1$, 所有 $c \in \mathcal{C}$ 和分布 $\mathcal{D}$, 若存在学习算法 $\mathcal{L}$, 其输出的假设 $h \in \mathcal{H}$ 满足

$$P(E(h) \leq \epsilon) \geq 1 - \delta, \quad (2.4)$$

则称学习算法 $\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中辨识概念类 $\mathcal{C}$.

这样的学习算法 $\mathcal{L}$ 能以较大的概率(至少 $1 - \delta$)学得目标概念 c 的近似(误差最大为 ϵ)

在此基础上我们可以定义PAC可学习

PAC可学习

PAC可学习 (PAC Learnable) :

令 m 表示从分布 $\mathcal{D}$ 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$, 对所有分布 $\mathcal{D}$, 若存在学习算法 $\mathcal{L}$ 和多项式函数 $poly(., ., ., .)$, 使得对于任何

$$m \geq poly(1/\epsilon, 1/\delta, size(x), size(c))$$

$\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中 PAC 辨识 概念类 $\mathcal{C}$, 则称概念类 $\mathcal{C}$ 对假设空间 $\mathcal{H}$ 而言是 PAC 可学习的, 有时也简称概念类 $\mathcal{C}$ 是 PAC 可学习的.

如果一个概念类 $\mathcal{C}$ 是 PAC 可学习的, 则学习算法能够在观察一定数量的样本后以较高概率 (至少 $1 - \delta$) 返回目标概念 c 近似正确的假设 (泛化错误率小于 ϵ)

PAC学习算法

PAC可学习性描述的是概念类 C 和假设空间 $\mathcal{H}$ 的性质, 若考虑到对应学习算法 $\mathcal{L}$ 的时间复杂度, 则有:

PAC学习算法(PAC Learning Algorithm):

若学习算法 $\mathcal{L}$ 使概念类 C 为PAC可学习的, 且 $\mathcal{L}$ 的运行时间也是多项式函数

$$\text{poly}(1/\epsilon, 1/\delta, \text{size}(\mathbf{x}), \text{size}(c))$$

则称概念类 C 是高效PAC可学习(efficiently PAC learnable)的, 称 $\mathcal{L}$ 为概念类 C 的PAC学习算法。

样本复杂度

假定学习算法 $\mathcal{L}$ 处理每个样本的时间为常数, 则 $\mathcal{L}$ 的时间复杂度等价于样本复杂度:

样本复杂度(Sample Complexity):

满足 PAC 学习算法 $\mathcal{L}$ 所需的 $m \geq \text{poly}(1/\epsilon, 1/\delta, \text{size}(x), \text{size}(c))$ 中最小的 m , 称为学习算法 $\mathcal{L}$ 的样本复杂度.

PAC框架的意义

PAC学习给出了一个抽象地刻画机器学习能力的框架, 基于这个框架能对很多重要问题进行理论探讨:

研究学习任务在什么样的条件下可学得较好的模型?

研究学习任务需多少训练样本才能获得较好的模型?

研究算法在什么样的条件下可进行有效的学习?

.....

可分情形：恰PAC可学习

恰PAC可学习(properly PAC learnable):

假设空间 $\mathcal{H}$ 包含了学习算法 $\mathcal{L}$ 所有可能输出的假设，在PAC学习中假设空间 $\mathcal{H}$ 与概念类 $\mathcal{C}$ 完全相同，即 $\mathcal{H} = \mathcal{C}$ ，这称为恰PAC可学习。

直观上看，这意味着学习算法的能力与学习任务“恰好匹配。”

然而在现实应用中，由于对概念类 $\mathcal{C}$ 通常一无所知，设计一个假设空间与概念类恰好相同的学习算法通常是不切实际的

研究的重点：假设空间与概念类不同的情形，即 $\mathcal{H} \neq \mathcal{C}$ 。

不可分情形

对较为困难的学习问题，目标概念 c 往往不存在于假设空间 $\mathcal{H}$ 中，假定对于任何 $h \in \mathcal{H}$ ， $\hat{E}(h) \neq 0$ ，也就是说， $\mathcal{H}$ 中的任意一个假设都会训练集上出现或多或少的错误。

【Hoeffding 不等式】对 m 个独立随机变量 $X_i \in [0, 1]$ ($i = 1, \dots, m$)，有

$$P\left(\frac{1}{m} \sum_{i=1}^m X_i - \mathbb{E}\left[\frac{1}{m} \sum_{i=1}^m X_i\right] \geq \epsilon\right) \leq e^{-2m\epsilon^2}. \quad (1.26)$$

基于Hoeffding不等式可得

引理2.1：若训练集 D 包含 m 个从分布 $\mathcal{D}$ 上独立同分布采样而得的样本， $0 < \epsilon < 1$ ，则对任意 $h \in \mathcal{H}$ ，有

$$P(\hat{E}(h) - E(h) \geq \epsilon) \leq \exp(-2m\epsilon^2), \quad (2.5)$$

$$P(E(h) - \hat{E}(h) \geq \epsilon) \leq \exp(-2m\epsilon^2), \quad (2.6)$$

$$P(|E(h) - \hat{E}(h)| \geq \epsilon) \leq 2 \exp(-2m\epsilon^2). \quad (2.7)$$

不可分情形

定理 2.1：若训练集 D 包含 m 个从分布 $\mathcal{D}$ 独立同分布采样而得的样例， $0 < \epsilon < 1$ ，则对任意 $h \in \mathcal{H}$ ，下式至少以 $1 - \delta$ 的概率成立：

$$\hat{E}(h) - \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}} < E(h) < \hat{E}(h) + \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}}. \quad (2.8)$$

上述推论表明，样例数目 m 较大时， h 的经验误差是其泛化误差很好的近似。

不可分情形

定理2.1的证明:
不妨令

$$\delta = 2 \exp(-2m\epsilon^2) , \quad (2.9)$$

即

$$\epsilon = \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}} , \quad (2.10)$$

将上面两个式子代入 $P(|E(h) - \hat{E}(h)| \geq \epsilon) \leq 2 \exp(-2m\epsilon^2)$.
得

$$P \left(|E(h) - \hat{E}(h)| \geq \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}} \right) \leq \delta , \quad (2.11)$$

即至少以 $1 - \delta$ 的概率有

$$|E(h) - \hat{E}(h)| < \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}} , \quad (2.12)$$

即式 (2.8) 成立, 定理2.1得证

□

不可分情形

当 $c \notin \mathcal{H}$ 时,

学习算法 $\mathcal{L}$ 无法学得目标概念 c 的 ϵ 近似.

当假设空间 $\mathcal{H}$ 给定时, 其中必存在一个泛化误差最小的假设
找出此假设的 ϵ 近似也不失为一个较好的目标.

$\mathcal{H}$ 中泛化误差最小的假设表示为 $\operatorname{argmin}_{h \in \mathcal{H}} E(h)$

于是, 以此为目标可将PAC学习推广到 $c \notin \mathcal{H}$ 的情形, 称为不可知学习 (agnostic learning). 相应的, 我们可以定义不可知PAC可学习:

不可知PAC可学习

不可知 PAC 可学习 (agnostic PAC learnable):

令 m 表示从分布 $\mathcal{D}$ 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$, 对所有分布 $\mathcal{D}$, 若存在学习算法 $\mathcal{L}$ 和多项式函数 $poly(., ., ., .)$, 使得对于任何 $m \geq poly(1/\epsilon, 1/\delta, size(x), size(c))$, $\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中输出满足下式的假设 h :

$$P(E(h) - \min_{h' \in \mathcal{H}} E(h') \leq \epsilon) \geq 1 - \delta, \quad (2.13)$$

则称假设空间 $\mathcal{H}$ 是不可知PAC可学习的.

若此处学习算法 $\mathcal{L}$ 的运行时间也是多项式函数 $poly(1/\epsilon, 1/\delta, size(x), size(c))$ 则称假设空间 $\mathcal{H}$ 是高效不可知PAC可学习的, 学习算法 $\mathcal{L}$ 则称为假设空间 $\mathcal{H}$ 的不可知PAC学习算法, 满足上述要求的最小 m 称为学习算法 $\mathcal{L}$ 的样本复杂度.

PAC框架的要点

- PAC框架是一种分布无关的模型，未对产生样本的分布 $\mathcal{D}$ 作任何假设。
 - 训练样本和用来计算错误率的测试样本都来自于同一个分布 $\mathcal{D}$ 。要使PAC模型能够得到推导，这是一个必不可少的假定。
 - PAC模型处理的是某个概念类 $\mathcal{C}$ 的可学习性，而不是某一个特定的概念。通常目标概念 $c \in \mathcal{C}$ 对于学习算法是未知的。
-

复杂度

假设空间 $\mathcal{H}$ 的复杂度是影响可学习性的重要因素之一.一般而言, $\mathcal{H}$ 越大,其包含的任意目标概念的可能性越大,但从中找到某个具体目标概念的难度就越大

$|\mathcal{H}|$ 有限时,我们称 $\mathcal{H}$ 为有限假设空间,否则称为无限假设空间.

有限假设空间包含的概念数有限,可以用概念个数 $|\mathcal{H}|$ 来衡量其复杂度

对于无限假设空间,需使用 $|\mathcal{H}|$ 之外的方法度量假设空间的复杂度:

VC 维 (Vapnik-Chervonekis dimension)

Rademacher 复杂度 (Rademacher Complexity)

复杂度的概念和性质将在后续进行进一步介绍

泛化性

PAC可学习考虑的是学习算法 $\mathcal{L}$ 输出假设的泛化误差与最优假设的泛化误差之间的差别(在可分情况下, 最优假设的泛化误差为0)。

由于真实分布 $\mathcal{D}$ 未知, 泛化误差通常无法直接计算。

不过, 由于经验误差与泛化误差有密切联系, 我们可以借助经验误差来进行比较, 于是有必要考虑经验误差与泛化误差之间的差距, 我们将在后续进行讨论。
