

统计学习理论简介

II. 复杂度

前言

由PAC学习理论可以看出，PAC可学习与假设空间 $\mathcal{H}$ 的复杂程度密切相关。假设空间 $\mathcal{H}$ 越复杂，从中寻找到目标概念的难度越大。

对于有限的假设空间，可以用其中包含假设的数目 $|\mathcal{H}|$ 来刻画假设空间的复杂度。在可分情形下，可以通过层层筛选的方式从有限的假设空间中寻找到目标概念。

然而，对于大多数学习问题来说，算法 $\mathcal{L}$ 考虑的假设空间并非是有限的，直接使用 $|\mathcal{H}|$ 来刻画假设空间的复杂度不再有意义。

为此，本章将介绍刻画无限假设空间复杂度的方法，包括与数据分布 $\mathcal{D}$ 无关的 VC 维及其扩展 Natarajan 维，以及与数据分布相关的 Rademacher 复杂度。

前者计算简单，适用于许多学习问题，但其未考虑具体学习问题的数据特点，对假设空间复杂度的刻画较为粗糙；后者考虑了具体学习问题的数据特点，对假设空间复杂度的刻画较为准确，但计算复杂度较高，有时甚至是 NP-难问题。

数据分布无关

现实学习任务面对的通常是无限假设空间，例如实数域中的区间， $\mathbb{R}^d$ 空间中的所有线性超平面。

为了对这些无限假设空间进行研究，通常考虑其 VC 维 (Vapnik-Chervonenkis Dimension) [Vapnik and Chervonenkis, 1971]。

在介绍 VC 维之前，先引入几个概念。

限制 (restriction)

令 $\mathcal{H}$ 表示假设空间, 其中的假设是 $\mathcal{X}$ 到 $\mathcal{Y} = \{-1, +1\}$ 的映射, 对于数据集 $D = \{x_1, \dots, x_m\} \subset \mathcal{X}$, $\mathcal{H}$ 在数据集 D 上的 **限制** 是从 D 到 $\{-1, +1\}^m$ 的一族映射:

$$\mathcal{H}|_D = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}. \quad (3.1)$$

其中, h 在 D 上的限制是一个 m 维向量。

- 假设空间 $\mathcal{H}$ 中不同的假设对于 D 中示例赋予标记的结果可能相同, 也可能不同。
 - 尽管 $\mathcal{H}$ 可能包含无穷多个假设, 但 $\mathcal{H}|_D$ 却是有限的, 即 $\mathcal{H}$ 对 D 中示例赋予标记的可能结果数是有限的。
 - 例如, 对二分类问题, 对于 m 个示例最多有 2^m 个可能的结果。
-

增长函数 (growth function)

增长函数 (growth function)

对于 $m \in \mathbb{N}$, 假设空间 $\mathcal{H}$ 的增长函数 $\Pi_{\mathcal{H}}(m)$ 表示为

$$\Pi_{\mathcal{H}}(m) = \max_{\{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}} |\{h(\mathbf{x}_1), \dots, h(\mathbf{x}_m) | h \in \mathcal{H}\}|. \quad (3.2)$$

利用限制的定義，可以記為

$$\Pi_{\mathcal{H}}(m) = \max_{|D|=m} |\mathcal{H}|_D. \quad (3.3)$$

增长函数表示假设空间对个示例所能赋予标记的最大可能的结果数。

增长函数在一定程度上描述了假设空间的表达能力，反映了假设空间的复杂程度！

对分 (dichotomy) 、 打散 (shattering)

对分 (dichotomy)

- 对于二分类问题，假设空间 $\mathcal{H}$ 中的假设对 D 中的示例赋予标记的每种可能结果称为对 D 的一种对分。
- 该假设把 D 中的示例分成了正、负两类。

打散 (shattering)

- 如果假设空间 $\mathcal{H}$ 能实现示例集 D 上的所有对分，即 $|\mathcal{H}|_D = 2^m$ ，则称示例集 D 能被假设空间 $\mathcal{H}$ 打散，此时 $\Pi_{\mathcal{H}}(m) = 2^m$ 。

对分 (dichotomy) 、 打散 (shattering)

例如：

令 $\mathcal{H}$ 表示 $\mathbb{R}$ 上的阈值函数构成的集合，其中阈值函数表示为 $h_a(x) = \text{sign}(\mathbb{I}_{\{x < a\}} - \frac{1}{2})$ ，则 $\mathcal{H} = \{h_a : a \in \mathbb{R}\}$ 。

令 $D = \{x_1\}$ ，如果取 $a = x_1 + 1$ ，则 $h_a(x_1) = +1$ ；

如果取 $a = x_1 - 1$ ，则 $h_a(x_1) = -1$ 。

因此 $\mathcal{H}$ 能打散 $D = \{x_1\}$ 。

令 $D' = \{x_1, x_2\}$ ，不妨假设 $x_1 < x_2$ ，则易知同时将 x_1 分类为 -1 但把 x_2 分类为 $+1$ 的结果不能被 $\mathcal{H}$ 中的任何阈值函数实现。

这是因为如果 $h_a(x_1) = -1$ ，则必有 $h_a(x_2) = -1$ 。

所以 $\mathcal{H}$ 不能打散 D' 。

定义 3.1 [Vapnik and Chervonenkis, 1971] VC 维: 假设空间 $\mathcal{H}$ 的 VC 维是能被 $\mathcal{H}$ 打散的最大示例集的大小, 即

$$VC(\mathcal{H}) = \max\{m : \Pi_{\mathcal{H}}(m) = 2^m\}. \quad (3.4)$$

$VC(\mathcal{H}) = d$ 表明存在大小为 d 的示例集能被假设空间 $\mathcal{H}$ 打散。

注意:

- 这并不意味着所有大小为 d 的示例集都能被假设空间 $\mathcal{H}$ 打散。
- VC 维的定义与数据分布 $\mathcal{D}$ 无关! 因此, 在数据分布未知时仍能计算出假设空间 $\mathcal{H}$ 的 VC 维。

定义 3.1 [Vapnik and Chervonenkis, 1971] VC 维: 假设空间 $\mathcal{H}$ 的 VC 维是能被 $\mathcal{H}$ 打散的最大示例集的大小, 即

$$VC(\mathcal{H}) = \max\{m : \Pi_{\mathcal{H}}(m) = 2^m\}. \quad (3.4)$$

要证明一个具体的假设空间 $\mathcal{H}$ 的 VC 维为 d , 需要证明两点:

- 存在大小为 d 的示例集 D 能被 $\mathcal{H}$ 打散;
- 任意大小为 $d+1$ 的示例集 D' 都不能被 $\mathcal{H}$ 打散。

用 VC 维来衡量有限假设空间的复杂度更为准确, 且更具优势。

- 令假设空间 $\mathcal{H}$ 为有限集合。对于任意数据集 D , 有 $|\mathcal{H}|_D \leq |\mathcal{H}|$ 。还可知当 $|\mathcal{H}| < 2^{|D|}$ 时, $\mathcal{H}$ 无法打散 D 。因此, 可得 $VC(\mathcal{H}) \leq \log_2 |\mathcal{H}|$ 。事实上, 有限假设空间 $\mathcal{H}$ 的 $VC(\mathcal{H})$ 通常可以远小于 $\log_2 |\mathcal{H}|$ 。

两种假设空间的 VC 维：

- 阈值函数的VC维：

令 $\mathcal{H}$ 表示所有定义在 $\mathbb{R}$ 上的阈值函数组成的集合，由上述讨论可知存在大小为 1 的示例集 D 能被 $\mathcal{H}$ 打散，但任意大小为 2 的示例集 $|D'|$ 都不能被 $\mathcal{H}$ 打散，于是根据定义可知 $VC(\mathcal{H}) = 1$ 。

- 区间函数的VC维：

令 $\mathcal{H}$ 表示所有定义在 $\mathbb{R}$ 上的区间组成的集合 $\mathcal{H} = \{h_{a,b} : a, b \in \mathbb{R}, a < b\}$ ，其中 $h_{a,b}(x) = (\mathbb{I}_{\{x \in (a,b)\}} - 1/2)$ 。令 $D = \{1, 2\}$ ，易知 $\mathcal{H}$ 能打散 D ，因此 $VC(\mathcal{H}) \geq 2$ 。对于任意大小为 3 的示例集 $D' = \{x_1, x_2, x_3\}$ ，不妨设 $x_1 < x_2 < x_3$ ，则分类结果 $(+1, -1, +1)$ 不能被 $\mathcal{H}$ 中的任何区间函数实现，因为当 $h_{a,b}(x_1) = +1$ 且 $h_{a,b}(x_3) = +1$ 时，必有 $h_{a,b}(x_2) = +1$ 。所以 $\mathcal{H}$ 无法打散任何大小为 3 的示例集，即得出结论 $VC(\mathcal{H}) = 2$ 。

由增长函数的定义可知，VC维与增长函数关系密切，引理 3.1 [Sauer, 1972] 给出了二者之间的定量关系：

引理 3.1 若假设空间 $\mathcal{H}$ 的 VC 维为 d ，则对任意 $m \in \mathbb{N}$ 有

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i}. \quad (3.5)$$

注：Sauer 引理由 [Sauer, 1972] 而命名，但 Vapnik and Chervonenkis [1971] 和 Shelah [1972] 也分别独立地给出了该结果。

证明：利用数学归纳法证明。

当 $m = 1$, $d = 0$ 或 $d = 1$ 时, 引理成立。

假设引理对 $(m - 1, d - 1)$ 和 $(m - 1, d)$ 成立。

令 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $D' = \{\mathbf{x}_1, \dots, \mathbf{x}_{m-1}\}$,

$$\mathcal{H}_{|D} = \{(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m)) | h \in \mathcal{H}\}, \quad (3.6)$$

$$\mathcal{H}_{|D'} = \{(h(\mathbf{x}_1), \dots, h(\mathbf{x}_{m-1})) | h \in \mathcal{H}\}, \quad (3.7)$$

分别为假设空间在 D 和 D' 上的限制。任何假设 $h \in \mathcal{H}$ 对 $\mathbf{x}_m$ 的分类结果为 $+1$ 或 -1 , 因此任何出现在 $\mathcal{H}_{|D'}$ 的串都会在 $\mathcal{H}_{|D}$ 出现一次或者两次。令 $\mathcal{H}_{D'|D}$ 表示 $\mathcal{H}_{|D}$ 中出现两次的 $\mathcal{H}_{|D'}$ 中串组成的集合, 即

$$\begin{aligned} \mathcal{H}_{D'|D} = \{ & (y_1, \dots, y_{m-1}) \in \mathcal{H}_{|D'} | \exists h, h' \in \mathcal{H}, \\ & (h(\mathbf{x}_i) = h'(\mathbf{x}_i) = y_i) \wedge (h(\mathbf{x}_m) \neq h'(\mathbf{x}_m)), 1 \leq i \leq m - 1\}. \end{aligned} \quad (3.8)$$

考虑到 $\mathcal{H}_{D'|D}$ 中的串在 $\mathcal{H}_D$ 中出现了两次，但在 $\mathcal{H}_{D'}$ 中仅出现了一次，有

$$|\mathcal{H}_D| = |\mathcal{H}_{D'}| + |\mathcal{H}_{D'|D}|. \quad (3.9)$$

D' 的大小为 $m - 1$ ，根据归纳的前提假设可得

$$|\mathcal{H}_{D'}| \leq \Pi_{\mathcal{H}}(m - 1) \leq \sum_{i=0}^d \binom{m - 1}{i}. \quad (3.10)$$

令 Q 表示能被 $\mathcal{H}_{D'|D}$ 打散的集合，由 Q 的定义可知 $Q \cup \{x_m\}$ 必能被 $\mathcal{H}_D$ 打散。由于 $\mathcal{H}$ 的 VC 维为 d ，因此 $\mathcal{H}_{D'|D}$ 的 VC 维最大为 $d - 1$ ，于是有

$$|\mathcal{H}_{D'|D}| \leq \Pi_{\mathcal{H}}(m - 1) \leq \sum_{i=0}^{d-1} \binom{m - 1}{i}. \quad (3.11)$$

综合式 (3.9) - (3.11) 可得

$$\begin{aligned} |\mathcal{H}|_D &\leq \sum_{i=0}^d \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} \\ &= \sum_{i=0}^d \left(\binom{m-1}{i} + \binom{m-1}{i-1} \right) \\ &= \sum_{i=0}^d \binom{m}{i}. \end{aligned} \tag{3.12}$$

由 D 的任意性, 式 (3.5) 成立。引理得证。

由引理 3.1 可以计算出增长函数的上界 [Sauer, 1972] :

定理 3.1 若假设空间 $\mathcal{H}$ 的 VC 维为 d , 则对任意整数 $m \geq d$ 有

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{e \cdot m}{d} \right)^d. \quad (3.13)$$

- 当假设空间 $\mathcal{H}$ 的 VC 维为无穷大时, 任意大小的示例集 D 都能被 $\mathcal{H}$ 打散, 此时有 $\Pi_{\mathcal{H}}(m) = 2^m$, 增长函数随着数据集的大小指数级增长;
- 当 VC 维有限为 d 且 $m \geq d$ 时, 由定理 3.1 可知增长函数随数据集的大小多项式级增长。

证明:

$$\begin{aligned}\Pi_{\mathcal{H}}(m) &\leq \sum_{i=0}^d \binom{m}{i} \\ &\leq \sum_{i=0}^d \binom{m}{i} \left(\frac{m}{d}\right)^{d-i} \\ &= \left(\frac{m}{d}\right)^d \sum_{i=0}^d \binom{m}{i} \left(\frac{d}{m}\right)^i \\ &\leq \left(\frac{m}{d}\right)^d \sum_{i=0}^m \binom{m}{i} \left(\frac{d}{m}\right)^i \\ &= \left(\frac{m}{d}\right)^d \left(1 + \frac{d}{m}\right)^m \\ &\leq \left(\frac{e \cdot m}{d}\right)^d.\end{aligned}$$

- VC维是针对二分类问题定义的。
- 对于多分类问题，需定义Natarajan维。

多分类问题：

假设空间 $\mathcal{H}$ 包含的假设是 $\mathcal{X}$ 到 $\mathcal{Y} = \{0, \dots, K-1\}$ 的映射，其中 K 为类别数。

打散(多分类问题)：

对于给定的一个集合 $D \subset \mathcal{X}$ ，若假设空间 $\mathcal{H}$ 中存在两个映射 $f_0, f_1 : D \rightarrow \mathcal{Y}$ 满足以下两个条件：

- 对于任意的 $x \in D$, $f_0(x) \neq f_1(x)$;
- 对于任意的集合 $B \subset D$ 存在一个映射 $h \in \mathcal{H}$ 使得

$$\forall x \in B, h(x) = f_0(x) \text{ 且 } \forall x \in D \setminus B, h(x) = f_1(x), \quad (3.14)$$

则称集合 D 能被假设空间 $\mathcal{H}$ **打散**(多分类问题)。

定义 3.2 Natarajan 维: 对于多分类问题的假设空间 $\mathcal{H}$, Natarajan 维是能被 $\mathcal{H}$ 打散的最大示例集的大小, 记作 $Natarajan(\mathcal{H})$.

显然, Natarajan维是VC维从二分类问题到多分类问题的扩展。

下面的定理表明, 二分类问题的VC维与Natarajan维相同。

定理 3.2 类别数 $K = 2$ 时, $VC(\mathcal{H}) = Natarajan(\mathcal{H})$.

证明: 首先证明 $VC(\mathcal{H}) \leq Natarajan(\mathcal{H})$ 。

令 D 表示大小为 $VC(\mathcal{H})$ 且能被 $\mathcal{H}$ 打散的集合。取多分类问题打散定义中的 f_0, f_1 为常值函数, 即 $f_0 = 0, f_1 = 1$ 。由于 D 能被 $\mathcal{H}$ 打散, 则对于任意集合 $B \subset D$, 存在 h_B 使得 $x \in B$ 时 $h_B(x) = 0, x \in D \setminus B$ 时 $h_B(x) = 1$, 即 $\mathcal{H}$ 能打散大小为 $VC(\mathcal{H})$ 的 D , 于是有 $VC(\mathcal{H}) \leq Natarajan(\mathcal{H})$ 。

再证明 $VC(\mathcal{H}) \geq Natarajan(\mathcal{H})$ 。

令 D 表示大小为 $Natarajan(\mathcal{H})$ 且在多分类问题中能被 $\mathcal{H}$ 打散的集合。当 $K = 2$ 时, $f_0, f_1 : D \rightarrow \mathcal{Y} = \{0, 1\}$ 。取 $D_i^v = \{x \in D | f_i(x) = v\}$ 。对于 D 上的任意一种划分 $c : D \rightarrow \mathcal{Y}$, 记 $D^+ = \{x \in D | c(x) = 1\}, D^- = \{x \in D | c(x) = 0\}$ 。令多分类问题打散定义中 $B = (D^+ \cap D_0^1) \cup (D^- \cap D_0^0)$, 可知存在 $h \in \mathcal{H}$ 使得 $\forall x \in D$ 有 $h(x) = c(x)$, 即 $\mathcal{H}$ 能打散大小为 $Natarajan(\mathcal{H})$ 的 D , 于是有 $VC(\mathcal{H}) \geq Natarajan(\mathcal{H})$ 。

定理得证。

对于多分类问题，通过Natarajan维控制增长函数的增长速度，可得到下面的定理 [Natarajan, 1989]:

定理 3.3 若多分类问题假设空间 $\mathcal{H}$ 的 Natarajan 维为 d , 类别数为 K , 则对任意 $m \in \mathbb{N}$ 有

$$\Pi_{\mathcal{H}}(m) \leq m^d K^{2d}. \quad (3.15)$$

证明：利用数学归纳法证明。

当 $m = 1$, $d = 0$ 或 $d = 1$ 时, 定理成立。

假设定理对 $(m - 1, d - 1)$ 和 $(m - 1, d)$ 成立。

令 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, 对于 $\mathcal{Y} = \{0, \dots, K - 1\}$, $\mathcal{H}|_D$ 可以推广到多分类问题。

令

$$\mathcal{H}_k = \{h \in \mathcal{H}|_D \mid h(\mathbf{x}_1) = k\}, k = 0, \dots, K - 1, \quad (3.16)$$

基于 $\mathcal{H}_k$ 可以定义如下集合：

$$\forall i \neq j, \mathcal{H}_{ij} = \{h \in \mathcal{H}_i \mid \exists h' \in \mathcal{H}_j, h(\mathbf{x}_l) = h'(\mathbf{x}_l), l = 2, \dots, m\}, \quad (3.17)$$

$$\bar{\mathcal{H}} = \mathcal{H}|_D - \cup_{i \neq j} \mathcal{H}_{ij}. \quad (3.18)$$

根据联合界 (Union Bound) 不等式 (1.14) 可知

$$|\mathcal{H}|_D| \leq |\bar{\mathcal{H}}| + |\cup_{i \neq j} \mathcal{H}_{ij}| \leq |\bar{\mathcal{H}}| + \sum_{i \neq j} |\mathcal{H}_{ij}|. \quad (3.19)$$

根据定义, $\bar{\mathcal{H}}$ 在 $D - \{x_1\}$ 上无相同假设, 且 $Natarajan(\bar{\mathcal{H}}) \leq d$ 。根据归纳的前提假设, 可知

$$|\bar{\mathcal{H}}| \leq \Pi_{\bar{\mathcal{H}}}(m-1) \leq (m-1)^d K^{2d}. \quad (3.20)$$

同时, 对于任意 $\mathcal{H}_{ij}$, 其 Natarajan 维最多为 $d-1$, 否则 $\mathcal{H}$ 的 Natarajan 维将超过 d 。同样根据归纳的前提假设, 有

$$\forall i \neq j, |\mathcal{H}_{ij}| \leq \Pi_{\mathcal{H}_{ij}}(m) \leq m^{d-1} K^{2(d-1)}. \quad (3.21)$$

综上所述可得

$$\begin{aligned} |\mathcal{H}_D| &\leq |\bar{\mathcal{H}}| + \sum_{i \neq j} |\mathcal{H}_{ij}| \leq \Pi_{\bar{\mathcal{H}}}(m-1) + \sum_{i \neq j} \Pi_{\mathcal{H}_{ij}}(m) \\ &\leq (m-1)^d K^{2d} + K^2 m^{d-1} K^{2(d-1)} \\ &\leq m^d K^{2d}. \end{aligned} \quad (3.22)$$

由 D 的任意性, (3.15) 成立。定理得证。

VC维

VC维的定义与数据分布无关。因此基于VC维的分析结果是分布无关、数据独立的，也就是说对任意数据分布都成立。

- 一方面，基于VC维的分析结果具有一定的“普适性”；
- 另一方面，由于没有考虑数据自身，基于VC维的分析结果通常比较“松”，对那些与学习问题的典型情况相差甚远的较“坏”分布来说尤其如此。

Rademacher 复杂度

- 是另一种刻画假设空间复杂度的工具；
- 与VC维不同的是，它在一定程度上考虑了数据分布。

给定数据集 $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$, 假设 h 的经验误差为

$$\begin{aligned}\hat{E}(h) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(\mathbf{x}_i) \neq y_i) \\ &= \frac{1}{m} \sum_{i=1}^m \frac{1 - y_i h(\mathbf{x}_i)}{2} \\ &= \frac{1}{2} - \frac{1}{2m} \sum_{i=1}^m y_i h(\mathbf{x}_i).\end{aligned}\tag{3.23}$$

其中 $\frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i)$ 体现了预测值 $h(\mathbf{x}_i)$ 与样例真实标记 y_i 之间的一致性, 若 $h(\mathbf{x}_i) = y_i, 1 \leq i \leq m$, 则 $\frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i)$ 取得最大值 1, 也就是说具有最小经验误差的假设是

$$\arg \max_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i).\tag{3.24}$$

现实任务中样例的标记有时会受到噪声的影响，即对某些样例 $(\mathbf{x}_i, y_i)$ 来说，其 y_i 或许已经受到随机因素的影响，不再是 $\mathbf{x}_i$ 的真实标记。在此情形下，选择假设空间 $\mathcal{H}$ 中在训练集上表现最好的假设，有时还不如选择 $\mathcal{H}$ 中事先已考虑了随机噪声的假设。

Rademacher随机变量

考虑随机变量 σ_i ，它以 0.5 的概率取值 -1 ，以 0.5 的概率取值 $+1$ ，称其为 Rademacher 随机变量。基于 σ_i 可将 (3.24) 改写为

$$\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i). \quad (3.25)$$

对所有的 σ_i 求期望可得

$$\mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) \right]. \quad (3.26)$$

$$\mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) \right] . \quad (3.26)$$

式 (3.26) 和增长函数有着相似的作用，体现了假设空间在数据集 D 上的表示能力，取值范围为 $[0, 1]$ 。当式 (3.26) 取值为 1 时，意味着对任意 $\sigma = \{\sigma_1, \dots, \sigma_m\}$ $\sigma_i \in \{-1, +1\}$ ，有

$$\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) = 1 . \quad (3.27)$$

在有限假设空间的情况下，即 $\exists h \in \mathcal{H}$, s.t. $h(\mathbf{x}_i) = \sigma_i, 1 \leq i \leq m$ ，类似于 $|\mathcal{H}|_D = 2^m$ ，也就有 $\Pi_{\mathcal{H}}(m) = 2^m$ ，即 $\mathcal{H}$ 能打散 D 。

总的来说，式 (3.26) 的值越接近 1，假设空间的表示能力越强。

考虑实值函数空间 $\mathcal{F} : \mathcal{Z} \rightarrow \mathbb{R}$, 令 $Z = \{z_1, \dots, z_m\}$, 其中 $z_i \in \mathcal{Z}$, 将式(3.27) 中的 $\mathcal{X}$ 和 $\mathcal{H}$ 替换为 $\mathcal{Z}$ 和 $\mathcal{F}$ 可得 [Koltchinskii, 2001]

定义 3.3 函数空间 $\mathcal{F}$ 关于 Z 的经验 Rademacher 复杂度为

$$\hat{R}_Z(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right]. \quad (3.28)$$

这里的 Z 是一个给定的集合。经验Rademacher复杂度衡量了函数空间 $\mathcal{F}$ 与随机噪声在数据集 Z 中的相关性。

对从分布 $\mathcal{D}$ 独立同分布采样得到的大小为 m 的集合 Z 求期望可得

定义 3.4 函数空间 $\mathcal{F}$ 关于 Z 在分布 $\mathcal{D}$ 上的 Rademacher 复杂度为

$$R_m(\mathcal{F}) = \mathbb{E}_{Z \subset \mathcal{Z}: |Z|=m} [\hat{R}_Z(\mathcal{F})]. \quad (3.29)$$

- Rademacher复杂度依赖于具体学习问题及数据分布，是为具体学习问题量身定制的。
- 基于Rademacher复杂度可以比基于VC维推导出更紧的泛化误差界。
- 需要注意到，在Rademacher复杂度的定义中 σ 是 $\{-1, +1\}$ 上服从均匀分布的随机变量。如果将均匀分布改为其他分布，会得到其他一些复杂度的定义。

经验Gauss复杂度 [Bartlett and Mendelson, 2003]

定义 3.5 函数空间 $\mathcal{F}$ 关于 Z 的经验 Gauss 复杂度为

$$\hat{G}_Z(\mathcal{F}) = \mathbb{E}_{\mathbf{g}} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m g_i f(z_i) \right], \quad (3.30)$$

其中 $\mathbf{g} = \{g_1, \dots, g_m\}$ 服从高斯分布, 即标准正态分布。

Gauss复杂度: 对经验Gauss复杂度求期望可得

定义 3.6 函数空间 $\mathcal{F}$ 关于 Z 在分布 $\mathcal{D}$ 上的 Gauss 复杂度为

$$G_m(\mathcal{F}) = \mathbb{E}_{Z \subset \mathcal{Z}: |Z|=m} \left[\hat{G}_Z(\mathcal{F}) \right]. \quad (3.31)$$

Rademacher复杂度与前面介绍VC维用到的增长函数之间也具有一定的关系，首先引入定理 [Massart, 2000]：

定理 3.4 令 $A \subset \mathbb{R}^m$ 为有限集合且 $r = \max_{\mathbf{x} \in A} \|\mathbf{x}\|_2$ ，有

$$\mathbb{E}_{\sigma} \left[\frac{1}{m} \sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{r \sqrt{2 \ln |A|}}{m}, \quad (3.32)$$

其中 σ_i 为独立且符合 $\{-1, +1\}$ 上均匀分布的随机变量， x_i 为向量 $\mathbf{x}$ 的分量。

证明：对任意 $t > 0$ 使用 Jensen不等式 (1.8) 可得

$$\begin{aligned} \exp \left(t \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \right) &\leq \mathbb{E}_{\sigma} \left[\exp \left(t \sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right) \right] \\ &= \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \exp \left(t \sum_{i=1}^m \sigma_i x_i \right) \right] \\ &\leq \sum_{\mathbf{x} \in A} \mathbb{E}_{\sigma} \left[\exp \left(t \sum_{i=1}^m \sigma_i x_i \right) \right]. \end{aligned} \quad (3.33)$$

接着使用 σ 的独立性及Hoeffding不等式 (1.26) 可得

$$\begin{aligned}\exp \left(t \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \right) &\leq \sum_{\mathbf{x} \in A} \prod_{i=1}^m \mathbb{E}_{\sigma_i} [\exp(t \sigma_i x_i)] \\&\leq \sum_{\mathbf{x} \in A} \prod_{i=1}^m \exp \left(\frac{t^2 (2x_i)^2}{8} \right) \\&= \sum_{\mathbf{x} \in A} \exp \left(\frac{t^2}{2} \sum_{i=1}^m x_i^2 \right) \\&\leq \sum_{\mathbf{x} \in A} \exp \left(\frac{t^2 r^2}{2} \right) \\&= |A| \exp \left(\frac{t^2 r^2}{2} \right).\end{aligned}\tag{3.34}$$

对不等式两边取对数，可得

$$\mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{\ln |A|}{t} + \frac{tr^2}{2}. \quad (3.35)$$

当 $t = \frac{\sqrt{2 \ln |A|}}{r}$ 时右侧取最小值，即

$$\mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq r \sqrt{2 \ln |A|}. \quad (3.36)$$

两边除以 m 定理得证。

由定理 3.4 可得关于Rademacher复杂度与增长函数之间关系的推论：

推论 3.1 假设空间 $\mathcal{H}$ 的 Rademacher 复杂度 $R_m(\mathcal{H})$ 与增长函数 $\Pi_{\mathcal{H}}(m)$ 满足

$$R_m(\mathcal{H}) \leq \sqrt{\frac{2 \ln \Pi_{\mathcal{H}}(m)}{m}}. \quad (3.37)$$

证明： 对于 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $\mathcal{H}|_D$ 为假设空间 $\mathcal{H}$ 在 D 上的限制。由于 $h \in \mathcal{H}$ 的值域为 $\{-1, +1\}$, 可知 $\mathcal{H}|_D$ 中的元素为模长 $\sqrt{m}$ 的向量。因此, 由定理 3.4 可得

$$\begin{aligned} R_m(\mathcal{H}) &= \mathbb{E}_D \left[\mathbb{E}_{\boldsymbol{\sigma}} \left[\sup_{u \in \mathcal{H}|_D} \frac{1}{m} \sum_{i=1}^m \sigma_i u_i \right] \right] \\ &\leq \mathbb{E}_D \left[\frac{\sqrt{m} \sqrt{2 \ln |\mathcal{H}|_D}}{m} \right]. \end{aligned} \quad (3.38)$$

又因为 $|\mathcal{H}|_D| \leq \Pi_{\mathcal{H}}(m)$, 有

$$R_m(\mathcal{H}) \leq \mathbb{E}_D \left[\frac{\sqrt{m} \sqrt{2 \ln \Pi_{\mathcal{H}}(m)}}{m} \right] = \sqrt{\frac{2 \ln \Pi_{\mathcal{H}}(m)}{m}}, \quad (3.39)$$

定理得证。

线性超平面

对于二分类问题, 线性超平面假设空间 $\mathcal{H}$ 可以表示为

$$\left\{ h_{\mathbf{w},b} : h_{\mathbf{w},b}(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b) = \text{sign} \left(\left(\sum_{i=1}^d w_i x_i \right) + b \right) \right\}, \quad (3.40)$$

$b = 0$ 时为齐次线性超平面。

典型的线性超平面是将 $\mathbf{w}, b$ 放缩后, 满足 $\min_{(x,y) \in D} |\mathbf{w}^T \mathbf{x} + b| = 1$ 的 $(\mathbf{w}, b)$ 所构成的超平面。

对线性超平面进行VC维和Rademacher复杂度分析, 有

定理 3.5 $\mathbb{R}^d$ 空间中, 由齐次线性超平面构成的假设空间的 VC 维为 d .

证明：令 $e_1, \dots, e_d$ 表示 $\mathbb{R}^d$ 中的 d 个单位向量, $D = \{e_1, \dots, e_d\}$ 。对于任意 d 个标记 $y_1, \dots, y_d$, 取 $w = (y_1, \dots, y_d)$, 则有 $w^T e_i = y_i$, 所以 D 能被齐次线性超平面打散。

令 $D' = \{x_1, \dots, x_{d+1}\}$ 为 $\mathbb{R}^d$ 中任意 $d+1$ 个向量, 则必存在不全为 0 的实数 $a_1, \dots, a_{d+1}$ 使得 $\sum_{i=1}^{d+1} a_i x_i = 0$ 。令 $I = \{i : a_i > 0\}$, $J = \{j : a_j < 0\}$, 则 I, J 至少一个不为空集。首先假设两者都不为空集, 则有

$$\sum_{i \in I} a_i x_i = \sum_{j \in J} |a_j| x_j. \quad (3.41)$$

下面采用反证法。假设 D' 能被 $\mathcal{H}$ 打散, 则存在向量 w 使得 $w^T x_i > 0, i \in I$, 且 $w^T x_j < 0, j \in J$ 。由此可得

$$0 < \sum_{i \in I} a_i (x_i^T w) = \left(\sum_{i \in I} a_i x_i \right)^T w = \left(\sum_{j \in J} |a_j| x_j \right)^T w = \sum_{j \in J} |a_j| (x_j^T w) < 0. \quad (3.42)$$

此式矛盾, 即 D' 能被 $\mathcal{H}$ 打散不成立。当 I, J 只有一个不为空集时同理可证。

综上所述, $VC(\mathcal{H}) = d$, 定理得证。

定理 3.6 $\mathbb{R}^d$ 空间中, 由非齐次线性超平面构成的假设空间的 VC 维为 $d + 1$.

证明: 由定理 3.5 的证明可知 $D = \{0, \mathbf{e}_1, \dots, \mathbf{e}_d\}$ 能被非齐次线性超平面 $\mathcal{H}$ 打散。下面将非齐次线性超平面转化为齐次线性超平面:

$$\mathbf{w}^T \mathbf{x} + b = \mathbf{w}'^T \mathbf{x}, \quad \mathbf{w} \in \mathbb{R}^d, \mathbf{x} \in \mathbb{R}^d, \mathbf{w}' \in \mathbb{R}^{d+1}, \mathbf{x}' \in \mathbb{R}^{d+1}, \quad (3.43)$$

其中 $\mathbf{w}' = (\mathbf{w}; b)$, $\mathbf{x}' = (\mathbf{x}; 1)$ 。如果 $D' = \{\mathbf{x}_1, \dots, \mathbf{x}_{d+2}\}$ 能被 $\mathbb{R}^d$ 中非齐次线性超平面打散, 则 $D'' = \{\mathbf{x}'_1, \dots, \mathbf{x}'_{d+2}\}$ 能被 $\mathbb{R}^{d+1}$ 中齐次线性超平面打散, 这与定理 3.5 矛盾。

因此, 非齐次线性超平面的 VC 维为 $d + 1$ 。

线性超平面的假设空间复杂度不仅可基于VC维进行刻画，还可基于Rademacher复杂度刻画。但Rademacher复杂度与数据相关，因此在计算Rademacher复杂度时需要将分布 $\mathcal{D}$ 限制在某一范围内。

定理 3.7 令 $D \subset \{\mathbf{x} : \|\mathbf{x}\| \leq r\}$ 是大小为 m 的数据集，则典型超平面族 $\mathcal{H} = \{\mathbf{x} \mapsto \mathbf{w}^T \mathbf{x} : \|\mathbf{w}\| \leq \Lambda\}$ 的经验 Rademacher 复杂度满足

$$\hat{R}_D(\mathcal{H}) \leq \sqrt{\frac{r^2 \Lambda^2}{m}}. \quad (3.44)$$

不难发现，定理 3.7 只给出了Rademacher复杂度的上界。这是由于Rademacher复杂度依赖于数据分布，使得计算Rademacher复杂度的具体数值相当困难。

线性超平面的Rademacher复杂度

证明:

$$\begin{aligned}\hat{R}_D(\mathcal{H}) &= \frac{1}{m} \mathbb{E}_{\sigma} \left[\sup \sum_{i=1}^m \sigma_i \mathbf{w}^T \mathbf{x}_i \right] \\&= \frac{1}{m} \mathbb{E}_{\sigma} \left[\sup \mathbf{w}^T \sum_{i=1}^m \sigma_i \mathbf{x}_i \right] \\&\leq \frac{\Lambda}{m} \mathbb{E}_{\sigma} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\| \right] \\&\leq \frac{\Lambda}{m} \left[\mathbb{E}_{\sigma} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|^2 \right] \right]^{1/2} \\&= \frac{\Lambda}{m} \left[\mathbb{E}_{\sigma} \left[\sum_{i,j=1}^m \sigma_i \sigma_j (\mathbf{x}_i^T \mathbf{x}_j) \right] \right]^{1/2} \\&\leq \frac{\Lambda}{m} \left[\sum_{i=1}^m \|\mathbf{x}_i\|^2 \right]^{1/2} \\&\leq \sqrt{\frac{r^2 \Lambda^2}{m}},\end{aligned}\tag{3.45}$$

SVM

由于原样本空间往往是线性不可分的，SVM通常需要将原样本空间映射到可分的高维空间，并在高维空间中训练线性超平面进行分类。由定理 3.6 可知，若高维空间的维度为 d ，则在高维空间中SVM的VC维为 $d + 1$ 。

在实际运用中，映射后的高维空间维数通常很大甚至接近无穷，使得依赖空间维度的VC维失去了实际意义。这时就需要一种与空间维数无关的VC维进行刻画。虽然这种刻画方法与空间维数无关，但仍需要对超平面加以限制。

对于限制后的超平面可以得到下面的定理 [Vapnik, 1998]:

定理 3.8 令 $D \subset \{\mathbf{x} : \|\mathbf{x}\| \leq r\}$ ，超平面族 $\{\mathbf{x} \mapsto \text{sign}(\mathbf{w}^T \mathbf{x}) : \min_{\mathbf{x} \in D} |\mathbf{w}^T \mathbf{x}| = 1 \wedge \|\mathbf{w}\| \leq \Lambda\}$ 的 VC 维 d 满足下面的不等式

$$d \leq r^2 \Lambda^2. \quad (3.46)$$

证明： 令 $\{\mathbf{x}_1, \dots, \mathbf{x}_d\}$ 为能被超平面族打散的集合，则对于任意 $y = (y_1, \dots, y_d) \in \{-1, +1\}^d$ 存在 $\mathbf{w}$ 使得

$$y_i(\mathbf{w}^T \mathbf{x}_i) \geq 1, 1 \leq i \leq d. \quad (3.47)$$

对这些不等式求和可得

$$d \leq \mathbf{w}^T \sum_{i=1}^d y_i \mathbf{x}_i \leq \|\mathbf{w}\| \left\| \sum_{i=1}^d y_i \mathbf{x}_i \right\| \leq \Lambda \left\| \sum_{i=1}^d y_i \mathbf{x}_i \right\|. \quad (3.48)$$

由于式 (3.48) 对任意 $y \in \{-1, +1\}^d$ 都成立，对其两边按 $y_1, \dots, y_d$ 服从 $\{-1, +1\}$ 独立且均匀的分布取期望可得

$$\begin{aligned} d &\leq \Lambda \mathbb{E}_y \left[\left\| \sum_{i=1}^d y_i \mathbf{x}_i \right\|^2 \right] \\ &\leq \Lambda \left[\mathbb{E}_y \left[\left\| \sum_{i=1}^d y_i \mathbf{x}_i \right\|^2 \right] \right]^{1/2} \\ &= \Lambda \left[\sum_{i,j=1}^d \mathbb{E}_y[y_i y_j] (\mathbf{x}_i^T \mathbf{x}_j) \right]^{1/2} \\ &= \Lambda \left[\sum_{i=1}^d (\mathbf{x}_i \cdot \mathbf{x}_i) \right]^{1/2} \\ &\leq \Lambda [dr^2]^{1/2} \\ &= \Lambda r \sqrt{d}, \end{aligned} \tag{3.49}$$

从而可知, $\sqrt{d} \leq \Lambda r$, 定理得证。

分析实例之三 (以多层神经网络为例)

多层神经网络

在多分类情况下, 当标记集合为 $\mathcal{Y}$ 时, 函数族 $\mathcal{F} \subset \mathcal{Y}^{\mathcal{X}}$ 的增长函数有如下性质:

$$\Pi_{\mathcal{F}}(m) = \max_{D \subset \mathcal{X}} |\mathcal{F}|_D, \quad (3.50)$$

其中 D 是大小为 m 且独立同分布从 $\mathcal{X}$ 中采样得到的训练集, 易知 $\Pi_{\mathcal{F}}(m) \leq |\mathcal{Y}|^m$.

引理 3.2 令 $\mathcal{F}^{(1)} \subset \mathcal{Y}_1^{\mathcal{X}}$, $\mathcal{F}^{(2)} \subset \mathcal{Y}_2^{\mathcal{X}}$ 为两个函数族, $\mathcal{F} = \mathcal{F}^{(1)} \times \mathcal{F}^{(2)}$ 为它们的笛卡尔积, 有

$$\Pi_{\mathcal{F}}(m) \leq \Pi_{\mathcal{F}^{(1)}}(m) \cdot \Pi_{\mathcal{F}^{(2)}}(m) \quad (3.51)$$

分析实例之三 (以多层神经网络为例)

引理 3.2 令 $\mathcal{F}^{(1)} \subset \mathcal{Y}_1^{\mathcal{X}}$, $\mathcal{F}^{(2)} \subset \mathcal{Y}_2^{\mathcal{X}}$ 为两个函数族, $\mathcal{F} = \mathcal{F}^{(1)} \times \mathcal{F}^{(2)}$ 为它们的笛卡尔积, 有

$$\Pi_{\mathcal{F}}(m) \leq \Pi_{\mathcal{F}^{(1)}}(m) \cdot \Pi_{\mathcal{F}^{(2)}}(m) \quad (3.51)$$

证明: 对于大小为 m 且独立同分布从 $\mathcal{X}$ 中采样得到的训练集 $D \subset \mathcal{X}$, 根据笛卡尔积的定义可知

$$\begin{aligned} |\mathcal{F}|_D &= \left| \mathcal{F}_{|D}^{(1)} \right| \left| \mathcal{F}_{|D}^{(2)} \right| \\ &\leq \Pi_{\mathcal{F}^{(1)}}(m) \cdot \Pi_{\mathcal{F}^{(2)}}(m). \end{aligned} \quad (3.52)$$

由 D 的任意性, 引理得证。

分析实例之三 (以多层神经网络为例)

引理 3.3 令 $\mathcal{F}^{(1)} \subset \mathcal{Y}_1^{\mathcal{X}}$, $\mathcal{F}^{(2)} \subset \mathcal{Y}_2^{\mathcal{X}}$ 为两个函数族, $\mathcal{F} = \mathcal{F}^{(2)} \circ \mathcal{F}^{(1)}$ 为它们的复合函数族, 有

$$\Pi_{\mathcal{F}}(m) \leq \Pi_{\mathcal{F}^{(2)}}(m) \cdot \Pi_{\mathcal{F}^{(1)}}(m). \quad (3.53)$$

证明: 对于大小为 m 且独立同分布从 $\mathcal{X}$ 中采样得到的训练集 $D \subset \mathcal{X}$, 根据笛卡尔积的定义可知

$$\begin{aligned} \mathcal{F}|_D &= \left\{ \left(f_2(f_1(\mathbf{x}_1)), \dots, f_2(f_1(\mathbf{x}_m)) \right) \mid f_1 \in \mathcal{F}^{(1)}, f_2 \in \mathcal{F}^{(2)} \right\} \\ &= \bigcup_{\mathbf{u}_i \in \mathcal{F}|_D^{(1)}} \left\{ \left(f_2(\mathbf{u}_1), \dots, f_2(\mathbf{u}_m) \right) \mid f_2 \in \mathcal{F}^{(2)} \right\}. \end{aligned} \quad (3.54)$$

分析实例之三 (以多层神经网络为例)

因此有

$$\begin{aligned} |\mathcal{F}_{|D}| &\leq \sum_{\mathbf{u}_i \in \mathcal{F}_{|D}^{(1)}} \left| \left\{ (f_2(\mathbf{u}_1), \dots, f_2(\mathbf{u}_m)) \mid f_2 \in \mathcal{F}^{(2)} \right\} \right| \\ &\leq \sum_{\mathbf{u}_i \in \mathcal{F}_{|D}^{(1)}} \Pi_{\mathcal{F}^{(2)}}(m) \\ &= \left| \mathcal{F}_{|D}^{(1)} \right| \cdot \Pi_{\mathcal{F}^{(2)}}(m) \\ &\leq \Pi_{\mathcal{F}^{(2)}}(m) \cdot \Pi_{\mathcal{F}^{(1)}}(m). \end{aligned} \tag{3.55}$$

由 D 的任意性, 引理得证。

分析实例之三 (以多层神经网络为例)

一般来说, 神经网络中的每个结点 v 计算一个函数

$$\varphi\left((\mathbf{w}^{(v)})^T \mathbf{x} - \theta^{(v)}\right), \quad (3.56)$$

其中 φ 被称为激活函数, $\mathbf{w}^{(v)}$ 是与结点 v 相关的权值参数, $\theta^{(v)}$ 是与结点 v 相关的阈值参数, φ 以 $\mathbf{x}$ 为输入, 输出激活信号。本节主要考虑使用符号激活函数 $\varphi(t) = \text{sign}(t)$ 的多层神经网络。假设输入空间 $\mathcal{X} = \mathbb{R}^{d_0}$, 一个 l 层的多层网络可以简化为一系列映射的复合:

$$f_l \circ \cdots \circ f_2 \circ f_1(\mathbf{x}), \quad (3.57)$$

其中

$$\begin{aligned} f_i &: \mathbb{R}^{d_{i-1}} \mapsto \{\pm 1\}^{d_i}, 1 \leq i \leq l-1 \\ f_l &: \mathbb{R}^{d_{l-1}} \mapsto \{\pm 1\}. \end{aligned} \quad (3.58)$$

分析实例之三 (以多层神经网络为例)

f_i 是一个多维到多维的映射, 可以将其分解为若干个二值多元函数, 对于 f_i 的每个分量 $f_{i,j} : \mathbb{R}^{d_i-1} \mapsto \{\pm 1\}$ 表示为:

$$f_{i,j}(\mathbf{u}) = \text{sign} \left((\mathbf{w}^{i,j})^T \cdot \mathbf{u} - \theta^{i,j} \right), \quad (3.59)$$

其中 $\mathbf{w}^{i,j} \in \mathbb{R}^{d_i-1}$, $\theta^{i,j} \in \mathbb{R}$ 分别为关于第 i 层第 j 个结点的权值参数与阈值参数, 将多元函数 $f_{i,j}(\mathbf{u})$ 的函数族记为 $\mathcal{F}^{(i,j)}$, 关于第 i 层的函数族可以表示为

$$\mathcal{F}^{(i)} = \mathcal{F}^{(i,1)} \times \dots \times \mathcal{F}^{(i,d_i)}, \quad (3.60)$$

从而整个多层神经网络的函数族可以表示为

$$\mathcal{F} = \mathcal{F}^{(l)} \circ \dots \circ \mathcal{F}^{(2)} \circ \mathcal{F}^{(1)}. \quad (3.61)$$

分析实例之三 (以多层神经网络为例)

根据引理 3.1, 引理 3.2 和定理 3.1 可得

$$\begin{aligned}\Pi_{\mathcal{F}}(m) &\leq \prod_{i=1}^l \Pi_{\mathcal{F}^{(i)}}(m) \leq \prod_{i=1}^l \prod_{j=1}^{d_i} \Pi_{\mathcal{F}^{(i,j)}}(m) \\ &\leq \prod_{i=1}^l \prod_{j=1}^{d_i} \left(\frac{e \cdot m}{d_{i-1} + 1} \right)^{d_{i-1} + 1}.\end{aligned}\quad (3.62)$$

令

$$N = \sum_{i=1}^l \sum_{j=1}^{d_i} (d_{i-1} + 1) \quad (3.63)$$

表示整个多层神经网络的参数数目, 可以将式 (3.62) 化简为

$$\Pi_{\mathcal{F}}(m) \leq (e \cdot m)^N, \quad (3.64)$$

进一步可以计算出 $\mathcal{F}$ 的 VC 维的界:

定理 3.9 令 $\mathcal{F}$ 表示对应多层神经网络的函数族, 其 VC 维 $VC(\mathcal{F}) = O(N \log_2(N))$.

证明: 假设能被 $\mathcal{F}$ 打散的最大样本集大小为 d , 则 $\Pi_{\mathcal{F}}(d) = 2^d$, 由式 (3.64) 可得

$$2^d \leq (de)^N, \quad (3.65)$$

化简得知 $d = O(N \log_2(N))$, 定理得证。