

统计学习理论

泛化性

前言

对于学习算法来说, 判断其性能好坏的依据是泛化误差, 即学习算法基于训练数据学习得到的模型在未见数据上的预测能力.

由第2章介绍的PAC学习理论可知, 泛化误差的大小会依赖于学习算法所考虑的假设空间及训练集的大小, 这使得评估学得模型的泛化误差较为困难.

一般来说, 泛化误差与学习算法 $\mathcal{L}$ 所考虑的假设空间 $\mathcal{H}$ 、训练集大小 m 以及数据分布 $\mathcal{D}$ 有关.

到底是如何相关的呢? 本章就来讨论这一重要问题. 下面将按照泛化误差上界和下界分别展开讨论.

泛化误差上界

由第二章内容可知，假设空间 $\mathcal{H}$ 可分为：

- 有限假设空间
- 无限假设空间

根据目标概念 c 是否在 $\mathcal{H}$ 中又可以分为：

- 可分情况
 - 不可分情况
-

有限假设空间的可分情况

可分情况

可分意味着目标概念 c 属于假设空间 $\mathcal{H}$, 即 $c \in \mathcal{H}$.

一个简单的策略:

对于可分的有限假设空间, 任何在训练集 D 上犯错的概念都不是目标概念.
剔除在训练集上犯错的概念.

最终留下的是和数据集 D 一致的假设, 显然目标概念也在其中.

如果 D 足够大, 甚至是包含了所有样本, 则最终剩下的假设就是目标概念. 然而实际情况中 D 通常是有限的, 最终, 假设空间 $\mathcal{H}$ 中会存在不止一个和 D 一致的“等效”假设, 一般很难通过 D 进行进一步区分.

无法强求通过训练集 D 精确地找到目标概念, 在 PAC 框架中, 只要训练集 D 的规模能使得学习算法 $\mathcal{L}$ 以 $1 - \delta$ 的概率找到目标假设的 ϵ 近似即可.

有限可分情况的泛化误差界

当 $\mathcal{H}$ 为可分得有限假设空间时，有下面的定理成立：

定理 4.1 令 $\mathcal{H}$ 为可分的有限假设空间, D 为从 $\mathcal{D}$ 独立同分布采样得到大小为 m 的训练集, 学习算法 $\mathcal{L}$ 基于训练集 D 输出与训练集一致的假设 $h \in \mathcal{H}$, 对于任意 $c \in \mathcal{H}$, $0 < \epsilon, \delta < 1$, 若 $m \geq \frac{1}{\epsilon}(\ln |\mathcal{H}| + \ln \frac{1}{\delta})$, 则有

$$P(E(h) \leq \epsilon) \geq 1 - \delta, \quad (4.1)$$

即 $E(h) \leq \epsilon$ 以至少 $1 - \delta$ 的概率成立.

参见 2.2 节, m 被称为学习算法 $\mathcal{L}$ 的样本复杂度, 不难发现这里的 m 是关于 $1/\delta$ 和 $1/\epsilon$ 的多项式, 因此有限可分的假设空间 $\mathcal{H}$ 是 PAC 可学习的.

定理表明, 当假设空间 $\mathcal{H}$ 是有限可分时:

输出假设的泛化误差依赖于假设空间的大小 $|\mathcal{H}|$ 和训练集的大小 m .

随着训练集样本数目增加, 泛化误差的上界逐渐收敛于0, 收敛率是 $O(1/m)$.

有限假设空间的不可分情况

不可分情况:

不可分意味着目标概念 c 不属于假设空间 $\mathcal{H}$, 或者目标概念不存在

不可分情况中, 假设空间中的每个假设都会有或多或少的错误.

我们不再奢望找到目标概念的 ϵ 近似, 而是希望找到假设空间中泛化误差最小假设的 ϵ 近似

对于学习算法输出的假设 h 来说, 泛化误差是其在未见数据上的预测能力, 无法直接观测得到, 但其在训练数据上的经验误差是可以直接观测得到的.

有限不可分情况的泛化误差界

第二章的定理2.1探讨了泛化误差与经验误差之间的关系, 表明当训练集中样本数目 m 较大时, h 的经验误差是泛化误差的较好近似. 基于这一关系, 可以给出下面的定理:

定理 4.2 令 $\mathcal{H}$ 为有限假设空间, D 为从 $\mathcal{D}$ 独立同分布采样得到大小为 m 的训练集, 学习算法 $\mathcal{L}$ 基于训练集 D 输出的假设为 h , 对于 $0 < \delta < 1$ 有

$$P \left(\left| E(h) - \hat{E}(h) \right| \leq \sqrt{\frac{\ln |\mathcal{H}| + \ln(2/\delta)}{2m}} \right) \geq 1 - \delta. \quad (4.5)$$

$\sqrt{\frac{\ln |\mathcal{H}| + \ln(2/\delta)}{2m}} = O(1/\sqrt{m})$, 有限不可分的情况下, 收敛率为 $O(1/\sqrt{m})$.

与可分的情况相比, 收敛速度较慢.

无限假设空间

实际任务中, 假设空间通常是无限的.

对于无限假设空间, 可以从VC维以及Rademacher复杂度的角度来研究其泛化界.

对于基于VC维的泛化误差界, 主要讨论有限VC维的情况.

有限VC维假设空间的泛化误差界

基于引理4.1, 再结合关于 VC 维与增长函数之间关系的定理3.1, 有

定理 4.3 若假设空间 $\mathcal{H}$ 的 VC 维为 d , 对于 $h \in \mathcal{H}$, $m > d$ 和 $0 < \delta < 1$ 有

$$P \left(\left| E(h) - \hat{E}(h) \right| \leq \sqrt{\frac{8d \ln \frac{2em}{d} + 8 \ln \frac{4}{\delta}}{m}} \right) \geq 1 - \delta. \quad (4.23)$$

由定理4.3可知 $E(h) \leq \hat{E}(h) + O\left(\sqrt{\frac{\ln(m/d)}{m/d}}\right)$ 以 $1 - \delta$ 的概率成立, 泛化误差的收敛率为 $O(\sqrt{\frac{\ln(m/d)}{m/d}})$, (这里忽略 δ 和常数项)

有限VC维假设空间的收敛率与VC维的大小有关, VC维越大, 假设空间越复杂, 泛化误差的收敛速率也越慢

收敛率与 $O(\sqrt{\frac{1}{m}})$ 相比可知, 有限VC维的不可分假设空间比有限不可分假设空间更难收敛, 这也是有限假设空间与无限假设空间的区别.

基于Rademacher复杂度的泛化误差界

除了有基于VC维的泛化误差界, 也有基于Rademacher复杂度的泛化误差界.

先来回顾一下Rademacher复杂度的相关定义.

函数空间 $\mathcal{F}$ 关于训练集 Z 的经验Rademacher复杂度:

$$\hat{\mathfrak{R}}_Z(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right]$$

函数空间 $\mathcal{F}$ 关于 Z 上分布 $\mathcal{D}$ 的Rademacher复杂度:

$$\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_{Z \subset \mathcal{Z}: |Z|=m} \left[\hat{R}_Z(\mathcal{F}) \right]$$

数据分布相关

VC维

VC维的定义与数据分布无关。因此基于VC维的分析结果是分布无关、数据独立的，也就是说对任意数据分布都成立。

- 一方面，基于VC维的分析结果具有一定的“普适性”；
- 另一方面，由于没有考虑数据自身，基于VC维的分析结果通常比较“松”，对那些与学习问题的典型情况相差甚远的较“坏”分布来说尤其如此。

Rademacher 复杂度

- 是另一种刻画假设空间复杂度的工具；
 - 与VC维不同的是，它在一定程度上考虑了数据分布。
-

给定数据集 $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$, 假设 h 的经验误差为

$$\begin{aligned}\hat{E}(h) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(\mathbf{x}_i) \neq y_i) \\ &= \frac{1}{m} \sum_{i=1}^m \frac{1 - y_i h(\mathbf{x}_i)}{2} \\ &= \frac{1}{2} - \frac{1}{2m} \sum_{i=1}^m y_i h(\mathbf{x}_i).\end{aligned}\tag{3.23}$$

其中 $\frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i)$ 体现了预测值 $h(\mathbf{x}_i)$ 与样例真实标记 y_i 之间的一致性, 若 $h(\mathbf{x}_i) = y_i, 1 \leq i \leq m$, 则 $\frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i)$ 取得最大值 1, 也就是说具有最小经验误差的假设是

$$\arg \max_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m y_i h(\mathbf{x}_i).\tag{3.24}$$

Rademacher随机变量

现实任务中样例的标记有时会受到噪声的影响，即对某些样例 $(\mathbf{x}_i, y_i)$ 来说，其 y_i 或许已经受到随机因素的影响，不再是 $\mathbf{x}_i$ 的真实标记。在此情形下，选择假设空间 $\mathcal{H}$ 中在训练集上表现最好的假设，有时还不如选择 $\mathcal{H}$ 中事先已考虑了随机噪声的假设。

Rademacher随机变量

考虑随机变量 σ_i ，它以 0.5 的概率取值 -1 ，以 0.5 的概率取值 $+1$ ，称其为 Rademacher 随机变量。基于 σ_i 可将 (3.24) 改写为

$$\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i). \quad (3.25)$$

对所有的 σ_i 求期望可得

$$\mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) \right]. \quad (3.26)$$

Rademacher随机变量

$$\mathbb{E}_{\boldsymbol{\sigma}} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) \right] . \quad (3.26)$$

式 (3.26) 和增长函数有着相似的作用，体现了假设空间在数据集 D 上的表示能力，取值范围为 $[0, 1]$ 。当式 (3.26) 取值为 1 时，意味着对任意 $\boldsymbol{\sigma} = \{\sigma_1, \dots, \sigma_m\}$ $\sigma_i \in \{-1, +1\}$ ，有

$$\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i) = 1 . \quad (3.27)$$

在有限假设空间的情况下，即 $\exists h \in \mathcal{H}$, s.t. $h(\mathbf{x}_i) = \sigma_i, 1 \leq i \leq m$ ，类似于 $|\mathcal{H}|_D = 2^m$ ，也就有 $\Pi_{\mathcal{H}}(m) = 2^m$ ，即 $\mathcal{H}$ 能打散 D 。

总的来说，式 (3.26) 的值越接近 1，假设空间的表示能力越强。

经验Rademacher复杂度 [Koltchinskii, 2001]

考虑实值函数空间 $\mathcal{F} : \mathcal{Z} \rightarrow \mathbb{R}$, 令 $Z = \{z_1, \dots, z_m\}$, 其中 $z_i \in \mathcal{Z}$, 将式(3.27) 中的 $\mathcal{X}$ 和 $\mathcal{H}$ 替换为 $\mathcal{Z}$ 和 $\mathcal{F}$ 可得 [Koltchinskii, 2001]

定义 3.3 函数空间 $\mathcal{F}$ 关于 Z 的经验 Rademacher 复杂度为

$$\hat{R}_Z(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right]. \quad (3.28)$$

这里的 Z 是一个给定的集合。经验Rademacher复杂度衡量了函数空间 $\mathcal{F}$ 与随机噪声在数据集 Z 中的相关性。

Rademacher复杂度

对从分布 $\mathcal{D}$ 独立同分布采样得到的大小为 m 的集合 Z 求期望可得

定义 3.4 函数空间 $\mathcal{F}$ 关于 Z 在分布 $\mathcal{D}$ 上的 Rademacher 复杂度为

$$R_m(\mathcal{F}) = \mathbb{E}_{Z \subset \mathcal{Z}: |Z|=m} \left[\hat{R}_Z(\mathcal{F}) \right]. \quad (3.29)$$

- Rademacher复杂度依赖于具体学习问题及数据分布，是为具体学习问题量身定制的。
 - 基于Rademacher复杂度可以比基于VC维推导出更紧的泛化误差界。
 - 需要注意到，在Rademacher复杂度的定义中 σ 是 $\{-1, +1\}$ 上服从均匀分布的随机变量。如果将均匀分布改为其他分布，会得到其他一些复杂度的定义。
-

Rademacher复杂度

经验Gauss复杂度 [Bartlett and Mendelson, 2003]

定义 3.5 函数空间 $\mathcal{F}$ 关于 Z 的经验 Gauss 复杂度为

$$\hat{G}_Z(\mathcal{F}) = \mathbb{E}_{\mathbf{g}} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m g_i f(z_i) \right], \quad (3.30)$$

其中 $\mathbf{g} = \{g_1, \dots, g_m\}$ 服从高斯分布，即标准正态分布。

Gauss复杂度：对经验Gauss复杂度求期望可得

定义 3.6 函数空间 $\mathcal{F}$ 关于 Z 在分布 $\mathcal{D}$ 上的 Gauss 复杂度为

$$G_m(\mathcal{F}) = \mathbb{E}_{Z \subset \mathcal{Z}: |Z|=m} \left[\hat{G}_Z(\mathcal{F}) \right]. \quad (3.31)$$

基于Rademacher复杂度的泛化误差界

对于基于Rademacher复杂度的泛化误差界, 有如下定理成立:

定理 4.4 对于实值函数空间 $\mathcal{F} : \mathcal{Z} \mapsto [0, 1]$, 从分布 $\mathcal{D}$ 独立同分布采样得到的大小为 m 的训练集 $Z = \{z_1, z_2, \dots, z_m\}$, $z_i \in \mathcal{Z}$, $f \in \mathcal{F}$ 和 $0 < \delta < 1$, 以至少 $1 - \delta$ 的概率有

$$\mathbb{E}[f(z)] \leq \frac{1}{m} \sum_{i=1}^m f(z_i) + 2\mathfrak{R}_m(\mathcal{F}) + \sqrt{\frac{\ln(1/\delta)}{2m}}, \quad (4.26)$$

$$\mathbb{E}[f(z)] \leq \frac{1}{m} \sum_{i=1}^m f(z_i) + 2\hat{\mathfrak{R}}_Z(\mathcal{F}) + 3\sqrt{\frac{\ln(2/\delta)}{2m}}. \quad (4.27)$$

重要不等式

【McDiarmid 不等式】 对 m 个独立随机变量 $X_i \in \mathcal{X}$ ($i = 1, \dots, m$), 若 $f: \mathcal{X}^m \rightarrow \mathbb{R}$ 是关于 X_i 的实值函数且 $\forall x_1, \dots, x_m, x'_i \in \mathcal{X}$ 都有

$$|f(x_1, \dots, x_i, \dots, x_m) - f(x_1, \dots, x'_i, \dots, x_m)| \leq c_i ,$$

则 $\forall \epsilon > 0$ 有

$$P(f(X_1, \dots, X_m) - \mathbb{E}[f(X_1, \dots, X_m)] \geq \epsilon) \leq e^{-2\epsilon^2 / \sum_{i=1}^m c_i^2} . \quad (1.25)$$

【Bennett 不等式】 对 m 个独立同分布的随机变量 X_i ($i = 1, \dots, m$), 令 $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$, 若 $X_i - \mathbb{E}[X_i] \leq 1$, 则有

$$P(\bar{X} \geq \mathbb{E}[\bar{X}] + \epsilon) \leq \exp\left(\frac{-m\epsilon^2}{2\mathbb{V}[X_1] + 2\epsilon/3}\right) .$$

定理4.4证明

证明 令

$$\hat{E}_Z(f) = \frac{1}{m} \sum_{i=1}^m f(\mathbf{z}_i) , \quad (4.28)$$

$$\Phi(Z) = \sup_{f \in \mathcal{F}} \left(\mathbb{E}[f] - \hat{E}_Z(f) \right) , \quad (4.29)$$

Z' 为只与 Z 有一个示例不同的训练集, 不妨设 $\mathbf{z}_m \in Z$ 和 $\mathbf{z}'_m \in Z'$ 为不同示例, 可得

$$\begin{aligned} \Phi(Z') - \Phi(Z) &= \sup_{f \in \mathcal{F}} \left(\mathbb{E}[f] - \hat{E}_{Z'}(f) \right) - \sup_{f \in \mathcal{F}} \left(\mathbb{E}[f] - \hat{E}_Z(f) \right) \\ &\leq \sup_{f \in \mathcal{F}} \left(\hat{E}_Z(f) - \hat{E}_{Z'}(f) \right) \\ &= \sup_{f \in \mathcal{F}} \frac{f(\mathbf{z}_m) - f(\mathbf{z}'_m)}{m} \\ &\leq \frac{1}{m}. \end{aligned} \quad (4.30)$$

定理4.4证明

同理可得

$$\Phi(Z) - \Phi(Z') \leq \frac{1}{m}, \quad (4.31)$$

$$|\Phi(Z) - \Phi(Z')| \leq \frac{1}{m}. \quad (4.32)$$

根据 McDiarmid 不等式 (1.30) 可知, 对于 $0 < \delta < 1$,

$$\Phi(Z) \leq \mathbb{E}_Z [\Phi(Z)] + \sqrt{\frac{\ln(1/\delta)}{2m}} \quad (4.33)$$

以至少 $1 - \delta$ 的概率成立. 下面估计 $\mathbb{E}_Z[\Phi(Z)]$ 的上界

$$P(f(X_1, \dots, X_m) - \mathbb{E}[f(X_1, \dots, X_m)] \geq \epsilon) \leq e^{-2\epsilon^2 / \sum_{i=1}^m c_i^2}, \quad (1.30)$$

定理4.4证明

利用 Jensen 不等式
(1.11) .

$\sigma = (\sigma_1, \dots, \sigma_m)$, $\sigma_i \in \{-1, +1\}$.

$$\begin{aligned}
 \mathbb{E}_Z [\Phi(Z)] &= \mathbb{E}_Z \left[\sup_{f \in \mathcal{F}} \left(\mathbb{E}[f] - \widehat{E}_Z(f) \right) \right] \\
 &= \mathbb{E}_Z \left[\sup_{f \in \mathcal{F}} \mathbb{E}_{Z'} \left[\widehat{E}_{Z'}[f] - \widehat{E}_Z[f] \right] \right] \\
 &\leq \mathbb{E}_{Z, Z'} \left[\sup_{f \in \mathcal{F}} \left(\widehat{E}_{Z'}[f] - \widehat{E}_Z[f] \right) \right] \\
 &= \mathbb{E}_{Z, Z'} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m (f(z'_i) - f(z_i)) \right] \\
 &= \mathbb{E}_{\sigma, Z, Z'} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i (f(z'_i) - f(z_i)) \right] \\
 &\leq \mathbb{E}_{\sigma, Z'} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z'_i) \right] + \mathbb{E}_{\sigma, Z} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m -\sigma_i f(z_i) \right] \\
 &= 2\mathbb{E}_{\sigma, Z} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right] \\
 &= 2\mathfrak{R}_m(\mathcal{F}) .
 \end{aligned} \tag{4.34}$$

由 (4.28), (4.29), (4.33) 和 (4.34) 可知 (4.26) 得证.

定理4.4证明

Z' 为只与 Z 有一个示例不同的训练集, $z_m \in Z$ 和 $z'_m \in Z'$ 为不同示例, 由经验 Rademacher 复杂度定义 3.4 和 (4.30) 可知替换训练集中的一个样例后经验 Rademacher 复杂度最多改变 $1/m$, 即

$$|\hat{\mathfrak{R}}_Z(f) - \hat{\mathfrak{R}}_{Z'}(f)| \leq \frac{1}{m} . \quad (4.35)$$

再根据 McDiarmid 不等式 (1.31) 可知

$$\mathfrak{R}_m(\mathcal{F}) \leq \hat{\mathfrak{R}}_Z(f) + \sqrt{\frac{\ln(2/\delta)}{2m}} \quad (4.36)$$

以至少 $1 - \delta/2$ 的概率成立, 并且

$$\Phi(Z) \leq \mathbb{E}_Z[\Phi(Z)] + \sqrt{\frac{\ln(2/\delta)}{2m}} \quad (4.37)$$

以至少 $1 - \delta/2$ 的概率成立. 由 (4.34), (4.36), (4.37) 和 Union Bound (1.19) 可知

$$\Phi(Z) \leq 2\hat{\mathfrak{R}}_Z(\mathcal{F}) + 3\sqrt{\frac{\ln(2/\delta)}{2m}} \quad (4.38)$$

以至少 $1 - \delta$ 的概率成立, 从而 (4.27) 得证. $\square$

$$P(f(X_1, \dots, X_m) - \mathbb{E}[f(X_1, \dots, X_m)] \leq -\epsilon) \leq e^{-2\epsilon^2 / \sum_{i=1}^m c_i^2} . \quad (1.31)$$

分类基于Rademacher复杂度的泛化误差界

定理4.4适用的范围是函数空间 $\mathcal{F} : \mathcal{Z} \rightarrow [0, 1]$, 一般使用在回归问题中. 对于分类问题, 可以得到如下的泛化误差界:

定理 4.5 对于假设空间 $\mathcal{H} : \mathcal{X} \mapsto \{-1, +1\}$, 从分布 $\mathcal{D}$ 独立同分布采样得到的大小为 m 的训练集 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $\mathbf{x}_i \in \mathcal{X}$, $h \in \mathcal{H}$ 和 $0 < \delta < 1$, 以至少 $1 - \delta$ 的概率有

$$E(h) \leq \hat{E}(h) + \mathfrak{R}_m(\mathcal{H}) + \sqrt{\frac{\ln(1/\delta)}{2m}}, \quad (4.39)$$

$$E(h) \leq \hat{E}(h) + \hat{\mathfrak{R}}_D(\mathcal{H}) + 3\sqrt{\frac{\ln(2/\delta)}{2m}}. \quad (4.40)$$

定理4.5证明

证明 对于二分类问题的假设空间 $\mathcal{H}$, 令 $\mathcal{Z} = \mathcal{X} \times \{-1, +1\}$, $\mathcal{H}$ 中的假设 h 可以变形为

$$f_h(\mathbf{z}) = f_h(\mathbf{x}, y) = \mathbb{I}(h(\mathbf{x}) \neq y) . \quad (4.41)$$

于是值域为 $\{-1, +1\}$ 的假设空间 $\mathcal{H}$ 转化为值域为 $[0, 1]$ 的函数空间 $\mathcal{F}_{\mathcal{H}} = \{f_h : h \in \mathcal{H}\}$. 根据经验 Rademacher 复杂度的定义 3.4 可知

定理4.5证明

$$\begin{aligned}\hat{\mathfrak{R}}_Z(\mathcal{F}_{\mathcal{H}}) &= \mathbb{E}_{\sigma} \left[\sup_{f_h \in \mathcal{F}_{\mathcal{H}}} \frac{1}{m} \sum_{i=1}^m \sigma_i f_h(\mathbf{x}_i, y_i) \right] \\ &= \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i \mathbb{I}(h(\mathbf{x}_i) \neq y_i) \right] \\ &= \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i \frac{1 - y_i h(\mathbf{x}_i)}{2} \right] \\ &= \frac{1}{2} \mathbb{E}_{\sigma} \left[\frac{1}{m} \sum_{i=1}^m \sigma_i + \sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m (-y_i \sigma_i h(\mathbf{x}_i)) \right] \\ &= \frac{1}{2} \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m (-y_i \sigma_i h(\mathbf{x}_i)) \right] \\ &= \frac{1}{2} \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m (\sigma_i h(\mathbf{x}_i)) \right] \\ &= \frac{1}{2} \hat{\mathfrak{R}}_D(\mathcal{H}).\end{aligned}\tag{4.42}$$

由于 $y_i \in \{-1, +1\}$,
 $-y_i \sigma_i$ 等价于 σ_i .

同时对上式两边取期望可得

$$\mathfrak{R}_Z(\mathcal{F}_{\mathcal{H}}) = \frac{1}{2} \mathfrak{R}_D(\mathcal{H}).\tag{4.43}$$

将 (4.43) 代入定理 4.4, 定理得证.

□

Rademacher复杂度与增长函数

Rademacher复杂度与前面介绍VC维用到的增长函数之间也具有一定的关系，首先引入定理 [Massart, 2000]：

定理 3.4 令 $A \subset \mathbb{R}^m$ 为有限集合且 $r = \max_{\mathbf{x} \in A} \|\mathbf{x}\|_2$ ，有

$$\mathbb{E}_{\boldsymbol{\sigma}} \left[\frac{1}{m} \sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{r \sqrt{2 \ln |A|}}{m}, \quad (3.32)$$

其中 σ_i 为独立且符合 $\{-1, +1\}$ 上均匀分布的随机变量， x_i 为向量 $\mathbf{x}$ 的分量。

增长函数 (growth function)

增长函数 (growth function)

对于 $m \in \mathbb{N}$, 假设空间 $\mathcal{H}$ 的增长函数 $\Pi_{\mathcal{H}}(m)$ 表示为

$$\Pi_{\mathcal{H}}(m) = \max_{\{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}} |\{h(\mathbf{x}_1), \dots, h(\mathbf{x}_m) | h \in \mathcal{H}\}|. \quad (3.2)$$

利用限制的定義，可以記為

$$\Pi_{\mathcal{H}}(m) = \max_{|D|=m} |\mathcal{H}|_D. \quad (3.3)$$

增长函数表示假设空间对个示例所能赋予标记的最大可能的结果数。

增长函数在一定程度上描述了假设空间的表达能力，反映了假设空间的复杂程度！

Rademacher复杂度与增长函数

证明： 对任意 $t > 0$ 使用 Jensen不等式 (1.8) 可得

$$\begin{aligned} \exp \left(t \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \right) &\leq \mathbb{E}_{\sigma} \left[\exp \left(t \sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right) \right] \\ &= \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \exp \left(t \sum_{i=1}^m \sigma_i x_i \right) \right] \\ &\leq \sum_{\mathbf{x} \in A} \mathbb{E}_{\sigma} \left[\exp \left(t \sum_{i=1}^m \sigma_i x_i \right) \right]. \end{aligned} \tag{3.33}$$

Rademacher复杂度与增长函数

接着使用 σ 的独立性及Hoeffding不等式 (1.26) 可得

$$\begin{aligned}\exp \left(t \mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \right) &\leq \sum_{\mathbf{x} \in A} \prod_{i=1}^m \mathbb{E}_{\sigma_i} [\exp(t \sigma_i x_i)] \\ &\leq \sum_{\mathbf{x} \in A} \prod_{i=1}^m \exp \left(\frac{t^2 (2x_i)^2}{8} \right) \\ &= \sum_{\mathbf{x} \in A} \exp \left(\frac{t^2}{2} \sum_{i=1}^m x_i^2 \right) \\ &\leq \sum_{\mathbf{x} \in A} \exp \left(\frac{t^2 r^2}{2} \right) \\ &= |A| \exp \left(\frac{t^2 r^2}{2} \right).\end{aligned}\tag{3.34}$$

Rademacher复杂度与增长函数

对不等式两边取对数，可得

$$\mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{\ln |A|}{t} + \frac{tr^2}{2}. \quad (3.35)$$

当 $t = \frac{\sqrt{2 \ln |A|}}{r}$ 时右侧取最小值，即

$$\mathbb{E}_{\sigma} \left[\sup_{\mathbf{x} \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq r \sqrt{2 \ln |A|}. \quad (3.36)$$

两边除以 m 定理得证。

Rademacher复杂度与增长函数

由定理 3.4 可得关于Rademacher复杂度与增长函数之间关系的推论：

推论 3.1 假设空间 $\mathcal{H}$ 的 Rademacher 复杂度 $R_m(\mathcal{H})$ 与增长函数 $\Pi_{\mathcal{H}}(m)$ 满足

$$R_m(\mathcal{H}) \leq \sqrt{\frac{2 \ln \Pi_{\mathcal{H}}(m)}{m}}. \quad (3.37)$$

Rademacher复杂度与增长函数

证明： 对于 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$, $\mathcal{H}_{|D}$ 为假设空间 $\mathcal{H}$ 在 D 上的限制。由于 $h \in \mathcal{H}$ 的值域为 $\{-1, +1\}$, 可知 $\mathcal{H}_{|D}$ 中的元素为模长 $\sqrt{m}$ 的向量。因此, 由定理 3.4 可得

$$\begin{aligned} R_m(\mathcal{H}) &= \mathbb{E}_D \left[\mathbb{E}_{\boldsymbol{\sigma}} \left[\sup_{u \in \mathcal{H}_{|D}} \frac{1}{m} \sum_{i=1}^m \sigma_i u_i \right] \right] \\ &\leq \mathbb{E}_D \left[\frac{\sqrt{m} \sqrt{2 \ln |\mathcal{H}_{|D}|}}{m} \right]. \end{aligned} \quad (3.38)$$

又因为 $|\mathcal{H}_{|D}| \leq \Pi_{\mathcal{H}}(m)$, 有

$$R_m(\mathcal{H}) \leq \mathbb{E}_D \left[\frac{\sqrt{m} \sqrt{2 \ln \Pi_{\mathcal{H}}(m)}}{m} \right] = \sqrt{\frac{2 \ln \Pi_{\mathcal{H}}(m)}{m}}, \quad (3.39)$$

定理得证。

分析实例之一 (以线性超平面为例)

线性超平面

对于二分类问题, 线性超平面假设空间 $\mathcal{H}$ 可以表示为

$$\left\{ h_{\mathbf{w},b} : h_{\mathbf{w},b}(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b) = \text{sign} \left(\left(\sum_{i=1}^d w_i x_i \right) + b \right) \right\}, \quad (3.40)$$

$b = 0$ 时为齐次线性超平面。

典型的线性超平面是将 $\mathbf{w}, b$ 放缩后, 满足 $\min_{(\mathbf{x}, y) \in D} |\mathbf{w}^T \mathbf{x} + b| = 1$ 的 $(\mathbf{w}, b)$ 所构成的超平面。

对线性超平面进行VC维和Rademacher复杂度分析, 有

定理 3.5 $\mathbb{R}^d$ 空间中, 由齐次线性超平面构成的假设空间的 VC 维为 d .

线性超平面的VC维

证明：令 $e_1, \dots, e_d$ 表示 $\mathbb{R}^d$ 中的 d 个单位向量, $D = \{e_1, \dots, e_d\}$ 。对于任意 d 个标记 $y_1, \dots, y_d$, 取 $\mathbf{w} = (y_1, \dots, y_d)$, 则有 $\mathbf{w}^T \mathbf{e}_i = y_i$, 所以 D 能被齐次线性超平面打散。

令 $D' = \{\mathbf{x}_1, \dots, \mathbf{x}_{d+1}\}$ 为 $\mathbb{R}^d$ 中任意 $d+1$ 个向量, 则必存在不全为 0 的实数 $a_1, \dots, a_{d+1}$ 使得 $\sum_{i=1}^{d+1} a_i \mathbf{x}_i = 0$ 。令 $I = \{i : a_i > 0\}$, $J = \{j : a_j < 0\}$, 则 I, J 至少一个不为空集。首先假设两者都不为空集, 则有

$$\sum_{i \in I} a_i \mathbf{x}_i = \sum_{j \in J} |a_j| \mathbf{x}_j. \quad (3.41)$$

下面采用反证法。假设 D' 能被 $\mathcal{H}$ 打散, 则存在向量 $\mathbf{w}$ 使得 $\mathbf{w}^T \mathbf{x}_i > 0, i \in I$, 且 $\mathbf{w}^T \mathbf{x}_j < 0, j \in J$ 。由此可得

$$0 < \sum_{i \in I} a_i (\mathbf{x}_i^T \mathbf{w}) = \left(\sum_{i \in I} a_i \mathbf{x}_i \right)^T \mathbf{w} = \left(\sum_{j \in J} |a_j| \mathbf{x}_j \right)^T \mathbf{w} = \sum_{j \in J} |a_j| (\mathbf{x}_j^T \mathbf{w}) < 0. \quad (3.42)$$

此式矛盾, 即 D' 能被 $\mathcal{H}$ 打散不成立。当 I, J 只有一个不为空集时同理可证。

综上所述, $VC(\mathcal{H}) = d$, 定理得证。

线性超平面的VC维

定理 3.6 $\mathbb{R}^d$ 空间中, 由非齐次线性超平面构成的假设空间的 VC 维为 $d + 1$.

证明: 由定理 3.5 的证明可知 $D = \{0, \mathbf{e}_1, \dots, \mathbf{e}_d\}$ 能被非齐次线性超平面 $\mathcal{H}$ 打散。下面将非齐次线性超平面转化为齐次线性超平面:

$$\mathbf{w}^T \mathbf{x} + b = \mathbf{w}'^T \mathbf{x}, \quad \mathbf{w} \in \mathbb{R}^d, \mathbf{x} \in \mathbb{R}^d, \mathbf{w}' \in \mathbb{R}^{d+1}, \mathbf{x}' \in \mathbb{R}^{d+1}, \quad (3.43)$$

其中 $\mathbf{w}' = (\mathbf{w}; b)$, $\mathbf{x}' = (\mathbf{x}; 1)$ 。如果 $D' = \{\mathbf{x}_1, \dots, \mathbf{x}_{d+2}\}$ 能被 $\mathbb{R}^d$ 中非齐次线性超平面打散, 则 $D'' = \{\mathbf{x}'_1, \dots, \mathbf{x}'_{d+2}\}$ 能被 $\mathbb{R}^{d+1}$ 中齐次线性超平面打散, 这与定理 3.5 矛盾。

因此, 非齐次线性超平面的 VC 维为 $d + 1$ 。

线性超平面的Rademacher复杂度

线性超平面的假设空间复杂度不仅可基于VC维进行刻画，还可基于Rademacher复杂度刻画。但Rademacher复杂度与数据相关，因此在计算Rademacher复杂度时需要将分布 $\mathcal{D}$ 限制在某一范围内。

定理 3.7 令 $D \subset \{\mathbf{x} : \|\mathbf{x}\| \leq r\}$ 是大小为 m 的数据集, 则典型超平面族 $\mathcal{H} = \{\mathbf{x} \mapsto \mathbf{w}^T \mathbf{x} : \|\mathbf{w}\| \leq \Lambda\}$ 的经验 Rademacher 复杂度满足

$$\hat{R}_D(\mathcal{H}) \leq \sqrt{\frac{r^2 \Lambda^2}{m}}. \quad (3.44)$$

不难发现，定理 3.7 只给出了Rademacher复杂度的上界。这是由于Rademacher复杂度依赖于数据分布，使得计算Rademacher复杂度的具体数值相当困难。

线性超平面的Rademacher复杂度

证明:

$$\begin{aligned}\hat{R}_D(\mathcal{H}) &= \frac{1}{m} \mathbb{E}_{\boldsymbol{\sigma}} \left[\sup \sum_{i=1}^m \sigma_i \mathbf{w}^T \mathbf{x}_i \right] \\&= \frac{1}{m} \mathbb{E}_{\boldsymbol{\sigma}} \left[\sup \mathbf{w}^T \sum_{i=1}^m \sigma_i \mathbf{x}_i \right] \\&\leq \frac{\Lambda}{m} \mathbb{E}_{\boldsymbol{\sigma}} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\| \right] \\&\leq \frac{\Lambda}{m} \left[\mathbb{E}_{\boldsymbol{\sigma}} \left[\left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|^2 \right] \right]^{1/2} \\&= \frac{\Lambda}{m} \left[\mathbb{E}_{\boldsymbol{\sigma}} \left[\sum_{i,j=1}^m \sigma_i \sigma_j (\mathbf{x}_i^T \mathbf{x}_j) \right] \right]^{1/2} \\&\leq \frac{\Lambda}{m} \left[\sum_{i=1}^m \|\mathbf{x}_i\|^2 \right]^{1/2} \\&\leq \sqrt{\frac{r^2 \Lambda^2}{m}},\end{aligned}\tag{3.45}$$
