



国防科技大学

National University of Defense Technology



统计决策理论与贝叶斯分析

第4讲 无信息先验

2025年秋季

陆 军



第4讲 无信息先验


回顾

■ 先验分布的确定方法：

- 边际矩方法
- ML-II最大似然方法
- 基于分布信息

具有完全或一定的主观性，可认为是主观先验！

■ 若没有任何先验信息如何确定分布？





第4讲 无信息先验

例1. 设 $X = (X_1, \dots, X_n)$ 为从总体 $N(\theta, 1)$ 中抽取 i. i. d. 样本，没有 θ 的任何先验信息，求 θ 的后验密度。

解：

$$\pi(\theta|\mathbf{x}) \propto p(\mathbf{x}|\theta)\pi(\theta) \propto \exp\left\{-\frac{(\theta - \bar{x})^2}{2/n}\right\}$$

因而

$$\theta|\mathbf{x} \sim N(\bar{x}, 1/n)$$

■ $\pi(\theta) \propto 1$ 也可以看作先验分布？



第4讲 无信息先验

4.1 无信息先验的概念


- 离散均匀分布（古典情形）

$$P(\theta = \theta_i) = \frac{1}{n}, \quad i = 1, 2, \dots, n$$

- 有限区间上的均匀分布

$$\theta \sim U(a, b)$$

- 能够把均匀分布扩展到整个实数域上吗？
- 也称为Laplace先验或广义先验分布





第4讲 无信息先验

4.1 无信息先验的概念

定义： 设 $X \sim f(x | \theta), \theta \in \Theta$ ，若先验分布 $\pi(\theta)$ 满足条件：

- ① 若 $\pi(\theta) \geq 0$ 且 $\int_{\Theta} \pi(\theta) d\theta = \infty$,
- ② 后验密度 $\pi(\theta | x)$ 是正常的密度函数；

则称 $\pi(\theta)$ 为 θ 的**广义先验密度** (improper prior density).

注： 由定义可见广义先验密度 $\pi(\theta)$ 乘以任一给定的常数 c ， $c\pi(\theta)$ 仍是一个广义先验密度。

问： 对于一般的总体参数，如何求其参数的无信息先验？



第4讲 无信息先验

4.2 位置参数族的无信息先验

■ 位置参数族： $X \sim f(x - \theta)$

➤ 正态分布： $X \sim N(\theta, \sigma^2)$ ，其中 σ^2 已知，则 θ 为位置参数

➤ Cauchy分布： $X \sim C(\mu, \lambda)$ ， λ 已知， μ 为位置参数

■ 性质：若做变换 $X \rightarrow Y = X + c$ ； $\theta \rightarrow \eta = \theta + c$ ，则有

$$Y \sim f(y - \eta)$$

η 仍为位置参数，样本空间和参数空间均不变

■ (X, θ) 与 (Y, η) 的统计结构相同，无信息先验也应相同

➤ 如何确定位置参数的无先验信息的形式？



第4讲 无信息先验

4.2 位置参数族的无信息先验

假定 π 和 π^* 分别是 θ 和 η 的无信息先验，那么应有


$$\pi(b) = \pi^*(b), \forall b \in \Theta$$

另一方面，由变换 $\eta = \theta + c$

$$\pi^*(\eta) = \pi(\eta - c) \left| \frac{d\theta}{d\eta} \right| = \pi(\eta - c)$$

因而有 $\pi(\eta) = \pi^*(\eta) = \pi(\eta - c)$ ，进而

$$\pi(\theta) \propto 1.$$






第4讲 无信息先验

4.2 位置参数族的无信息先验

例2. 设 $X_1, \dots, X_n$ 是来自指数分布 $p(x|\theta) = e^{-(x-\theta)}, x \geq \theta$, 假设 θ 无任何先验信息可利用, 求 θ 的后验分布并判断该分布是否为正常分布?

- 无信息先验是贝叶斯统计中最成功的结果之一:
 - 经典统计学中一些成功的估计量可以看作使用合理的无信息先验的结果.





第4讲 无信息先验

4.3 尺度参数的无信息先验

- 什么是尺度参数族？


$$f(x) \in \left\{ \frac{1}{\sigma} \varphi\left(\frac{x}{\sigma}\right) : \sigma \in (0, \infty) \right\}, \text{ 如 } X \sim N(0, \sigma^2)$$

- 尺度参数的结构不变性：作变换 $Y = cX (c > 0)$,

$$\eta = c\sigma, Y \text{ 的密度仍为 } \frac{1}{\eta} \varphi\left(\frac{y}{\eta}\right)$$

- 尺度参数的无信息先验是什么分布？

- $\pi(\sigma) \propto 1$?





第4讲 无信息先验


■ 推导： $\pi(\eta) = \pi^*(\eta) = \frac{1}{c} \pi\left(\frac{\eta}{c}\right)$ ，故

$$\pi(\sigma) = \frac{1}{\sigma}, \sigma > 0$$

例3. 假定 $\mathbf{x} = (x_1, \dots, x_n)$ 是来自密度函数为

$$f(x | \lambda) = \frac{1}{\lambda} \exp\left\{-\frac{x}{\lambda}\right\}, x > 0,$$

的简单随机样本，取 λ 的先验分布为无信息先验，试求其后验均值。





第4讲 无信息先验

4.3 尺度参数的无信息先验


解：

$$\pi(\lambda|\mathbf{x}) \propto p(\mathbf{x}|\lambda)\pi(\lambda) \propto \frac{1}{\lambda^{n+1}} \exp\left\{-\frac{1}{\lambda} \sum_{i=1}^n x_i\right\}$$

此为**逆伽马分布**，故后验均值为

$$E(\lambda|\mathbf{x}) = \frac{1}{n-1} \sum_{i=1}^n x_i, \quad n > 1$$

注：用近似的样本均值作为 λ 的估计是合理的。





第4讲 无信息先验

例4. 假定总体为 $N(\theta, \sigma^2)$ ，求参数 θ ， σ^2 的无信息先验

- μ, σ^2 均未知时，总体密度函数既不是位置参数族，也不是尺度参数族。
- 对于非位置参数族和尺度参数族，被广泛采用的是Jeffreys于1946年提出的方法，故称杰弗里斯先验 (Jeffreys Prior)
 - 由于推导涉及变换群和Harr测度，这里只给出具体的求解步骤。



第4讲 无信息先验

4.4 杰弗里斯先验——Fisher Information


- 对数似然函数： $l(\mathbf{x}; \theta) = \sum_{i=1}^n \log p(x_i | \theta)$
- 得分函数（估计方程）： $S(\mathbf{x}; \theta) = \sum_{i=1}^n \frac{\partial \log p(x_i | \theta)}{\partial \theta}$
- 费雪信息的**第一定义**： $I(\theta) = E[S(\mathbf{x}; \theta)^2]$
 - $I(\theta) = \text{Var}[S(\mathbf{x}; \theta)]$
 - 得分函数的方差：随着样本越来越多，得到的信息越来越多，估计越来越精准。
 - **例**： $X_i \sim N(\theta, 1)$, $I(\theta) = \sum_{i=1}^n \text{Var}(X_i - \theta) = n$



第4讲 无信息先验

■ 费雪信息的第二定义：
$$I(\theta) = -E \left[\frac{\partial^2 \log p(x_i|\theta)}{\partial \theta^2} \right]$$

- 例：逻辑模型 $P(X = 1|\theta) = \frac{e^\theta}{1+e^\theta}$
- 对数似然函数越平而宽，代表我们对于参数估计的能力越差；高而窄，代表我们对于参数估计的能力越好，即信息量越大。
- 对数似然函数在参数真实值处的负二阶导数，就反应了该函数在顶点处的弯曲程度，弯曲程度越大，整个对数似然函数的形状就越偏向于高而窄，也就代表掌握的信息越多





第4讲 无信息先验

4.4 杰弗里斯先验 (Jeffreys Prior)

1. 写出参数 θ 的对数似然函数

$$l = l(\theta | x) = \ln \left[\prod_{i=1}^n f(x_i | \theta) \right] = \sum_{i=1}^n \ln f(x_i | \theta)$$

2. 写出Fisher信息矩阵

$$I(\theta) = (I_{ij}(\theta))_{p \times p}, \quad I_{ij}(\theta) = E^{X|\theta} \left\{ -\frac{\partial^2 l}{\partial \theta_i \partial \theta_j} \right\}, \quad i, j = 1, \dots, p.$$

3. θ 的无信息先验的密度为

$$\pi(\theta) \propto |I(\theta)|^{\frac{1}{2}}$$



第4讲 无信息先验

例5 设 $\mathbf{x} = (x_1, \dots, x_n)$ 是从 $N(\mu, \sigma^2)$ 中抽取的随机样本，记 $\theta = (\mu, \sigma)$ ，求 (μ, σ) 的联合无信息先验。

解： θ 的对数似然函数是

$$l(\theta | \mathbf{x}) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

记 $I(\theta) = (I_{ij}(\theta))_{2 \times 2}$ ，则有

$$\triangleright I_{11}(\theta) = E^{X|\theta} \left\{ -\frac{\partial^2 l(\theta|x)}{\partial \mu^2} \right\} = \frac{n}{\sigma^2}$$

$$\triangleright I_{22}(\theta) = E^{X|\theta} \left\{ -\frac{\partial^2 l(\theta|x)}{\partial \sigma^2} \right\} = -\frac{n}{\sigma^2} + \frac{3}{\sigma^4} E \left\{ \sum_{i=1}^n (X_i - \mu)^2 \right\} = \frac{2n}{\sigma^2}$$

$$\triangleright I_{12}(\theta) = I_{21}(\theta) = E^{X|\theta} \left\{ -\frac{\partial^2 l(\theta|x)}{\partial \mu \partial \sigma} \right\} = E \left\{ \frac{2}{\sigma^3} \sum_{i=1}^n (X_i - \mu) \right\} = 0$$



第4讲 无信息先验


故有

$$I(\theta) = \begin{pmatrix} n/\sigma^2 & 0 \\ 0 & 2n/\sigma^2 \end{pmatrix}, |I(\theta)|^{\frac{1}{2}} = \frac{\sqrt{2}n}{\sigma^2},$$

所以, (μ, σ) 的Jeffreys先验为

$$\pi(\mu, \sigma) = \frac{1}{\sigma^2}$$

- 当 σ 已知时, $\pi_1(\mu) \propto 1$
- 当 μ 已知时, $\pi_2(\sigma^2) \propto \sigma^{-2}$
- 当 μ 和 σ 独立时, $\pi(\mu, \sigma^2) = \pi_1(\mu)\pi_2(\sigma^2) = \sigma^{-2}$






第4讲 无信息先验

4.4 杰弗里斯先验 (Jeffreys Prior)

再谈无信息先验：

- Box 与 Tiao 如此定义无信息先验分布 (non-informative prior):
“Non-informative prior is a prior which provides little information relative to the experiment.”
- Laplace pretended that he had no (prior) reason to consider one value of $p = p_1$ more likely than another value $p = p_2$.
- 为何 Jeffreys Prior 也能成为无信息先验的一种？！






第4讲 无信息先验

为什么Jeffreys Prior是无信息先验？

Jeffreys Prior看起来明显不是类似Laplace的无信息先验（即对参数的取值没有任何偏好），那么Jeffreys Prior到底为什么可以作为无信息先验分布呢？


“The Jeffreys prior is indeed the uniform prior over the parameter space, but not under the Euclidean geometry (pdfs depend on the geometry, as they give limits of probability of a set over the volume of the set, and volume calculation depends on geometry).”





第4讲 无信息先验

- 我们如何参数化一个模型也是一种主观的决策。
- Jeffreys先验能够保证不论采取什么样的参数化方法，它们的先验分布都是等价的，从而后验分布也是等价的。
- Fisher信息实际上是对样本中信息的提取值， $I(\theta)$ 越大表示先验分布中取到 θ 这一点值的概率越大，所以利用Fisher信息量来构造是很自然的。






第4讲 无信息先验

例6. 设 θ 为伯努利试验中的成功概率，在 n 次独立的伯努利试验中成功次数 $X \sim B(n, \theta)$ ，即

$$P(X = x | \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

求 θ 的 Jeffreys 无信息先验。





第4讲 无信息先验

解： θ 的对数似然函数为

$$l(\theta | x) = \ln \binom{n}{x} + x \ln \theta + (n - x) \ln(1 - \theta)$$

则有

$$\begin{aligned} I(\theta) &= E^{X|\theta} \left\{ -\frac{\partial^2 l(\theta | x)}{\partial \theta^2} \right\} = E^{X|\theta} \left\{ \frac{X}{\theta^2} + \frac{n - X}{(1 - \theta)^2} \right\} \\ &= \frac{n}{\theta} + \frac{n}{1 - \theta} = \frac{n}{\theta(1 - \theta)} \end{aligned}$$

故可取 $\pi(\theta) \propto I(\theta)^{1/2} = \theta^{-1/2}(1 - \theta)^{-1/2}$, $\theta \in (0, 1)$, 添加正则化因子得到先验密度 $\pi(\theta)$ 为贝塔密度函数 $Beta(1/2, 1/2)$.


■ 此先验分布也是共轭先验分布！（不具有普遍性）



第4讲 无信息先验

注：

- 一般说来无信息先验不唯一，如例5中 θ 的另一个无信息先验分布可取为 $(0,1)$ 上的均匀分布.
- 不同的无信息先验对贝叶斯推断影响都很小，很少对结果产生较大影响，所以**任何无信息先验都可以接受**。
- 无信息先验也称客观先验，这是近几十年贝叶斯学派最成功的应用，也被频率学派所接受。





第4讲 无信息先验

4.5 分层先验分布的概念

两层先验的结构：

$X \sim f(x | \theta)$ ，样本 $x \in \mathcal{X}$ ，

$\theta \sim \pi_1(\theta | \lambda)$ ，参数 $\theta \in \Theta$ ，

$\lambda \sim \pi_2(\lambda)$ ，超参数 $\lambda \in \Lambda$ ，

其中 $\mathcal{X}$ 为样本空间， Θ 为参数空间， Λ 为超参数空间。

■ $\pi_2(\lambda)$ 一般取为无信息先验

■ 上述模型称为贝叶斯分层模型



第4讲 无信息先验

4.5 分层先验分布的概念

例7 某经理对产品的不合格率 θ 了解较少，只知道 θ 较小，试给出 θ 的合理分层先验。

分层先验如下：

(i) θ 的先验分布 $\pi_1(\theta | \lambda)$ 为 $U(0, \lambda)$

(ii) λ 的先验分布 $\pi_2(\lambda)$ 为 $U(0.1, 0.5)$ ，于是可得 θ 的先验分布为

$$\pi(\theta) = \int_{\Lambda} \pi_1(\theta | \lambda) \pi_2(\lambda) d\lambda = \frac{1}{0.5 - 0.1} \int_{0.1}^{0.5} \lambda^{-1} I_{[0, \lambda]}(\theta) d\lambda$$




第4讲 无信息先验

4.5 分层先验分布的概念

分层先验的优点：

1. 分层先验模型允许在建模时将相对复杂的情形转化为一系列简单的情形。
2. 便于计算。



θ 的多层先验



第4讲 无信息先验

小结

- Laplace先验
- 位置参数及尺度参数的无信息先验分布
- Jefferyy无信息先验
- 多层先验

