



国防科技大学

National University of Defense Technology



统计决策理论与贝叶斯分析

# 第5讲 贝叶斯估计

2025年秋季

陆 军



# 第5讲 贝叶斯估计

## 5.1 充分统计量

### 1. 什么是统计量？

- 随机变量  $X \sim P_\theta$ ， $\theta$  为待估参数，样本  $\mathbf{X} = (X_1, \dots, X_n)$  独立同分布于  $P_\theta$ .
- 统计量  $T(\mathbf{X}) = T(X_1, \dots, X_n)$ ：**样本的函数**
  - $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ， $\sigma^2$  已知，如何估计  $\mu$ ？

a)  $X_1$

b)  $\bar{X}$

c)  $(X_1 + X_2)/2$



## 第5讲 贝叶斯估计


### 5.1 充分统计量——经典统计中的充分统计量

➤ 什么是好的估计量？

**例1** 研究某个运动员的打靶命中率 $\theta$ ，该运动员进行10次观测，发现除第三、六次没有命中，这样的结果包含了哪些信息？

(1) 打靶10次命中8次；

(2) 2次不命中分别出现在第3次和第6次。



■ 充分性的直观定义：

■ 不损失**包含参数 $\theta$** 的信息的统计量。




## 第5讲 贝叶斯估计

### 5.1 充分统计量——经典统计中的充分统计量

**定义：** 设  $\mathbf{x} = (x_1, \dots, x_n)$  是来自分布函数  $F(x|\theta)$  的一个样本， $T = T(\mathbf{x})$  是统计量，假如在给定  $T(\mathbf{x}) = t$  的条件下， $\mathbf{x}$  的条件分布与  $\theta$  无关的话，则称该统计量  $T(\mathbf{x})$  为  $\theta$  的充分统计量。

■  $p(\mathbf{x}|T(\mathbf{x}) = t)$  不依赖于  $\theta$





## 第5讲 贝叶斯估计

### 5.1 充分统计量——经典统计中的充分统计量


**例2**  $X_1, \dots, X_n \sim \text{Bernoulli}(1, p)$

- $X_i = 1$ : 喜欢百事
- $X_i = 0$ : 喜欢可口可乐



观测了40人， $Y = \sum_i^n X_i = 22$ 人喜欢百事。

- 请问 $Y$ 是 $p$ 的充分统计量吗？
- $P(X_1 = x_1, \dots, X_n = x_n | Y = y)$ 依赖于 $p$ ？





## 第5讲 贝叶斯估计

**定理（因子分解定理）** 一个统计量 $T(x)$ 对参数 $\theta$ 是充分的  
**充要条件**是：存在 $t$ 的密度函数 $g(t|\theta)$ 和样本 $x$ 的某个函数 $h(x)$ ，使得对任一样本 $x$ 和任意 $\theta$ ，样本的联合密度 $p(x|\theta)$ 可表示为它们的乘积，即

$$p(x|\theta) = g(T(x)|\theta)h(x)$$

- 若 $T(x)$ 为充分统计量，则 $p(x|\theta)$ 一定可以分解为两个因子的乘积：（1）一个因子与 $\theta$ 无关；（2）另一个因子与样本 $x$ 的关系仅仅通过充分统计量 $T(x)$ 就可以表现出来。





## 第5讲 贝叶斯估计

**例3.** 设 $\mathbf{x} = (x_1, \dots, x_n)$ 是来自 $\exp(\theta)$ 的样本, 验证

$T(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$  是 $\theta$ 的充分统计量。

**解:**

$$f(\mathbf{x}|\theta) = \theta^n \exp\left(-\theta \sum_{i=1}^n x_i\right) = \theta^n \exp(-n\bar{x}\theta)$$

这里,

$$g(t|\theta) = \theta^n \exp(-nt\theta), h(\mathbf{x}) = 1$$



## 第5讲 贝叶斯估计

### 5.1 充分统计量——贝叶斯统计中的充分统计量

■ 贝叶斯统计中的充分统计量与经典统计中充分统计量的定义一致。

**定理2：** 设  $\mathbf{x} = (x_1, \dots, x_n)$  是来自  $p(\mathbf{x}|\theta)$  的一组样本， $T = T(\mathbf{x})$  是统计量，又设  $H = \{\pi(\theta)\}$  是  $\theta$  的某个先验分布族，则  $T(\mathbf{x})$  为  $\theta$  的充分统计量的 **充要条件** 是对 **任一先验分布**  $\pi(\theta) \in H$ ，有

$$\pi(\theta|T(\mathbf{x})) = \pi(\theta|\mathbf{x})$$





## 第5讲 贝叶斯估计

**例4** 设  $\mathbf{x} = (x_1, \dots, x_n)$  是来自正态分布  $N(\theta, 1)$  的一组样本，取  $\theta$  的先验分布为  $N(\mu, 1)$ ，求  $\theta$  的后验分布。

**解：**  $\bar{X}$  是  $\theta$  的充分统计量且  $\bar{X} \sim N(\theta, n^{-1})$

$$\pi(\theta|\mathbf{x}) = \pi(\theta|\bar{x}) = p(\bar{x}|\theta)\pi(\theta)$$

$$\propto \exp\left(-\frac{n(\bar{x} - \theta)^2}{2} - \frac{(\theta - \mu)^2}{2}\right)$$

$$\theta|\mathbf{x} \sim N\left(\frac{\mu + n\bar{x}}{n+1}, \frac{1}{n+1}\right)$$



## 第5讲 贝叶斯估计

### 5.2 点估计——从充分统计量到点估计

**回顾：**经典统计视角下的点估计？

**例5.** 设 $x_1, \dots, x_n$ 是来自正态总体 $N(\theta, \sigma^2)$ 的一组样本， $\sigma^2$ 已知，取 $\theta$ 的先验分布为 $N(\mu, \tau^2)$ ，求 $\theta$ 的估计？

■ 贝叶斯观点下， $\theta$ 有无点估计？

■  $\theta$ 的后验分布： $\theta \sim N(\mu_1, \sigma_1^2)$

$$\mu_1 = \gamma\mu + (1 - \gamma)\bar{x}, \quad \gamma = \frac{\tau^{-2}}{\sigma_0^{-2} + \tau^{-2}}$$

■  $\theta$ 的点估计： $\hat{\theta}_B = \mu_1$ ？




# 第5讲 贝叶斯估计

## 5.2 点估计

**定义：** 贝叶斯统计视角下的点估计（三种估计）

- 最大后验估计  $\theta_{MD}$
- 后验中位数估计  $\hat{\theta}_{Me}$
- 后验期望值估计  $\hat{\theta}_E = \int_{\Theta} \theta \pi(\theta|x) d\theta$






## 第5讲 贝叶斯估计

### 5.2 点估计——条件观点

#### 贝叶斯估计的基本思想：

- 基于后验分布进行统计推断，只考虑已出现的数据，这一观点被称为“**条件观点**”
- 后验分布的特点：集三种信息于一身，它包含了所有可利用的信息。
- 参数估计和假设检验等统计推断都从后验分布提取信息，其提取方法与经典统计推断相比要简明得多。





## 第5讲 贝叶斯估计

### 5.2 点估计——条件观点

**条件方法与频率方法的区别**（以对估计的无偏性认识为例）：经典统计学认为参数的无偏估计应满足

$$E\left(\hat{\theta}(x)\right)=\int_x \hat{\theta}(x) p(x|\theta) d x=\theta$$

- 平均是对样本空间中**所有可能出现的样本**而平均
- 频率方法适合长期主义、大样本情形
- 在贝叶斯推断中不用无偏性，条件方法更容易被实际工作者理解和接受的。



## 第5讲 贝叶斯估计


**例6** 设 $x$ 是来自如下指数分布的一个样本,

$$p(x|\theta) = e^{-(x-\theta)}, x \geq \theta$$

取柯西分布作为 $\theta$ 的先验分布, 即:

$$\pi(\theta) = \frac{1}{\pi(1 + \theta^2)}, -\infty < \theta < \infty$$

求 $\theta$ 的最大后验估计 $\hat{\theta}_{MD}$ .







## 第5讲 贝叶斯估计

**解：**易知， $\theta$ 的后验密度为：

$$\pi(\theta|x) = \frac{e^{-(x-\theta)}}{m(x)(1+\theta^2)\pi}, \theta \leq x$$

为了寻找 $\theta$ 的最大后验估计 $\hat{\theta}_{MD}$ ，对后验密度求导数，得：

$$\frac{d}{d\theta} \pi(\theta|x) = \frac{e^{-x}}{m(x)\pi} \left[ \frac{e^{\theta}}{1+\theta^2} - \frac{2\theta e^{\theta}}{(1+\theta^2)^2} \right] = \frac{e^{-x} e^{\theta} (\theta - 1)^2}{m(x)(1+\theta^2)^2 \pi} \geq 0$$

由于 $\pi(\theta|x)$ 的非减性，考虑到 $\theta$ 的取值不能超过 $x$ ，故 $\theta$ 的最大后验估计应为 $\hat{\theta}_{MD} = x$ 。

**思考：**如果是多个样本呢？



## 第5讲 贝叶斯估计

**例7** 为估计不合格率 $\theta$ ，从一批产品中随机抽取 $n$ 件，其中不合格品数 $X$ 服从 $B(n, p)$ ，选取 $Beta(\alpha, \beta)$ 为 $\theta$ 的先验分布，设 $\alpha, \beta$ 已知，求 $\theta$ 的Bayes估计。

**解：**  $\theta$ 的后验分布为：

$$Beta(\alpha + x, \beta + n - x)$$

则得：

$$\hat{\theta}_{MD} = \frac{\alpha + x - 1}{\alpha + \beta + n - 2}, \quad \hat{\theta}_E = \frac{\alpha + x}{\alpha + \beta + n}$$

**特例：** 选用贝叶斯假设(无信息先验)作为先验分布( $\alpha = \beta = 1$ )

则：

$$\hat{\theta}_{MD} = \frac{x}{n}, \quad \hat{\theta}_E = \frac{x + 1}{n + 2}$$



## 第5讲 贝叶斯估计

结论: (1) 二项分布下,  $\theta$  的极大似然估计是贝叶斯估计的特例 (取特定的先验分布)

(2) 看起来,  $\theta$  的后验期望估计  $\hat{\theta}_E$  要比最大后验估计  $\hat{\theta}_{MD}$  更合适一些 (见下表)

| 试验号 | 样本量 $n$ | 不合格数 $x$ | $\hat{\theta}_{MD} = \frac{x}{n}$ | $\hat{\theta}_E = \frac{x+1}{n+2}$ |
|-----|---------|----------|-----------------------------------|------------------------------------|
| 1   | 3       | 0        | 0                                 | 0.200                              |
| 2   | 10      | 0        | 0                                 | 0.083                              |
| 3   | 3       | 3        | 1                                 | 0.800                              |
| 4   | 10      | 10       | 1                                 | 0.917                              |

表1 不合格率  $\theta$  的二种贝叶斯估计的比较

■ 这样的结果是否是偶然的?



## 第5讲 贝叶斯估计

### 贝叶斯估计的误差

- 设  $\hat{\theta}$  是  $\theta$  的一个贝叶斯估计，如何度量估计  $\hat{\theta}$  的好坏？
- 经典统计中如何度量估计  $\hat{\theta}$  的好坏？无偏性、相合性.

**定义：**设参数  $\theta$  的后验分布为  $\pi(\theta|x)$ ，贝叶斯估计为  $\hat{\theta}$ ，则  $(\theta - \hat{\theta})^2$  的后验期望

$$\text{MSE}(\hat{\theta}|x) = E_{\theta|x}(\theta - \hat{\theta})^2$$

称为  $\hat{\theta}$  的**后验均方误差**.



## 第5讲 贝叶斯估计

注意：

① MSE是关于后验分布 $\pi(\theta|x)$ 的期望

② 当 $\hat{\theta} = \hat{\theta}_E = E(\theta|x)$ 时， $\text{MSE}(\hat{\theta}_E|x) = E_{\theta|x}(\theta - \hat{\theta}_E)^2 = \text{Var}(\hat{\theta}_E|x)$  称为**后验方差**。

③ 后验均方误差与后验方差的关系：

$$\begin{aligned}\text{MSE}(\hat{\theta}|x) &= E_{\theta|x}(\theta - \hat{\theta})^2 \\ &= E_{\theta|x}[(\theta - \hat{\theta}_E) + (\hat{\theta}_E - \hat{\theta})]^2 \\ &= \text{Var}(\hat{\theta}_E|x) + (\hat{\theta}_E - \hat{\theta})^2\end{aligned}$$

■ 当 $\hat{\theta} = \hat{\theta}_E$ 时，可使后验均方误差达到最小，实际中常取**后验均值** $\hat{\theta}_E$ 作为 $\theta$ 的贝叶斯估计值



## 第5讲 贝叶斯估计

**例7（续）** 若选用共轭分布，试比较产品不合格品率 $\theta$ 的后验期望估计与最大后验估计的均方误差。


**解：**  $\theta \sim \text{Beta}(x + \alpha, n - x + \beta)$ ,  $\hat{\theta}_E = \frac{x+1}{n+2}$ ,  $\hat{\theta}_{MD} = \frac{x}{n}$

后验方差为

$$\text{Var}(\hat{\theta}_E | x) = E_{\theta|x}(\hat{\theta}_E - \theta)^2 = \frac{(\alpha + x)(\beta + n - x)}{(\alpha + \beta + n)^2(\alpha + \beta + n + 1)}$$

当取 $\alpha = \beta = 1$ ，则

$$\text{Var}(\hat{\theta}_E | x) = \frac{(x + 1)(n - x + 1)}{(n + 2)^2(n + 3)}$$







## 第5讲 贝叶斯估计

$\hat{\theta}_{MD}$ 的后验均方误差为：

$$\text{MSE}(\hat{\theta}_{MD}|x) = \frac{(x+1)(n-x+1)}{(n+2)^2(n+3)} + \left( \frac{x+1}{n+2} - \frac{x}{n} \right)^2$$

对若干 $(n, x)$ 的值算得的后验方差和后验均方误差见下表

| $n$ | $x$ | $\hat{\theta}_E$ | Var    | $\hat{\theta}_{MD}$ | MSE    |
|-----|-----|------------------|--------|---------------------|--------|
| 3   | 0   | 1/5              | 0.0267 | 0                   | 0.0667 |
| 10  | 0   | 1/12             | 0.0059 | 0                   | 0.0128 |
| 10  | 1   | 2/12             | 0.0107 | 1/10                | 0.0151 |
| 20  | 1   | 2/22             | 0.0036 | 1/20                | 0.0053 |

$\hat{\theta}_E$ 和 $\hat{\theta}_{MD}$ 的后验均方差



## 第5讲 贝叶斯估计

### 5.3 可信区间

■  $\theta$  落在某区间  $[a, b]$  内的后验概率：

$$P(a \leq \theta \leq b | x) = 1 - \alpha$$

■ 若给定概率  $1 - \alpha$ ，存在区间  $[a, b]$  使上式成立，该区间即为  $\theta$  的贝叶斯区间估计，又称为可信区间。

**注：**若  $\theta$  为离散随机变量，对给定的概率  $1 - \alpha$ ，满足上式的区间  $[a, b]$  不一定存在，这时只有略微放大上式左端概率，才能找到  $a$  与  $b$ ，使得

$$P(a \leq \theta \leq b | x) > 1 - \alpha$$

该区间也是  $\theta$  的贝叶斯可信区间。



# 第5讲 贝叶斯估计

## 5.3 可信区间


定义：

■ 可信区间 $[\hat{\theta}_L, \hat{\theta}_U]$ ：  $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U | \mathbf{x}) \geq 1 - \alpha$

■ 可信下限 $\hat{\theta}_L$ ：  $P(\theta \geq \hat{\theta}_L | \mathbf{x}) \geq 1 - \alpha$

■ 可信上限 $\hat{\theta}_U$ ：  $P(\theta \leq \hat{\theta}_U | \mathbf{x}) \geq 1 - \alpha$

$\hat{\theta}_L = \hat{\theta}_L(x)$  与  $\hat{\theta}_U = \hat{\theta}_U(x)$  为统计量， $1 - \alpha$  为可信水平.





## 第5讲 贝叶斯估计

### 5.3 可信区间

可信区间与经典统计中的置信区间的差别：

- 求经典统计中的置信区间有时是困难的，它要设法
  - 构造一个**枢轴量**，使它的分布不含未知参数，这是一项技术性很强的工作。
- 条件方法下，可信水平与可信区间更自然的
  - 相比之下，可信区间只要利用后验分布，不需要再去寻求另外的分布。
  - 然而一般求后验分布是比较困难的。
- 可信区间与置信区间的意义天差地别




## 第5讲 贝叶斯估计

**例5 (续)** 设  $x_1, x_2, \dots, x_n$  是来自正态总体  $N(\theta, \sigma^2)$  的一组样本，其中  $\sigma^2$  已知，若正态均值的先验分布取为  $N(\mu, \tau^2)$ ，其中  $\mu$  与  $\tau^2$  已知，试求  $\theta$  的  $1 - \alpha$  可信区间。

**解：** 可求得  $\theta$  的后验分布为  $N(\mu_1, \sigma_1^2)$ ，由此很容易获得  $\theta$  的  $1 - \alpha$  可信区间：

$$P(\mu_1 - \sigma_1 \mu_{1-\alpha/2} \leq \theta \leq \mu_1 + \sigma_1 \mu_{1-\alpha/2}) = 1 - \alpha$$

其中， $\mu_{1-\alpha/2}$  是标准正态分布的  $1 - \alpha/2$  分位数。







## 第5讲 贝叶斯估计

### 5.3 可信区间—最大后验密度(HPD)可信区间

**定义：** 设参数 $\theta$ 的后验密度为 $\pi(\theta|x)$ ，对给定的概率 $1 - \alpha$  ( $0 < \alpha < 1$ )，若在直线上存在这样一个子集 $C$ ，满足下列两个条件：

①  $P(C|x) = 1 - \alpha$


② 对任给 $\theta_1 \in C$  和  $\theta_2 \notin C$ ，总有 $\pi(\theta_1|x) \geq \pi(\theta_2|x)$ ，

则称 $C$ 是 $\theta$ 的可信水平为 $(1 - \alpha)$ 的**最大后验密度可信集**，简称 $(1 - \alpha)$  HPD可信集，如果 $C$ 是一个区间，则 $C$ 又称为 $(1 - \alpha)$  **HPD可信区间**。






## 第5讲 贝叶斯估计



a. 单峰



b. 双峰  $C=C_1 \cup C_2$

HPD可信集与HPD可信区间



## 第5讲 贝叶斯估计

后验密度函数 $\pi(\theta|x)$ 是 $\theta$ 的**单峰连续函数**时，获得 $\theta$ 的 $(1 - \alpha)$  HPD可信区间的计算方法：

**Step1**：对给定的 $k$ ，解方程 $\pi(\theta|x) = k$ ，得解 $\theta_1(k)$ 和 $\theta_2(k)$ ，从而组成一个区间： $C(k) = [\theta_1(k), \theta_2(k)] = \{\theta: \pi(\theta|x) \geq k\}$ .

**Step2**：计算概率

$$P(\theta \in C(k)|x) = \int_{C(k)} \pi(\theta|x) d\theta$$

**Step3**：对给定的 $k$ ，若 $P(\theta \in C(k)|x) \approx 1 - \alpha$ ，则 $C(k)$ 即为所求的HPD可信区间。

➤ 若 $P(\theta \in C(k)|x) > 1 - \alpha$ ，则增大 $k$ ，再转入Step1与Step2.

➤ 若 $P(\theta \in C(k)|x) < 1 - \alpha$ ，则减小 $k$ ，再转入Step1与Step2.



## 第5讲 贝叶斯估计

**例5（续）** 设  $x_1, \dots, x_n$  是来自正态总体  $N(\theta, \sigma^2)$  的一组样本， $\sigma^2$  已知，取  $\theta$  的先验分布为  $N(\mu, \tau^2)$ ，求  $\theta$  的  $1 - \alpha$  的HPD.

基本步骤：

1. 确定参数  $\theta$  的后验密度和分布函数：

$$\text{后验密度: } \pi(\theta|x) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left\{-\frac{(\theta-\mu_1)^2}{\sigma_1^2}\right\} \theta > 0$$

2. 确定初始值

3. 按第一步计算初始区间

4. 计算后验概率

5. 验证初始区间是否满足要求，满足则停止，否则继续。



# 第5讲 贝叶斯估计

## 小结

- 贝叶斯估计的定义
- 贝叶斯可信区间
  - 可信区间的定义
  - 可信区间的意义
  - HPD可信区间

