



国防科技大学

National University of Defense Technology

统计决策理论与贝叶斯分析

第11讲 贝叶斯计算

——蒙特卡洛及MCMC方法

2025年秋季

陆 军



第11讲 蒙特卡洛及MCMC方法

为什么需要贝叶斯计算？

例1 假设随机变量 $X \sim N(\theta, \sigma^2)$ ，其中 σ^2 已知。若选取 θ 的先验分布为柯西分布 $C(\mu, \tau)$ ，其中 μ, τ 已知，则 θ 的后验分布为

$$\pi(\theta|x) \propto \exp\{-(\theta - x)^2(2\sigma^2)^{-1}\}(\tau^2 + (\theta - \mu)^2)^{-1}.$$

因此后验期望为

$$E(\theta|x) = \frac{\int_{-\infty}^{\infty} \theta \exp\{-(\theta - x)^2(2\sigma^2)^{-1}\}(\tau^2 + (\theta - \mu)^2)^{-1} d\theta}{\int_{-\infty}^{\infty} \exp\{-(\theta - x)^2(2\sigma^2)^{-1}\}(\tau^2 + (\theta - \mu)^2)^{-1} d\theta}$$

■ 上述期望没有显式解，只能通过数值积分进行计算




第11讲 蒙特卡洛及MCMC方法

例2 假设 $X_1, \dots, X_k$ 为相互独立的随机变量，且 X_i 服从泊松分布 $P(\theta_i)$ ， $i = 1, \dots, k$ 。如果 θ_i 的先验分布通过其对数的联合分布给出：

$$\mathbf{v} = (\ln(\theta_1), \dots, \ln(\theta_k))^{\top} \sim N(\mu \mathbf{1}_k, \tau^2 \{(1 - \rho) \mathbf{I}_k + \rho \mathbf{J}_k\}),$$

μ, τ^2, ρ 为已知的常数。

- $E(\theta_j | \mathbf{x})$ 是高维积分，数值积分方法无效
- 如何计算此类高维积分问题？





第11讲 蒙特卡洛及MCMC方法

11.1 蒙特卡洛抽样方法

- 给定 $p(\mathbf{x}|\theta)$, $\pi(\theta)$, θ 的后验分布为

$$\pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta)\pi(\theta)}{\int p(\mathbf{x}|\theta)\pi(\theta)d\theta}$$

- 感兴趣的积分为函数 $h(\theta)$ 的后验期望

$$E[h(\theta)|\mathbf{x}] = \int h(\theta)\pi(\theta|\mathbf{x})d\theta = \frac{\int h(\theta)p(\mathbf{x}|\theta)\pi(\theta)d\theta}{\int p(\mathbf{x}|\theta)\pi(\theta)d\theta} \quad (*)$$

- 给定 $\theta_1, \theta_2, \dots, \theta_m$,


$$\bar{h}_m = \frac{1}{m} \sum_{i=1}^m h(\theta_i) \rightarrow_{as} E[h(\theta)|\mathbf{x}]$$



第11讲 蒙特卡洛及MCMC方法

- 什么样的定理保证了上述结论？
- 根据大数定律，随着 m 的增加， $\bar{h}_m$ 将不断接近 $E[h(\theta)|\mathbf{x}]$ ，因而可作为 $E[h(\theta)|\mathbf{x}]$ 的估计。
- **估计的精度**：可以计算得到 $Var(\bar{h}_m) = \frac{1}{m} V^\pi[h(\theta)|\mathbf{x}]$ ，样本标准差是

$$s_m = \sqrt{\frac{1}{m} \sum_{i=1}^m (h(\theta_i) - \bar{h}_m)^2}$$





第11讲 蒙特卡洛及MCMC方法






第11讲 蒙特卡洛及MCMC方法

第二种方法：

从 $\pi(\theta)$ 生成 i.i.d. 观测值 $\theta_1, \theta_2, \dots, \theta_m$ ，对(*)式最右边项的分子和分母分别用蒙特卡洛逼近代替，得 $E[h(\theta) | \mathbf{x}]$ 的估计：

$$\tilde{h}_m = \frac{\sum_{i=1}^m h(\theta_i) p(\mathbf{x} | \theta_i)}{\sum_{i=1}^m p(\mathbf{x} | \theta_i)}$$

■ 大多数情况下后验分布都不是标准分布，难以从中抽样。





第11讲 蒙特卡洛及MCMC方法


第三种方法：蒙特卡洛重要性抽样方法

例1（续）：求积分

$$E(\theta|x) = \frac{\int_{-\infty}^{\infty} \theta(\tau^2 + (\theta - \mu)^2)^{-1} \cdot \exp\{-(\theta - x)^2(2\sigma^2)^{-1}\}d\theta}{\int_{-\infty}^{\infty} (\tau^2 + (\theta - \mu)^2)^{-1} \cdot \exp\{-(\theta - x)^2(2\sigma^2)^{-1}\}d\theta}$$

蒙特卡洛重要性抽样方法：引入“重要性函数”

- 从后验分布直接抽样很困难，而从与后验分布非常接近的分布 g 中抽样比较容易





第11讲 蒙特卡洛及MCMC方法

第三种方法：蒙特卡洛重要性抽样方法

- 设 $g(\theta)$ 是概率密度函数，它的支撑集包含 $h(\theta)p(x|\theta)\pi(\theta)$ 的支撑集，(*)式中的分子可表示为

$$\int h(\theta)p(x|\theta)\pi(\theta)d\theta$$

$$= \int \left\{ \frac{h(\theta)p(x|\theta)\pi(\theta)}{g(\theta)} \right\} \cdot g(\theta)d\theta = E_g \left\{ \frac{h(\theta)p(x|\theta)\pi(\theta)}{g(\theta)} \right\}$$

- 于是， $E[h(\theta)|x]$ 可表示为

$$E[h(\theta)|x] = E_g \left\{ \frac{h(\theta)p(x|\theta)\pi(\theta)}{g(\theta)} \right\} / E_g \left\{ \frac{p(x|\theta)\pi(\theta)}{g(\theta)} \right\}$$



第11讲 蒙特卡洛及MCMC方法

- 设 $\theta_1, \theta_2, \dots, \theta_m$ 为从分布 $g(\cdot)$ 中生成的*i.i.d*观测值，令 $\omega(\theta) = p(\mathbf{x}|\theta)\pi(\theta)/g(\theta)$ ，则由大数定律可知

$$\frac{1}{m} \sum_{i=1}^m h(\theta_i) \omega(\theta_i) \rightarrow_{as} E_g\{h(\theta) \omega(\theta)\}$$

$$\frac{1}{m} \sum_{i=1}^m \omega(\theta_i) \rightarrow_{as} E_g\{\omega(\theta)\}$$

- 故 $E[h(\theta)|\mathbf{x}]$ 的另一个估计为

$$\hat{h}_m = \frac{\sum_{i=1}^m h(\theta_i) \omega(\theta_i)}{\sum_{i=1}^m \omega(\theta_i)}$$

- **g 的选取**：要使得从分布 g 抽样容易；尽可能接近后验分布，以便提高蒙特卡洛逼近的效果。




第11讲 蒙特卡洛及MCMC方法

例2 $\mathbf{x} = (x_1, \dots, x_n)$ 为从 $N(\theta, \sigma^2)$ 中抽取的简单随机样本，其中 θ, σ^2 均未知，取 θ 和 σ^2 的先验为独立先验，其中 θ 服从双指数先验分布，密度为 $\exp(-|\theta|)/2$ ， σ^2 有先验密度 $(1 + \sigma^2)^{-2}$ 。试找一下计算后验均值

$$E(\theta \mid \mathbf{x}) = \int_{-\infty}^{\infty} \int_0^{\infty} \theta \pi(\theta, \sigma^2 \mid \mathbf{x}) d\theta d\sigma^2$$

的重要性函数。





第11讲 蒙特卡洛及MCMC方法

解 由于 $\pi(\theta, \sigma^2 | \mathbf{x})$ 不是一个标准分布，故先寻找一个离它较近的

分布. 记 $\bar{x} = \sum_{i=1}^n x_i / n, s_n^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / n$, 则

$$\begin{aligned}\pi(\theta, \sigma^2 | \mathbf{x}) &\propto (\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{n}{2\sigma^2} [(\theta - \bar{x})^2 + s_n^2]\right\} \cdot \frac{\exp\{-|\theta|\}}{(1 + \sigma^2)^2} \\&= \frac{[(\theta - \bar{x})^2 + s_n^2]^{\frac{n}{2}+1}}{(\sigma^2)^{\left(\frac{n}{2}+2\right)}} \exp\left\{-\frac{n[(\theta - \bar{x})^2 + s_n^2]}{2\sigma^2}\right\} \\&\quad \times \frac{[(\theta - \bar{x})^2 + s_n^2]^{-\left(\frac{n}{2}+1\right)} \exp\{-|\theta|\} \left(\frac{\sigma^2}{1 + \sigma^2}\right)^2}{\left(\frac{\sigma^2}{1 + \sigma^2}\right)^2} \\&\propto g_1(\sigma^2 | \theta, \mathbf{x}) g_2(\theta | \mathbf{x}) \cdot \exp\{-|\theta|\} \left(\frac{\sigma^2}{1 + \sigma^2}\right)^2\end{aligned}$$

逆伽马分布

t 分布



第11讲 蒙特卡洛及MCMC方法

- 注意到 $\exp(-|\theta|)(\sigma^2/(1+\sigma^2))^2$ 的尾部对 $g_1 \cdot g_2$ 不具有太大的影响，因此可以选择

$$g(\theta, \sigma^2 | \mathbf{x}) = g_1(\sigma^2 | \theta, \mathbf{x}) g_2(\theta | \mathbf{x})$$

作为重要性函数.

- ① 先从 g_2 抽取一个 θ
- ② 给定 θ ，再从 g_1 抽取一个 σ^2 ，组成一次抽样 (θ, σ^2) .
- ③ 抽取 m 对 (θ, σ^2) 后得到 $E^\pi(\theta | \mathbf{x})$ 的估计

$$\hat{E}^\pi(\theta | \mathbf{x}) = \frac{\sum_{i=1}^m \theta_i w(\theta_i, \sigma_i^2 | \mathbf{x})}{\sum_{i=1}^m w(\theta_i, \sigma_i^2 | \mathbf{x})}$$




第11讲 蒙特卡洛及MCMC方法

6.2 MCMC方法的基本概念

蒙特卡洛方法的缺点：

- 需要选择合适的建议密度（“重要性函数”）
- 必须知道后验分布的形式
- 不适用于多维情形
- 如何从后验分布获取样本？





第11讲 蒙特卡洛及MCMC方法

6.2 MCMC方法的基本概念

定义 $\{X_n, n \geq 0\}$ 是取**有限个或可列个值**的随机过程, $X_n = i$ 表示过程在时刻 n 时处于状态 i , $i \in S = \{0, 1, 2, \dots\}$, 若对一切 n 有

$$\begin{aligned} &P(X_{n+1} = j \mid X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = i) \\ &= P(X_{n+1} = j \mid X_n = i), \end{aligned}$$

则称 $\{X_n, n \geq 0\}$ 是**离散时间马尔可夫链**, 常简称为**马氏链**.

- 由定义可知, 随机过程的将来状态 $\{X_{n+1} = j\}$ 只与现在的状态 $\{X_n = i\}$ 有关, 而与过去的状态 $\{X_k = i_k, k \leq n-1\}$ 无关.



第11讲 蒙特卡洛及MCMC方法

- 条件概率 $P(X_{n+1} = j \mid X_n = i)$ 称为马氏链的一步转移概率，若转移概率与 n 无关，且为固定值，则称马氏链有平稳转移概率，记为 p_{ij} .
- 具有平稳转移概率的马氏链也称为时间齐性马氏链.
- $P = (p_{ij}), \forall i, j \in S$ 称为马氏链的转移概率矩阵，满足条件：

$$p_{ij} \geq 0, \text{ 且 } \sum_{i=0}^{\infty} p_{ij} = 1.$$



第11讲 蒙特卡洛及MCMC方法

(1) 马氏链的几条性质

定义(平稳性) 设马尔可夫链有转移概率阵 $P = (p_{ij})$, 一个概率分布 $\pi = \{\pi_i, i \geq 0\}$ 如果满足条件

$$\pi_j = \sum_i \pi_i p_{ij}$$

则称之为此马尔可夫链的平稳分布.

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{pmatrix}$$




第11讲 蒙特卡洛及MCMC方法

定义(不可约性)

$$p_{ij}^{(n)} = P(X_n = j \mid X_0 = i) > 0.$$

- 马氏链的“不可约性”意味着链从任一状态出发总可到达任一其他状态






第11讲 蒙特卡洛及MCMC方法

定义(非周期性) 一个马氏链的一个状态 i 有周期 K ，如果经过 K 的倍数步后一定可以返回到状态 i ，即

$$K(i) = \gcd\{n: P(X_n = i \mid X_0 = i) > 0\},$$

其中 $\gcd$ 表示“最大公约数”。

- 如果返回任一状态的次数的最大公约数是1，则称此马氏链是非周期的。
- 非周期的马氏链可以保证其不会陷入循环当中。






第11讲 蒙特卡洛及MCMC方法

定义(正常返性) 对常返状态 i , 定义

$$T_i = \inf\{n \geq 1: X_n = i \mid X_0 = i\}$$

为首次返回状态 i 的时刻, 如果 $\mu_i = E(T_i) < \infty$, 则称状态 i 是**正常返的**; 当 $\mu_i = \infty$ 时, 称状态 i 是**零常返的**.

注: 若过程以概率 1 从状态 i 出发, 经过有限步转移后又回到 i , 则称状态 i 是**常返的**.






第11讲 蒙特卡洛及MCMC方法

定义(遍历性) 一个马氏链的状态称为**遍历的**，如果它是非周期且正常返的。如果马氏链的所有状态都是遍历的，则称此马氏链是遍历的。

■ 综上所述，**“好”**的马氏链要**不可约**、**正常返**和**非周期**的，此时马氏链存在唯一的平稳分布。






第11讲 蒙特卡洛及MCMC方法

(2) 马氏链的极限定理

定理 马氏链 $\{X_n, n \geq 0\}$ 的转移概率矩阵为 P ，平稳分布为 $\pi = \{\pi_i: i \in S\}$ ，其不可约、非周期，则有

$$\lim_{n \rightarrow \infty} \sum_{j \in S} |P(X_n = j) - \pi_j| = 0.$$

■ $n \rightarrow \infty$ ， X_n 的分布将会接近 π .






第11讲 蒙特卡洛及MCMC方法

定理 (马氏链大数定律) 马氏链 $\{X_n, n \geq 0\}$ 的转移概率矩为阵 P , 平稳分布为 $\pi = \{\pi_i: i \in S\}$, 若其不可约,

离散:
$$\frac{1}{n} \sum_{i=0}^{n-1} h(X_i) \rightarrow_P \sum_j h(j) \pi_j, n \rightarrow \infty$$

连续:
$$\frac{1}{n} \sum_{i=0}^{n-1} h(X_i) \rightarrow_P \int_S h(x) d\pi(x), n \rightarrow \infty$$





第11讲 蒙特卡洛及MCMC方法

■ 计算积分


$$\mu = \int_{\mathcal{S}} h(\theta) d\pi(\theta|x)$$

■ 构造马氏链使其平稳分布 π 是目标后验分布 $\pi(\cdot|x)$

■ 从一初始值 θ_0 出发，将此链运行一段时间，比如 $0, 1, 2, \dots, n-1$ ，生成随机数(样本) $\theta_0, \theta_1, \dots, \theta_{n-1}$ ，则

$$\bar{\mu}_n = \frac{1}{n} \sum_{j=0}^{n-1} h(\theta_j) \rightarrow_P \mu$$

■ 上述称为MCMC方法






第11讲 蒙特卡洛及MCMC方法

例3 观测数据 $x = [2.1, 1.9, 2.3, 1.8, 2.2]$ 来自正态分布 $N(\mu, \sigma^2)$, μ 的先验分布是 $N(2, 1)$, $\sigma^2 = 0.5$ 已知, 求 μ 的后验期望。

解: 已经知道 $\mu|x \sim N(\mu_1, \sigma_1^2)$, 可计算得到


$$E(\mu|x) = 2.0614$$






第11讲 蒙特卡洛及MCMC方法

MCMC链轨迹图




后验密度图





第11讲 蒙特卡洛及MCMC方法


例4 观测数据 $x = [1.5, 3.7, 0.5, 1.9, 5.8]$ 来自 $t_4(\mu)$, μ 的先验分布是 $N(0, 100)$, 求 μ 的后验期望。






第11讲 蒙特卡洛及MCMC方法

mu链轨迹图



mu后验密度

```
> cat(sprintf("mu的后验均值 = %.4f\n", mu_est))
mu的后验均值 = 2.1979
> cat(sprintf("mu的后验标准差 = %.4f\n", mu_sd))
mu的后验标准差 = 0.7404
> cat(sprintf("mu的95%可信区间 = [%.4f, %.4f]\n", mu_ci[1], mu_ci[2]))
mu的95%可信区间 = [0.8246, 3.8014]
```





第11讲 蒙特卡洛及MCMC方法

小结

- 蒙特卡洛方法的主要原理
 - 重要性抽样方法
- 马氏链的基本概念
- 马氏链的主要性质
- 马氏链大数定律
- 马氏链蒙特卡洛方法

