

无服务器计算的研究前沿跟踪报告

——针对 SoCC 会议的前沿跟踪

报告人：23020119 谢昌熔

1 前言

本文梳理了 SoCC 会议近三年来收录的无服务器计算方向密切相关的论文。并对这些论文关注的问题、使用方法、结论与研究成果进行一一分析，总结无服务器计算方向的最新研究特点和趋势。

SoCC(ACM Symposium on Cloud Computing, CCF-B 推荐会议) 会议是云计算领域的首要会议，2021-2023 年会议的举办地点分别在西雅图、旧金山、加利福尼亚。它汇集了对云计算感兴趣的研究人员、开发人员、用户和从业者。旨在促进云计算相关的学术界与工业界的联系。无服务器计算被认为是有前景的下一代云计算模式，因此跟踪 SoCC 会议对了解无服务器计算前沿研究现状与趋势大有帮助。

2 论文分析

2.1 分析方法

本文利用关键词“serverless”、“FaaS”搜索 SoCC 会议从 2021 到 2023 年中收录的无服务器计算相关文献，再人工阅读论文题目与摘要内容进行筛选，通过上述方法可以得到 SoCC 会议三年内与无服务器计算密切相关的文章。如表 1 所示。

会议及时间	论文标题
SoCC-2021	Atoll: A Scalable Low-Latency Serverless Platform[1]
	Speedo: Fast Dispatch and Orchestration of Serverless Workflows[2]
SoCC-2022	Hermod: Principled and Practical Scheduling for Serverless Functions [3]
	SIMPPO: A Scalable and Incremental Online Learning Framework for Serverless Resource Management[4]
SoCC-2023	Golgi: Performance-Aware, Resource-Efficient Function Scheduling for Serverless Computing[5]
	The Gap Between Serverless Research and Real-world Systems[6]

表 1: 近三年 SoCC 会议无服务器计算相关文章

基于上述文献，本文将对它们的研究问题、研究方法、提出的创新技术、研究结果进行一一分析，以全面了解掌握 SoCC 会议中无服务器计算的研究现状与趋势。

3 SoCC-2021 会议

研究问题	提出了一种可扩展的低时延无服务器计算平台 Atoll
研究方法/提出技术	提出的平台具备优势： 1、提前预测函数的工作负载，提前分配运行容器，而非在函数请求运行后才分配。 2、使用截止时间感知调度策略，最大程度提高资源利用率。 3、优化调度策略。使用多个调度器，并将服务依据截止时间进行优先级排队，
研究结果	提出的 Atoll 延迟时间是当前最优平台的三分之一。

表 2: Atoll: A Scalable Low-Latency Serverless Platform.

研究问题	本研究提出了 Speedo 以实现无服务器计算工作流的快速调度和编排
研究方法/提出技术	提出的 Speedo 具备优势： 1、遵循最小化 CPU 处理 FaaS 调度器的原则对 Speed 进行设计。 2、将调度操作转移到 SmartNIC 上执行，以实现极低的调度延迟和高吞吐量。
研究结果	1、Speedo 在处理请求时表现出了几乎 50 倍的平均延迟降低，保持在 92.4 微秒。 2、Speedo 的调度延迟几乎保持恒定，即使在负载增加时也只有约 16% 的平均延迟增加。 3、Speedo 的调度器在处理独立函数和不同负载时都表现出色，具有极低的延迟和高吞吐量。

表 3: Speedo: Fast Dispatch and Orchestration of Serverless Workflows.

4 SoCC-2022 会议

研究问题	提出了一个具备负载和定位感知功能的无服务器函数调度器 Hermod。并在开源无服务器平台 OpenWhisk 上验证。
研究方法/提出技术	提出的工具具备优势： 1、具有局部性和负载感知的调度程序。 2、跟踪每个函数的可用热容器，尽可能避免冷启动。 3、使用提前绑定和处理器共享调度来避免在不知道函数执行时间情况下由于高负载导致的排队阻塞。
研究结果	在 OpenWhisk 上实现的该负载器可以提供高达 85% 的延迟减免与 60% 的承担工作负载提升。

表 4: Hermod: Principled and Practical Scheduling for Serverless Functions.

研究问题	提出了一种基于近端策略优化 (PPO) 的可扩展和增量的多智能体强化学习框架 SIMPPO，用于解决多租户无服务器平台资源管理中的性能问题
研究方法/提出技术	1、由于现有单智能体强化学习算法在多租户环境中的局限性，提出了基于多智能体强化学习的 SIMPPO 框架来解决这一问题。 2、每个 SIMPPO 中的智能体都有自己的策略，使用 PPO 进行训练，并管理一个独立的函数。该框架允许多个智能体在共享环境中共存，解决了训练不收敛和实现与单租户场景相当的策略服务性能的挑战。
研究结果	1、实验使用了一个开源的无服务器 FaaS 平台 OpenWhisk，在专用的本地集群和 IBM Cloud 上进行了实验。 2、在多租户情况下，p99 函数延迟退化增加了 2.2-4.8 倍。并且与多租户情况下的单智能体强化学习相比，资源开销有 4.5 倍的改进。SIMPPO 还显示出对更多函数和集群规模的可扩展性。

表 5: SIMPPO: A Scalable and Incremental Online Learning Framework for Serverless Resource Management.

5 SoCC-2023 会议

研究问题	提出了一种无服务器函数调度系统 Golgi, 目标是最小化资源供应成本, 同时满足功能持续性要求
研究方法/提出技术	提出的工具具备优势: 1、根据函数过去的资源使用情况来预测应当提供的资源量。 2、支持自动垂直缩放使过度提交的实例适应其性能需求。
研究结果	与现有方法相比产生的成本可显著减少 42%, 性能损失可忽略不计

表 6: Golgi: Performance-Aware, Resource-Efficient Function Scheduling for Serverless Computing.

研究问题	综述了当前无服务器计算的趋势和面临的挑战, 重点讨论了函数即服务 (FaaS) 的概念、可扩展性、性能和资源管理等方面
研究方法/提出技术	从实践经历中归纳总结出几个挑战的主题并对其进行分析。
研究结果	主要探究了五个挑战: 启动延迟、声明性的方法不足、调度开销大、需要更平衡的调度策略、多个控制器带来的开销。

表 7: The Gap Between Serverless Research and Real-world Systems.

6 总结

本文对 SoCC 会议近三年来无服务器计算相关的研究进行了跟踪, 主要关注其研究的问题、方法、提出的新技术、研究成果, 并对其进行了分析。通过阅读上述论文, 对无服务器计算当前的前沿研究方向与趋势有以下几点理解体会。

重点研究领域是资源管理与函数调度。在上述六篇文献中, 文献 [1]–[3], [5] 都是提出了具备新调度策略的平台或是函数调度器。由于在无服务器计算架构下, 应用是函数粒度, 由多个函数配合实现工作流, 在函数执行结束后函数的运行容器将被销毁, 因此如何为即将运行的函数分配合适的容器非常重要。优化函数调度策略的主要目的是提高资源利用率, 如文献 [5] 将应用的开销降低到了原来的一半, 这对云上运行的应用具有十分重要的意义。此外。文献 [4], [5] 都提出了新的资源管理策略。由于无服务器计算模式下, 资源管理的任务完全交给云服务供应商, 因此开发能最大限度利用资源的管理策略, 对云服务供应商来说意义重大。当前的方法主要是通过函数的特征或运行历史预测其可能需要的资源开销, 例如文献 [5] 对根据函数过去的资源使用情况预测当前应提供的资源量。总体而言, 当前的无服务器计算研究对这两个领域关注较多。

无服务器计算仍有大量研究问题可供探索。文献 [6] 是一篇综述性文献, 总结了当前无服务器计算的趋势和面临的挑战, 作者根据自己在实践中使用华为云等无服务器计算平台的经验, 对当前无服务器计算的启动延迟、调度开销大等问题进行了深入分析。研究表明, 这些领域仍存在许多问题亟待解决, 随着无服务器计算在近年来的快速推广, 在研究领域仍然存在许多可探索的问题方向。

无服务器计算距离实际广泛应用还有一定距离。在文献 [6] 中，作者提出了无服务器计算的研究与实际可使用的无服务器计算系统之间仍存在的五个挑战。分别是启动延迟、声明性方法不足、调度开销大、需要更平衡的调度策略、优化多个控制器带来的开销。这些问题的解决，有利于推进无服务器计算真正落地使用与更好地推广。这些问题的提出也为未来研究人员进一步深入研究无服务器计算领域提供了指导。

最后，我认为无服务器计算是一个前景光明的方向，由于其近年来的普遍流行，许多无服务器计算平台与应用被推出，但其底层技术仍然有很多需要进一步研究优化的缺陷，例如冷启动，通信策略、资源管理策略等。要把无服务器计算进一步推广到各种应用场景中，这些问题必须得到解决。

参考文献

- [1] A. Singhvi, A. Balasubramanian, K. Houck, M. D. Shaikh, S. Venkataraman, and A. Akella, “Atoll: A scalable low-latency serverless platform,” 2021.
- [2] N. Daw, U. Bellur, and P. Kulkarni, “Speedo: Fast dispatch and orchestration of serverless workflows,” in *Proceedings of the ACM Symposium on Cloud Computing*, Seattle WA USA: ACM, Nov. 2021, pp. 585–599, ISBN: 978-1-4503-8638-8.
- [3] K. Ka, N. J. Yadwadkar, and C. Kozyrakis, “Hermod: Principled and practical scheduling for serverless functions,” 2022.
- [4] H. Qiu, W. Mao, A. Patke, *et al.*, “Simppo: A scalable and incremental online learning framework for serverless resource management,” 2022.
- [5] S. Li, W. Wang, J. Yang, G. Chen, and D. Lu, “Golgi: Performance-aware, resource-efficient function scheduling for serverless computing,” in *Proceedings of the 2023 ACM Symposium on Cloud Computing*, Santa Cruz CA USA: ACM, Oct. 2023, pp. 32–47, ISBN: 9798400703874.
- [6] Q. Liu, D. Du, Y. Xia, P. Zhang, and H. Chen, “The gap between serverless research and real-world systems,” in *Proceedings of the 2023 ACM Symposium on Cloud Computing*, New York, NY, USA: Association for Computing Machinery, 2023, pp. 475–485, ISBN: 9798400703874.